TRABAJO FINAL DE GRADO

Presentado para lograr el título de

LICENCIADO EN CIENCIA DE DATOS

Seminario de Trabajo Final

«Impacto de shocks informativos en el comportamiento bursátil de empresas argentinas: un enfoque basado en análisis de sentimiento y modelos de series temporales»

Autores

Gino Frigoni	DNI 31.356.373
Nicolás Diego Diddi	DNI 46.443.733

Rosario, _____

_____ _____

Firma autor Firma autor

Resumen

Impacto de shocks informativos en el comportamiento bursátil de empresas argentinas: un enfoque basado en análisis de sentimiento y modelos de series temporales

Este trabajo estudió si las noticias económicas publicadas por los medios digitales argentinos anticipan el precio y el volumen operado de las acciones que cotizan en Bolsas y Mercados Argentinos (BYMA), o si, por el contrario, reflejan lo que el mercado ya hizo. Se construyó un corpus de 14.012 notas de siete portales, depurado de duplicados, plantillas y contenido que no era noticia, y se midió su tono con FinBETO, un modelo BETO adaptado al dominio y ajustado para clasificar oraciones de prensa económica en cuatro clases (F1 macro de 0,685 en noticias no vistas). En paralelo se armó un panel de 47 acciones de BYMA, con su volatilidad, su liquidez y el régimen de mercado de cada día estimado con un modelo de cambio de régimen de Markov. Ambos lados se unieron en 244 ruedas (mayo de 2025 a abril de 2026), asignando cada nota a la primera rueda en la que el mercado pudo reaccionar a ella. Sobre esa base se estimaron modelos VAR con pruebas de causalidad de Granger y funciones de impulso-respuesta, una prueba con las notas publicadas con el mercado cerrado, estudios de eventos sobre las ruedas de tono extremo y sobre los shocks de cantidad de noticias, y doce variantes de robustez. El tono de las noticias no anticipó los precios ni el volumen: ni en el mercado, ni en las empresas, ni en los sectores, ni según el régimen. Lo que apareció fue la relación inversa: el retorno del S&P Merval anticipa el tono de las notas siguientes, en 39 de las 47 empresas y en 15 de las 17 con tono propio, y el efecto se concentra en las notas publicadas la misma noche, después del cierre. Cuando una empresa aparece en muchas más notas que lo habitual, su acción se opera más ese día, sin una dirección en el precio. Los medios económicos argentinos, en el período estudiado, siguieron al mercado.

Palabras clave: análisis de sentimiento; BETO; noticias económicas; causalidad de Granger; estudio de eventos; S&P Merval.

Temática de Interés en Ciencia de Datos: procesamiento de lenguaje natural y econometría de series de tiempo aplicados a mercados financieros.

Índice general

Resumen **2**

Siglas y términos **11**

1. Introducción **12**

2. Objetivos **14**

2.1. Problemática observada 14

2.2. Hipótesis de investigación 14

2.3. Objetivo general 15

2.4. Objetivos específicos 15

2.5. Antecedentes 16

2.5.1. Noticias y precios: ¿anticipan o reflejan? 16

2.5.2. Medición del sentimiento con procesamiento de lenguaje natural . . . 17

2.5.3. Argentina y Latinoamérica 17

2.5.4. El vacío que cubre este trabajo 18

2.6. Metodología 18

2.7. Impacto esperado 19

2.8. Cronograma 19

3. Noticias, sentimiento y mercado: el caso del S&P Merval **21**

3.1. Conceptos centrales 21

3.1.1. Shock informativo 21

3.1.2. Eficiencia de mercado 21

3.1.3. Sentimiento del inversor y tono de los medios 22

3.1.4. Causalidad de Granger y modelos VAR 22

3.1.5. Estudios de eventos 22

3.1.6. Volatilidad y regímenes de mercado 22

3.2. El mercado argentino en la ventana de estudio 23

3.3. Unidades de análisis 25

4. Técnicas de Ciencia de Datos **27**

4.1. Adquisición de datos 28

4.1.1. Web scraping de noticias 28

4.1.2. Precios de acciones 29

4.2. Análisis exploratorio de series de tiempo 29

4.2.1. Estacionariedad: ADF y KPSS 29

4.2.2. Volatilidad realizada 30

4.2.3. Clustering de acciones 30

4.2.4. Regímenes de mercado 30

4.3. Modelos de lenguaje 31

4.3.1. FinBETO: BETO adaptado al dominio 31

4.3.2. Reconocimiento de entidades nombradas 31

4.4. Modelos de series de tiempo y pruebas 32

4.4.1. VAR, causalidad de Granger e impulso-respuesta 32

4.4.2. Estudio de eventos 32

4.4.3. Pruebas múltiples 32

4.4.4. Encogimiento hacia el promedio 33

5. Desarrollo Experimental **34**

5.1. Materiales y métodos 34

5.1.1. Recolección de los datos 35

5.1.2. Limpieza y preparación de los datos 36

5.1.3. Análisis univariado 42

5.1.4. Análisis multivariado 43

5.1.5. Modelado 47

6. Resultados y Discusión **53**

6.1. ¿Quién anticipa a quién? VAR y causalidad de Granger 53

6.1.1. El mercado 53

6.1.2. Las empresas 54

6.1.3. Los sectores y el régimen 56

6.2. La prueba más directa: notas publicadas con el mercado cerrado 57
6.3. Estudio de eventos: ruedas de tono extremo 58
6.4. Estudio de eventos: shocks de cantidad de noticias 60
6.5. Robustez: cuándo siguen los medios al mercado 62
6.6. Discusión 64

7. Conclusiones **66**
7.1. Respuesta a los objetivos 66
7.2. La hipótesis 66
7.3. Aporte 67
7.4. Limitaciones 67
7.5. Líneas futuras 68

Bibliografía **69**

A. Panel de acciones **78**

B. Diccionario de variables **80**

C. Alineación de las notas con las ruedas **83**

D. Detalle de las pruebas de Granger **84**

E. Especificaciones escritas antes de los resultados **87**
E.1. Notas publicadas con el mercado cerrado (U6b) 87
E.2. Shock de cantidad de noticias (U7b) 87

F. Reproducibilidad y organización del proyecto **89**

G. Bibliografía por tema **91**

Índice de figuras

3.1. S&P Merval en pesos (arriba) y VIX argentino (abajo), del 2/1/2025 al 30/4/2026. El sombreado marca los días por encima del promedio. Fuente: elaboración propia con datos de Yahoo Finance (`Lado Bursatil/03_vix_argentino`). 24

4.1. Mapa de la tesina: el lado bursátil (azul), el lado de noticias (verde), la unión (violeta) y el resultado (rojo). Fuente: elaboración propia (`Unión/09_entrega_final/mapa_tesis.py`, que lee los resultados de cada carpeta). 28

5.1. Arriba: hora de publicación de las notas, con la rueda sombreada y el cierre de las 17:00; en rojo, horas repetidas que no pueden ser reales. Abajo: notas que recibe cada rueda, según de dónde vienen. Fuente: elaboración propia (`Unión/01_alineacion_noticias_ruedas`). 38

5.2. Arriba: tono de cada rueda (ajustado por portal), su media de las 20 ruedas previas y las ruedas de tono extremo. Abajo: atención anormal de los medios. Fuente: elaboración propia (`Unión/02_sentimiento_por_rueda`). 40

5.3. Arriba: ruedas con al menos una noticia de cada empresa (en azul, las 17 con tono propio). Abajo: tono propio de esas 17 empresas en cada rueda. Fuente: elaboración propia (`Unión/03_sentimiento_por_empresa`). 41

5.4. Volatilidad promedio de las 47 acciones, coloreada por sector, con el VIX argentino como referencia (2/1/2025 al 30/4/2026). Fuente: elaboración propia (`Lado Bursatil/05_volatilidad_ranking`). 42

5.5. S&P Merval y VIX argentino coloreados por régimen, y probabilidad suavizada de cada régimen por día. Fuente: elaboración propia (`Lado Bursatil/06_hmm_regimen_mercado`). 45

5.6. S&P Merval, tono de las noticias, atención de los medios y monto operado anormal en la ventana de la unión. El color de fondo es el régimen; las líneas punteadas, los días electorales. Fuente: elaboración propia (`Unión/04_dataset_unificado`). 47

6.1. Funciones de impulso-respuesta del VAR del mercado ante un golpe de un desvío, con banda del 95 %. Si la banda no toca el cero, la respuesta es distinta de cero. Fuente: elaboración propia (`Unión/06_var_granger`). 54

6.2. Pruebas de Granger por empresa. Cada fila es una empresa y cada columna una prueba; más oscuro, p más chico; ∘ $p < 0{,}05$ sin corregir; • significativo después de la corrección. Fuente: elaboración propia (`Unión/06_var_granger`). . 56

6.3. Cada punto es una rueda. Horizontal: tono anormal de las notas publicadas con el mercado cerrado. Vertical: retorno promedio de las 47 acciones, de apertura (izquierda) y de la sesión (derecha). Fuente: elaboración propia (`Unión/06b_noticias_preapertura`). 58

6.4. Retorno anormal acumulado promedio del S&P Merval desde tres ruedas antes hasta cinco después de las ruedas de tono extremo. La banda gris es el 95 % de lo que da el azar con la misma cantidad de fechas. Fuente: elaboración propia (`Unión/07_event_study`). 59

6.5. Retorno anormal acumulado de cada empresa alrededor de sus ruedas de tono propio extremo, positivo y negativo. Fuente: elaboración propia (`Unión/07_event_study`). 60

6.6. A: retorno anormal acumulado del S&P Merval alrededor de los shocks de cantidad, contra el 95 % de fechas al azar. B y C: tamaño del movimiento en los shocks contra un día cualquiera; C cuenta solo las notas publicadas con el mercado cerrado. Fuente: elaboración propia (`Unión/07b_shock_volumen_noticias`). . 62

6.7. Resultados principales en cada variante de robustez. Fuente: elaboración propia (`Unión/08_robustez`). 64

Índice de tablas

2.1. Estado de los objetivos específicos. Fuente: elaboración propia. 16

2.2. Hitos del trabajo. Fuente: elaboración propia a partir de la documentación de cada etapa. 20

3.1. Las dos direcciones de la relación entre noticias y mercado y cómo se reconoce cada una en los datos. Fuente: elaboración propia. 23

3.2. Episodios con el VIX argentino por encima de 55 %. Fuente: elaboración propia (`Lado Bursatil/03_vix_argentino`). 24

3.3. Panel de acciones por sector. Fuente: elaboración propia (`Lado Bursatil/01_scraping_acciones`). 25

3.4. Corpus de noticias por fuente, después de la depuración. Fuente: elaboración propia (`Lado Noticias/noticias`). 26

4.1. Lectura conjunta de las pruebas ADF y KPSS. Fuente: elaboración propia. . . 29

5.1. Fuentes de datos y ventanas temporales. Fuente: elaboración propia. 34

5.2. Problemas del corpus y cómo se resolvieron. Fuente: elaboración propia a partir de la auditoría del lado de noticias (`Lado Noticias/noticias`). 36

5.3. Asignación de las notas a las ruedas con la regla de las 17:00. Fuente: elaboración propia (`Unión/01_alineacion_noticias_ruedas`). 37

5.4. Shocks de tono que marca cada regla con las noticias reales y con las notas mezcladas al azar (promedio de 300 mezclas). Fuente: elaboración propia (`Unión/02_sentimiento_por_rueda`). 39

5.5. Estadísticos descriptivos de las variables principales en la ventana de la unión (05/05/2025 al 30/04/2026). El tono anormal y la atención tienen 224 filas porque las primeras 20 ruedas no tienen 20 ruedas previas de referencia. Fuente: elaboración propia (`Unión/04_dataset_unificado`). 43

5.6. Robustez del grupo de 8 acciones del clustering. Fuente: elaboración propia (`Lado Bursatil/02_clustering_acciones`). 44

5.7. Regímenes del mercado entre el 2/1/2025 y el 30/4/2026 (323 ruedas). Fuente: elaboración propia (`Lado Bursatil/06_hmm_regimen_mercado`). 44

5.8. Estacionariedad de las series en la ventana de la unión. Fuente: elaboración propia (`Unión/05_adf_union`). 46

5.9. Calidad de FinBETO según cómo se dividen los datos. La estimación que corresponde informar es la de la división por noticia. Fuente: elaboración propia a partir de `Lado Noticias/sentimiento_finbert`. 48

5.10. Efecto de la limpieza del reconocimiento de entidades. Fuente: elaboración propia a partir de `Lado Noticias/ner_entidades`. 49

5.11. Niveles del análisis VAR. Fuente: elaboración propia (`Unión/06_var_granger`). . 50

6.1. Pruebas de causalidad de Granger en el VAR del mercado (224 ruedas). Fuente: elaboración propia (`Unión/06_var_granger`). 53

6.2. Pruebas de Granger por empresa. Fuente: elaboración propia (`Unión/06_var_granger`). 55

6.3. Pruebas de Granger según el régimen (p; en negrita, significativas después de la corrección). Fuente: elaboración propia (`Unión/06_var_granger`). 56

6.4. Tono de las notas publicadas con el mercado cerrado y retorno de la rueda siguiente. Fuente: elaboración propia (`Unión/06b_noticias_preapertura`). 57

6.5. Los dos días electorales en la prueba pre-apertura. Fuente: elaboración propia (`Unión/06b_noticias_preapertura`). 58

6.6. Retorno anormal acumulado del S&P Merval alrededor de las ruedas de tono extremo. Fuente: elaboración propia (`Unión/07_event_study`). 59

6.7. Estudio de eventos de los shocks de cantidad de noticias (selección de las 14 pruebas principales; el resto no es significativo). RA: retorno anormal; Vol.: volumen anormal en logaritmo (0 = lo habitual). La corrección de Benjamini-Hochberg se aplica sobre las 14. Fuente: elaboración propia (`Unión/07b_shock_volumen_noticias`). 61

6.8. Shocks de cantidad contando solo las notas publicadas con el mercado cerrado. El salto de apertura del mercado depende del 24/09/2025: sin ese día, $p = 0{,}093$. Fuente: elaboración propia (`Unión/07b_shock_volumen_noticias`). 61

6.9. Resultados principales en cada variante (p corregidos). Fuente: elaboración propia (`Unión/08_robustez`). 63

6.10. Relación entre el retorno de una rueda y el tono de las notas según la franja en que se publicaron. Fuente: elaboración propia (`Unión/08_robustez`). 63

A.1. Panel de 47 acciones. Fuente: elaboración propia (`Lado Bursatil/01_scraping_acciones`, `05_volatilidad_ranking` y `Unión/03_sentimiento_por_empresa`). 79

B.1. Diccionario de variables de los datasets unificados. Fuente: elaboración propia. 82

D.1. Granger con el tono propio de las 17 empresas. Fuente: elaboración propia (`Unión/06_var_granger/granger_resultados.csv`). 84

D.2. Granger de las 47 empresas con el tono anormal del mercado. Fuente: elaboración propia (Unión/06_var_granger/granger_resultados.csv). 86

D.3. Granger por sector. «Sí» indica significativo después de la corrección, con el signo del efecto; «sin corregir», $p < 0{,}05$ solo sin corrección. Fuente: elaboración propia (Unión/06_var_granger). 86

F.1. Organización del proyecto. Fuente: elaboración propia. 90

G.1. Referencias agrupadas por tema. Fuente: elaboración propia. 92

Siglas y términos

Sigla	Significado
ADF	Prueba de Dickey-Fuller aumentada (raíz unitaria).
AIC / BIC	Criterios de información de Akaike y bayesiano (Schwarz).
BETO	Modelo BERT preentrenado en español (Universidad de Chile).
BH	Corrección de Benjamini-Hochberg por pruebas múltiples.
BYMA	Bolsas y Mercados Argentinos.
CAR	Retorno anormal acumulado (*cumulative abnormal return*).
CCL	Dólar contado con liquidación.
CRISP-DM	Proceso estándar para proyectos de minería de datos.
DLM	Modelo de rezagos distribuidos (*distributed lag model*).
EWMA	Media móvil con ponderación exponencial.
F1 macro	Promedio simple del F1 de cada clase.
FinBETO	BETO adaptado al dominio de la prensa económica y ajustado para sentimiento.
HMM	Modelo oculto de Markov; aquí, modelo de cambio de régimen de Markov.
IRF	Función de impulso-respuesta.
KPSS	Prueba de estacionariedad de Kwiatkowski, Phillips, Schmidt y Shin.
MLM	Modelado de lenguaje enmascarado (*masked language modeling*).
MST	Árbol de expansión mínima (*minimum spanning tree*).
NER	Reconocimiento de entidades nombradas.
OLS / MCO	Mínimos cuadrados ordinarios.
Rueda	Día hábil de operación en BYMA (de 11:00 a 17:00).
Tono	Sentimiento neto: % de oraciones positivas menos % de negativas.
Tono anormal	Tono de la rueda menos el promedio de las 20 ruedas previas.
Tono propio	Cuánto mejor o peor se habla de una empresa que del mercado, ponderado por la cantidad de oraciones.
VAR	Vector autorregresivo.
VIX argentino	Volatilidad realizada del S&P Merval en 20 ruedas, anualizada.

Capítulo 1

Introducción

Los mercados financieros se mueven con la información. Un dato de inflación, un anuncio del Banco Central o el resultado de una elección cambian lo que los inversores esperan de las empresas, y esas expectativas se trasladan a los precios y al volumen operado. Los medios económicos son uno de los canales por los que esa información circula: cada día publican decenas de notas sobre el tipo de cambio, la política económica y las empresas que cotizan en bolsa. Desde hace casi dos décadas, la literatura financiera estudia si el contenido de esas notas, y en particular su tono, ayuda a anticipar el comportamiento de las acciones o si se limita a contar lo que el mercado ya hizo (Tetlock, 2007; Garcia, 2013; Verma et al., 2026).

Este trabajo lleva esa pregunta al mercado argentino. Se recolectaron 14.012 notas de las secciones de economía y finanzas de siete portales (Clarín, La Nación, Infobae, Ámbito Financiero, TN, El Economista e iProfesional) y se midió su tono con un modelo de lenguaje en español adaptado a la prensa económica. Del lado del mercado se armó un panel de 47 acciones de Bolsas y Mercados Argentinos (BYMA), que incluye a las 20 que componen el S&P Merval, con su precio, su volumen, su volatilidad y el régimen de mercado de cada día. Los dos lados se unieron en una ventana común de 244 ruedas, del 5 de mayo de 2025 al 30 de abril de 2026, asignando cada nota a la primera rueda en la que el mercado pudo reaccionar a ella. El período empieza semanas después de la salida del cepo cambiario, todavía dentro de la turbulencia global por los aranceles de Estados Unidos, e incluye el anuncio de apoyo financiero del Tesoro de Estados Unidos, las elecciones bonaerenses del 7 de septiembre y las legislativas nacionales del 26 de octubre de 2025: un año con shocks informativos grandes y frecuentes.

La pregunta importa por tres motivos. Para los inversores, si el tono de los medios anticipa los precios, es una señal que se puede usar; si no lo hace, es ruido que conviene no seguir. Para la teoría de los mercados eficientes, Argentina es un caso de interés: un mercado chico, con acciones poco líquidas y alta volatilidad macroeconómica, donde la información podría tardar más en incorporarse a los precios (Fama, 1970; Zablotsky, 2002). Y para la ciencia de datos en español, casi no existen trabajos que crucen el tono de la prensa económica con precios de acciones: hay modelos de sentimiento financiero en español (Braña et al., 2016; Rodríguez-García et al., 2023; Pan et al., 2023), pero el cruce con el mercado se hizo, en la región, en Brasil y Colombia (Galdi y Gonçalves, 2018; Cruz Montaña y Tirado León, 2025), no en Argentina.

El documento sigue el orden del trabajo. El capítulo 2 presenta el problema, la hipótesis, los objetivos, los antecedentes y la metodología. El capítulo 3 desarrolla el marco teórico y describe el mercado argentino en la ventana de estudio. El capítulo 4 define las técnicas de ciencia de datos utilizadas. El capítulo 5 detalla los datos, su limpieza, el análisis exploratorio

y la especificación de los modelos. El capítulo 6 presenta los resultados y los discute con la literatura, y el capítulo 7 cierra con las conclusiones, las limitaciones y las líneas futuras. Los anexos reúnen el diccionario de variables, el detalle de las pruebas y las especificaciones escritas antes de correr los análisis.

Capítulo 2

Objetivos

2.1 Problemática observada

En la conversación cotidiana sobre la bolsa argentina está muy extendida la idea de que «las noticias mueven las acciones»: un titular negativo sobre el dólar o sobre una empresa precedería a una caída de su cotización, y una buena noticia, a una suba. La observación tiene sustento intuitivo, porque los días de noticias grandes, como los posteriores a una elección, son también días de movimientos fuertes del S&P Merval. Pero esa coincidencia no dice qué vino primero. Es posible que las noticias muevan al mercado, y también que los medios cuenten lo que el mercado ya hizo, con un tono que acompaña la suba o la baja. El problema de este trabajo es separar esas dos posibilidades con datos: ordenar en el tiempo el tono y la cantidad de las noticias económicas y el precio y el volumen de las acciones, y ver cuál anticipa a cuál.

2.2 Hipótesis de investigación

El plan de trabajo define el *shock informativo* como un aumento anormal del volumen de noticias publicadas por medios digitales argentinos sobre temas económico-financieros, y plantea las siguientes hipótesis:

> **Hipótesis alternativa (H1).** «El shock informacional tiene un impacto medible y estadísticamente significativo sobre el comportamiento bursátil —precio y/o volumen de transacciones— de las empresas argentinas que cotizan en bolsa.»
>
> **Hipótesis nula (H0).** «El shock informacional no tiene un impacto estadísticamente significativo sobre el comportamiento bursátil de las empresas argentinas.»

Para contrastarlas, el shock se midió de dos maneras complementarias: por su *tono* (días en que las noticias son mucho más positivas o negativas que lo habitual) y por su *cantidad* (días con muchas más notas que lo habitual, la definición literal del plan). La dirección que interesa es noticias → mercado: que el shock preceda al movimiento del precio o del volumen. Si los datos muestran la dirección contraria, o ninguna, la hipótesis no se sostiene, y ese también es un resultado.

2.3 Objetivo general

- Modelar y cuantificar el impacto de shocks informativos provenientes de portales de noticias argentinos sobre el comportamiento bursátil —precio y volumen de transacciones— de empresas argentinas que cotizan en bolsa.

2.4 Objetivos específicos

1. Construir y consolidar un corpus de noticias de economía y finanzas de los principales portales digitales argentinos, estructurado como serie temporal por portal y fecha.
2. Diseñar e implementar un modelo de análisis de sentimiento financiero en español, adaptando la arquitectura FinBERT mediante el ajuste fino de BETO sobre noticias financieras argentinas.
3. Integrar datos de *trending topics* de X/Twitter como variable complementaria para la detección y validación de shocks informativos.
4. Definir y cuantificar variables de shock informativo: volumetría de publicaciones, temperatura del sentimiento agregado y presencia de entidades en el flujo noticioso.
5. Agrupar las empresas del mercado accionario argentino en conjuntos significativos, considerando la clasificación sectorial y la sensibilidad al flujo informativo.
6. Modelar la relación entre las variables de shock informativo y las variables bursátiles, incorporando desfases temporales para capturar el impacto diferido del flujo de noticias.

La tabla 2.1 resume cómo se cumplió cada objetivo y en qué parte del documento se desarrolla. El objetivo 3 no se realizó: los datos de X/Twitter no llegaron a integrarse al análisis y quedan como trabajo futuro. En el objetivo 6, el plan preveía también un modelo de rezagos distribuidos (DLM); se cumplió con un VAR, que ya incorpora los efectos rezagados, y el DLM queda como línea futura.

Obj.	Qué se hizo	Estado	Dónde
1	14.012 notas de 7 portales, depuradas y asignadas a ruedas con la regla de las 17:00	Cumplido	§5.1.1, §5.1.2
2	FinBETO, 4 clases; F1 macro de 0,685 en noticias no vistas, por encima del modelo de referencia	Cumplido	§5.1.5
3	Los datos de X/Twitter no se integraron	No realizado	§7.5
4	Atención anormal (cantidad de notas), tono anormal, ruedas de tono extremo, tono propio de cada empresa y shock de cantidad según el plan	Cumplido	§5.1.2, §6.4
5	Clustering de las 47 acciones y análisis por sector y por empresa	Cumplido	§5.1.4
6	VAR, Granger, impulso-respuesta, estudios de eventos y análisis por régimen; el DLM queda como trabajo futuro	Cumplido (con VAR)	cap. 6

Tabla 2.1. Estado de los objetivos específicos. Fuente: elaboración propia.

2.5 Antecedentes

2.5.1 Noticias y precios: ¿anticipan o reflejan?

El antecedente central es Tetlock (2007), que midió el pesimismo de una columna diaria del *Wall Street Journal* y encontró dos cosas: el pesimismo anticipa una baja de los precios que luego se revierte, y los retornos bajos anticipan más pesimismo en la columna. Es decir, la relación existe en las dos direcciones. Garcia (2013), con columnas financieras del *New York Times* entre 1905 y 2005, mostró que el tono anticipa los retornos casi solo en las recesiones, lo que sugiere que el efecto depende del estado del mercado. Otros trabajos separaron el efecto de la cobertura del de su contenido: Fang y Peress (2009) encontraron que las acciones sin cobertura de medios rinden más que las muy cubiertas, Engelberg y Parsons (2011) usaron la cobertura local de un mismo hecho para identificar un efecto causal de los medios sobre el volumen operado, y Dougal et al. (2012) mostraron que la identidad del periodista que escribe la columna predice el retorno del día siguiente. Da et al. (2011) propusieron medir la atención de los inversores con las búsquedas en internet, una variable de cantidad y no de tono.

Trabajos más recientes retoman la pregunta de fondo de esta tesina. Verma et al. (2026) usan el shock de 2020 para preguntar si las noticias influyen en el precio o reflejan información que el precio ya tiene; Jazbec et al. (2020) miden cuánta información pasa de las noticias de la web a los precios con medidas de transferencia de información; Kargarzadeh et al. (2026) estudian en qué momento el precio incorpora una noticia —antes, el mismo día o después—, y Glasserman et al. (2025) se preguntan si las noticias publicadas de noche explican el retorno entre el cierre y la apertura. Knuteson (2020) documenta que el retorno nocturno y el del día se comportan de forma muy distinta, lo que justifica separarlos. Sobre la cantidad de noticias, Cao et al. (2025) construyen un índice de atención mediática por acción, y Guo et al.

(2017) muestran que dos empresas que aparecen en una misma noticia comparten atención y movimientos de precio. Ardia et al. (2022) usan el *tono anormal* de los medios —el tono comparado con lo habitual— en estudios de eventos alrededor de anuncios de resultados, y Chen (2025) critican resumir el sentimiento de un día en un solo número sin separar los temas.

2.5.2 Medición del sentimiento con procesamiento de lenguaje natural

La medición del tono pasó de los diccionarios de palabras a los modelos de lenguaje. El diccionario financiero de Loughran y McDonald (2011) mostró que las listas de palabras generales clasifican mal el lenguaje financiero (por ejemplo, «pasivo» no es negativo en un balance). Malo et al. (2014) publicaron el *Financial PhraseBank*, un conjunto de oraciones financieras etiquetadas por personas, y Araci (2019) ajustó sobre él un modelo BERT (Devlin et al., 2019) para clasificar sentimiento financiero en inglés (FinBERT). Para el español, Cañete et al. (2020) entrenaron BETO, el BERT en español de la Universidad de Chile, y Gutiérrez-Fandiño et al. (2022) la familia MarIA del Barcelona Supercomputing Center. Pérez et al. (2021) publicaron pysentimiento, con modelos de sentimiento en español entrenados con tuits. En el dominio financiero en español, la competencia FinancES 2023 (Marín et al., 2023) y los trabajos de Pan et al. (2023), García-Díaz et al. (2023) y Rodríguez-García et al. (2023) evaluaron modelos tipo BERT sobre titulares y tuits económicos; en la comparación de Pan et al. (2023), BETO y MarIA son los de mejor desempeño.

Sobre cómo pasar de oraciones a series de tiempo, Mavillonio et al. (2026) construyen índices diarios de sentimiento con modelos tipo BERT frase por frase y los comparan con los de diccionario; Stan et al. (2026) y Carbó Casals (2026) muestran que la serie es ruidosa cuando hay días con pocas noticias y proponen darles menos peso, y Correa Rocha (2026) documenta que el tono de las noticias económicas es muy persistente. A nivel de empresa, Tang et al. (2023) y Sinha et al. (2023) clasifican el sentimiento hacia cada entidad nombrada en una noticia, ya que una misma nota puede ser buena para una empresa y mala para otra.

2.5.3 Argentina y Latinoamérica

En la región los antecedentes son pocos. Braña et al. (2016) clasificaron frases de noticias financieras argentinas como positivas, negativas o neutras, sin cruzarlas con precios. Galdi y Gonçalves (2018) midieron el tono de 1.237 ediciones del diario *Valor Econômico* y encontraron que las palabras de incertidumbre se asocian con menor rentabilidad de la bolsa brasileña. Cruz Montaña y Tirado León (2025) cruzaron el tono de noticias financieras con el índice COLCAP de Colombia. Coronado et al. (2022; 2023) probaron la causalidad de Granger desde índices de noticias sobre el COVID-19 hacia las bolsas latinoamericanas, Argentina incluida, pero con cantidad de noticias y no con tono. Rojas y Kristjanpoller (2015) estudiaron la causalidad entre retorno y volumen en las bolsas de la región, y Chniguir y Henchiri (2022) la causalidad entre sentimiento y retornos en Marruecos y Túnez, dos mercados emergentes chicos como el argentino. Mukherjee (2025) y Wu et al. (2026) aplican pruebas de Granger y redes de contagio del sentimiento entre noticias y redes sociales. Para Argentina, Calandroni

(2026) estudió el efecto de las elecciones sobre el Merval entre 2011 y 2023 con un estudio de eventos, y Amburgey (2025) mostró, para Estados Unidos, que un mismo shock electoral mueve a los sectores en direcciones distintas.

2.5.4 El vacío que cubre este trabajo

No se encontró un trabajo que cruce el tono de la prensa económica argentina con el precio y el volumen de las acciones de BYMA. Los antecedentes en español clasifican el sentimiento sin cruzarlo con el mercado; los latinoamericanos que sí lo cruzan son de Brasil y Colombia, o usan cantidad de noticias y no tono. Esta tesina aporta ese cruce para Argentina, con un modelo de sentimiento propio, tono por empresa, pruebas en las dos direcciones y una prueba que usa la hora de publicación de cada nota para ordenar noticias y precios en el tiempo.

2.6 Metodología

Tipo de estudio. Es un estudio observacional, longitudinal y correlacional: no interviene sobre las variables, las sigue en el tiempo (244 ruedas) y analiza su relación y su orden temporal. La población es el conjunto de acciones de empresas argentinas que cotizan en BYMA; la muestra son 47 acciones que cumplen criterios de cobertura y liquidez, 17 de ellas con noticias suficientes para medir su tono propio. El corpus son las notas de las secciones de economía y finanzas de siete portales nacionales.

El trabajo se organizó como un *pipeline* de tres partes, siguiendo las fases del proceso CRISP-DM (Wirth y Hipp, 2000):

- **Lado bursátil.** Selección del panel de acciones a partir de Yahoo Finance, clustering, volatilidad realizada del mercado (VIX argentino), pruebas de estacionariedad, volatilidad por acción y régimen de mercado con un modelo de cambio de régimen de Markov.
- **Lado de noticias.** Recolección del corpus (Wayback Machine y mapas del sitio), depuración, etiquetado de oraciones con un modelo de lenguaje, entrenamiento de FinBETO, serie diaria de sentimiento y reconocimiento de entidades (NER) para medir el tono de cada empresa.
- **Unión.** Alineación de cada nota con la rueda en la que el mercado pudo reaccionar (regla de las 17:00), series de tono y atención por rueda y por empresa, datasets unificados, estacionariedad, VAR con pruebas de Granger e impulso-respuesta, prueba con las notas publicadas con el mercado cerrado, estudios de eventos y robustez.

Dos especificaciones (la prueba pre-apertura y el estudio de eventos del shock de cantidad) se escribieron y guardaron antes de correr los cálculos, y todas las familias de pruebas se corrigieron por comparaciones múltiples. El detalle de cada paso está en los capítulos 4 y 5.

2.7 Impacto esperado

Científico. El trabajo aporta evidencia sobre la relación entre medios y mercado en un mercado emergente y en español, donde casi no la hay, y un conjunto de oraciones de prensa económica argentina etiquetadas por sentimiento, que no existía. El método es replicable: cada paso tiene su script, sus controles automáticos y su documentación.

Práctico. Para inversores y analistas, el resultado indica si el tono de los medios es una señal que se adelanta al mercado o un reflejo de él. Para reguladores, ofrece una forma de medir cómo la cobertura mediática acompaña la actividad bursátil.

Metodológico. El *pipeline* es reproducible de punta a punta: un solo comando rehace toda la unión y verifica que los 64 archivos de resultados salgan idénticos y que los 66 controles automáticos pasen.

Por qué de a dos. La tesina combina dos campos con técnicas propias: el procesamiento de lenguaje natural (recolectar y depurar miles de notas, entrenar y evaluar un modelo de sentimiento, reconocer entidades) y la econometría financiera (armar y depurar un panel de acciones, medir volatilidad y regímenes, modelar series de tiempo). La carga de trabajo de cada lado justifica un equipo de dos. La división fue la siguiente: el lado de noticias (corpus, sentimiento y NER) estuvo a cargo de Gino Frigoni; el lado bursátil (panel, clustering, volatilidad, estacionariedad y régimen), de Nicolás Diddi. La unión de los dos lados, que responde la pregunta de la tesina, integra el trabajo de ambos.

2.8 Cronograma

El plan de trabajo se presentó en mayo de 2026. A partir de entonces el trabajo avanzó por lados: cada uno cerró sus resultados con su propia documentación y recién después se unieron. La tabla 2.2 registra los hitos documentados del proceso.

Etapa	Hito	Fecha
Plan de trabajo	Presentación del proyecto (hipótesis, objetivos y metodología)	Mayo de 2026
Corpus de noticias	Recolección de notas publicadas hasta el 3 de mayo de 2026	Hasta mayo de 2026
Lado bursátil	Panel de 47 acciones, VIX, ADF, volatilidad y régimen; revisión cerrada	Octubre de 2026
Lado de noticias	Auditoría del corpus, nueva medición de FinBETO y cruce con el NER; versión final	18/10/2026
Unión	Alineación, datasets, VAR y Granger, estudios de eventos y robustez (U1 a U9)	17 al 24/10/2026
Actualización del plan	Estado de los objetivos y corrección del apellido de un autor (versión 3)	Octubre de 2026
Informe final	Redacción de esta tesina	Octubre de 2026

Tabla 2.2. Hitos del trabajo. Fuente: elaboración propia a partir de la documentación de cada etapa.

Respecto de lo planificado hubo tres cambios. Los datos de X/Twitter no se integraron (objetivo 3). El DLM se reemplazó por el VAR, que ya trabaja con rezagos. Y se sumaron pruebas que el plan no preveía: el tono propio de cada empresa, la prueba con las notas publicadas con el mercado cerrado y las doce variantes de robustez.

Capítulo 3

Noticias, sentimiento y mercado: el caso del S&P Merval

Que «las noticias mueven la bolsa» es una frase que mezcla dos ideas. La primera es que el precio de una acción resume lo que los inversores saben y esperan de la empresa, y que cambia cuando llega información nueva. La segunda es que los medios son el vehículo de esa información. Si las dos son ciertas, una noticia relevante debería mover el precio en cuanto se publica. Pero los medios también cumplen otra función: informan sobre el propio mercado. Una nota que cuenta que «el Merval subió 5 %» es una noticia económica con tono positivo, y su causa es el precio, no al revés. Este capítulo presenta los conceptos con los que se analiza esa doble relación y describe el mercado argentino en el período estudiado.

3.1 Conceptos centrales

3.1.1 Shock informativo

Se llama *shock informativo* a la llegada de información que se aparta de lo esperado y que, por eso, puede cambiar las expectativas de los inversores. El plan de trabajo lo define por la cantidad: un aumento anormal del volumen de noticias publicadas, medido con un puntaje z respecto de la media de los 30 días previos. En este trabajo se usa además una definición por el tono: días en que las noticias son mucho más positivas o negativas que lo habitual. Las dos definiciones miden cosas distintas. La cantidad capta la *atención*, cuánto se habla de un tema o de una empresa (Da et al., 2011; Fang y Peress, 2009; Cao et al., 2025); el tono capta el *contenido*, si lo que se dice es bueno o malo (Tetlock, 2007; Ardia et al., 2022).

3.1.2 Eficiencia de mercado

La hipótesis de mercados eficientes (Fama, 1970) sostiene que los precios reflejan toda la información disponible. En su versión semifuerte, la información pública, como una noticia, se incorpora al precio tan rápido que no se puede usar para anticiparlo. Si el mercado argentino fuera eficiente en ese sentido, el tono de las noticias no debería anticipar los retornos de los días siguientes: cualquier efecto quedaría en la misma rueda en que la noticia se conoce. Una consecuencia de la eficiencia es que el precio sigue un paseo aleatorio y el retorno no tiene tendencia, lo que se prueba con tests de raíz unitaria. La evidencia para Argentina y la región es mixta: Zablotsky (2002) discute la eficiencia del mercado de capitales argentino, Worthington y Higgs (2003) rechazan el paseo aleatorio en siete bolsas latinoamericanas y Medina Pérez (2013) revisa la hipótesis en los principales mercados de la región. En otros mercados emergentes la eficiencia también varía según el período (Jain et al., 2020; Malafe-

yev et al., 2017; Kulikova et al., 2024; Rocha Filho y Rocha, 2019).

3.1.3 Sentimiento del inversor y tono de los medios

El sentimiento del inversor es el grado de optimismo o pesimismo que no se explica por los fundamentos. Tetlock (2007) lo midió en el tono de una columna periodística y encontró que un tono muy pesimista anticipa bajas transitorias de los precios, que se revierten: un efecto de sentimiento y no de información. Garcia (2013) mostró que ese efecto se concentra en las recesiones, cuando los inversores están más atentos a las malas noticias. Que el tono sea un *reflejo* del mercado también tiene respaldo: en Tetlock (2007) los retornos bajos anticipan columnas más pesimistas, y Verma et al. (2026) encuentran, para el shock de 2020, que buena parte de la cobertura refleja información que el precio ya había incorporado.

3.1.4 Causalidad de Granger y modelos VAR

Con datos observacionales no se puede probar una causa en sentido estricto, pero sí qué variable se mueve antes. Una variable X *causa en sentido de Granger* a otra Y si el pasado de X mejora la predicción de Y más allá de lo que predice el propio pasado de Y (Granger, 1969). La prueba se hace dentro de un modelo de vector autorregresivo (VAR), que explica cada variable con los rezagos de todas (Sims, 1980; Lütkepohl, 2005). El VAR permite además simular cómo responde cada variable a un «golpe» en otra (funciones de impulso-respuesta). Es el marco natural para la pregunta de esta tesina, porque trata las dos direcciones —noticias $\rightarrow$ mercado y mercado $\rightarrow$ noticias— de forma simétrica.

3.1.5 Estudios de eventos

Un estudio de eventos mide qué hace el precio alrededor de un hecho puntual, comparado con lo que habría sido normal (MacKinlay, 1997; Brown y Warner, 1985). Se define una ventana de estimación, donde se calcula el retorno «normal», y una ventana del evento, donde se mide el retorno *anormal*: lo que el precio se movió de más o de menos. Si una noticia mueve el mercado, el retorno anormal aparece el día del evento o después; si la noticia refleja lo que el mercado ya hizo, aparece antes. En Argentina, Calandroni (2026) aplicó este método a las elecciones nacionales entre 2011 y 2023.

3.1.6 Volatilidad y regímenes de mercado

La volatilidad de los mercados no es constante: se agrupa en períodos de calma y de estrés. Para el S&P Merval esto está documentado con modelos de la familia GARCH (Segovia y Favata, 2022a;b; Larre y Auza, 2019; Xenofontos, 2014), que además muestran que las caídas aumentan la volatilidad más que las subas (Otuki et al., 2008). Una forma de describir esa alternancia es suponer que el mercado pasa por un número finito de *regímenes*, cada uno con su nivel de volatilidad, y que salta de uno a otro según una cadena de Markov (Hamilton, 1989; Rabiner, 1989; Kim, 1994). Para mercados latinoamericanos, Ataurima Arellano

(2016) y Caballero Martínez y Caballero Claure (2016) estiman modelos de cambio de régimen sobre acciones y tipo de cambio, y trabajos recientes los usan para pronosticar volatilidad (Blake et al., 2025; Ataei, 2025) o armar carteras (Majumder et al., 2023). El régimen importa para esta tesina porque la relación entre noticias y precios podría cambiar según el mercado esté calmo o tenso (Garcia, 2013).

	Noticias → mercado	**Mercado → noticias**
Mecanismo	La nota trae información nueva o mueve el ánimo de los inversores	La nota cuenta lo que el mercado ya hizo
Qué se espera ver	El tono anticipa el retorno o el volumen de las ruedas siguientes	El retorno anticipa el tono de las notas siguientes
En un estudio de eventos	El retorno anormal aparece el día del evento o después	El retorno anormal aparece antes del evento
Con notas de la noche	El tono de la noche anticipa el salto de apertura	El tono de la noche refleja el cierre del día
Referencias	Tetlock (2007), Garcia (2013), Galdi y Gonçalves (2018)	Tetlock (2007), Verma et al. (2026)

Tabla 3.1. Las dos direcciones de la relación entre noticias y mercado y cómo se reconoce cada una en los datos. Fuente: elaboración propia.

3.2 El mercado argentino en la ventana de estudio

El S&P Merval es el índice principal de BYMA y reúne a las acciones más negociadas del mercado local. Es un mercado chico y con liquidez dispareja: junto a acciones muy operadas, como YPF o Grupo Financiero Galicia, cotizan empresas que pasan días sin operaciones. Los precios están en pesos, de modo que su tendencia incluye la inflación y la evolución del tipo de cambio.

En Argentina no existe un mercado de opciones con la liquidez necesaria para calcular un índice de volatilidad implícita como el VIX de Chicago. Por eso se construyó un *VIX argentino* con volatilidad realizada: el desvío estándar de los retornos diarios del índice en las últimas 20 ruedas, anualizado (Sakowski et al., 2023). Entre el 2 de enero de 2025 y el 30 de abril de 2026 (323 ruedas) promedió 44,0 %, con un mínimo de 15,4 % el 30/04/2026 y un máximo de 91,0 % el 21/11/2025 (figura 3.1).

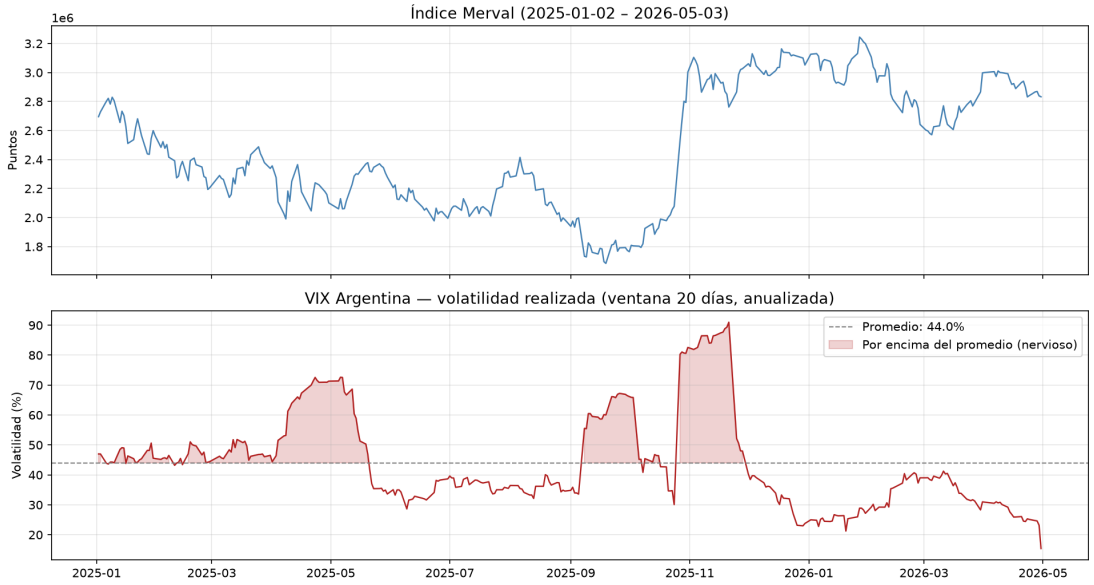


Figura 3.1. S&P Merval en pesos (arriba) y VIX argentino (abajo), del 2/1/2025 al 30/4/2026. El sombreado marca los días por encima del promedio. Fuente: elaboración propia con datos de Yahoo Finance (`Lado Bursatil/03_vix_argentino`).

El período tuvo tres episodios de volatilidad alta, todos disparados por un hecho puntual (tabla 3.2). El primero coincide con la turbulencia global por los aranceles de Estados Unidos y la salida del cepo cambiario; los otros dos arrancan el día hábil siguiente a una elección. El máximo de toda la serie no vino de una caída sino de la suba de 21,8 % del 27/10/2025, después de las legislativas nacionales. A estos hechos se suma el anuncio de apoyo financiero del Tesoro de Estados Unidos del 24/09/2025.

Período	Ruedas	Pico del VIX	Disparador	Contexto
09/04 al 14/05/2025	22	72,6 % (06/05)	09/04: +9,7 %	Aranceles de EE. UU.; incluye la salida del cepo (14/04)
08/09 al 03/10/2025	20	67,2 % (26/09)	08/09: −13,3 %	Día hábil siguiente a las elecciones bonaerenses (07/09)
27/10 al 21/11/2025	20	91,0 % (21/11)	27/10: +21,8 %	Día hábil siguiente a las legislativas nacionales (26/10)

Tabla 3.2. Episodios con el VIX argentino por encima de 55 %. Fuente: elaboración propia (`Lado Bursatil/03_vix_argentino`).

Una advertencia de lectura: como el VIX argentino es un desvío de 20 ruedas, un único día extremo queda dentro del cálculo durante exactamente 20 ruedas. El índice salta el día del shock y cae de golpe 20 ruedas después, aunque ese día el mercado no haga nada especial. Los dos episodios del segundo semestre duran exactamente 20 ruedas: son, casi en su totalidad, el eco de un único día. Este artefacto de las medias móviles con pesos iguales está descrito en la literatura como *ghost features* (Papaioannou et al., 2014); una media exponencial (J.P. Morgan y Reuters, 1996) lo atenuaría.

3.3 Unidades de análisis

Las acciones. El panel tiene 47 acciones de BYMA, en diez sectores (tabla 3.3). Incluye a las 20 que integran el S&P Merval y a 27 más, todas con cotización en el 100 % de las ruedas de tres años y al menos 90 % de días con volumen real (sección 5.1.1). El listado completo, con la liquidez, la volatilidad y la cobertura de noticias de cada una, está en el anexo A.

Sector	Acciones	Tickers
Consumo	9	GRIM, HAVA, LEDE, LONG, MIRG, MOLI, MORI, SAMI, SEMI
Financiero	8	BBAR, BHIP, BMA, BPAT, BYMA, GGAL, SUPV, VALO
Utilities	8	CEPU, CGPA2, DGCU2, EDN, GBAN, METR, PAMP, TRAN
Materiales	6	ALUA, CELU, FIPL, LOMA, RIGO, TXAR
Energía	4	CAPX, TGNO4, TGSU2, YPFD
Conglomerado	3	COME, CRES, GARO
Industrial	3	AGRO, AUSO, OEST
Real Estate	3	CTIO, GCDI, IRSA
Comunicaciones	2	CVH, TECO2
Tecnología	1	BOLT
Total	**47**	

Tabla 3.3. Panel de acciones por sector. Fuente: elaboración propia (`Lado Bursatil/01_scraping_acciones`).

Las empresas con tono propio. No todas las empresas aparecen seguido en las noticias. Para medir el tono propio de una empresa hace falta que tenga noticias en buena parte de las ruedas; con un corte de 90 de las 244 ruedas quedan 17: YPFD, BBAR, SUPV, EDN, GGAL, CEPU, TGSU2, IRSA, BMA, LOMA, PAMP, CRES, BYMA, TRAN, METR, TXAR y ALUA. Cualquier corte entre 75 y 94 ruedas da exactamente las mismas 17. Las otras 30 entran a los modelos con el tono general del mercado.

Los portales. El corpus reúne siete portales nacionales, recolectados en nueve fuentes (tabla 3.4). iProfesional aporta el 39 % de las notas y Clarín el 29 %; TN es el más chico. Cada portal tiene su propio tono promedio, de +30,4 puntos en TN a 0,0 en Ámbito Finanzas, lo que obliga a controlar la composición por portal cuando se arma la serie diaria (sección 5.1.2).

Portal	Método de recolección	Artículos
iProfesional	Mapa del sitio	5.455
Clarín	Mapa del sitio	3.737
Clarín — Economía	Wayback Machine	294
El Economista	Mapa del sitio	2.695
Ámbito Financiero — Economía	Wayback Machine	498
Ámbito Financiero — Finanzas	Wayback Machine	240
Infobae — Economía	Wayback Machine	500
La Nación — Economía	Wayback Machine	491
TN — Economía	Wayback Machine	102
Total		**14.012**

Tabla 3.4. Corpus de noticias por fuente, después de la depuración. Fuente: elaboración propia (`Lado Noticias/noticias`).

Capítulo 4

Técnicas de Ciencia de Datos

La ciencia de datos combina programación, estadística y conocimiento del dominio para extraer conocimiento de datos. Este trabajo siguió las fases del proceso CRISP-DM (Wirth y Hipp, 2000): comprensión del problema (capítulos 2 y 3), comprensión y preparación de los datos, modelado y evaluación (capítulos 5 y 6). Todo se programó en Python; los modelos estadísticos usan la librería `statsmodels` (Seabold y Perktold, 2010) y los de lenguaje, `transformers` y `spaCy`. La figura 4.1 resume el *pipeline* completo, con el resultado de cada paso.

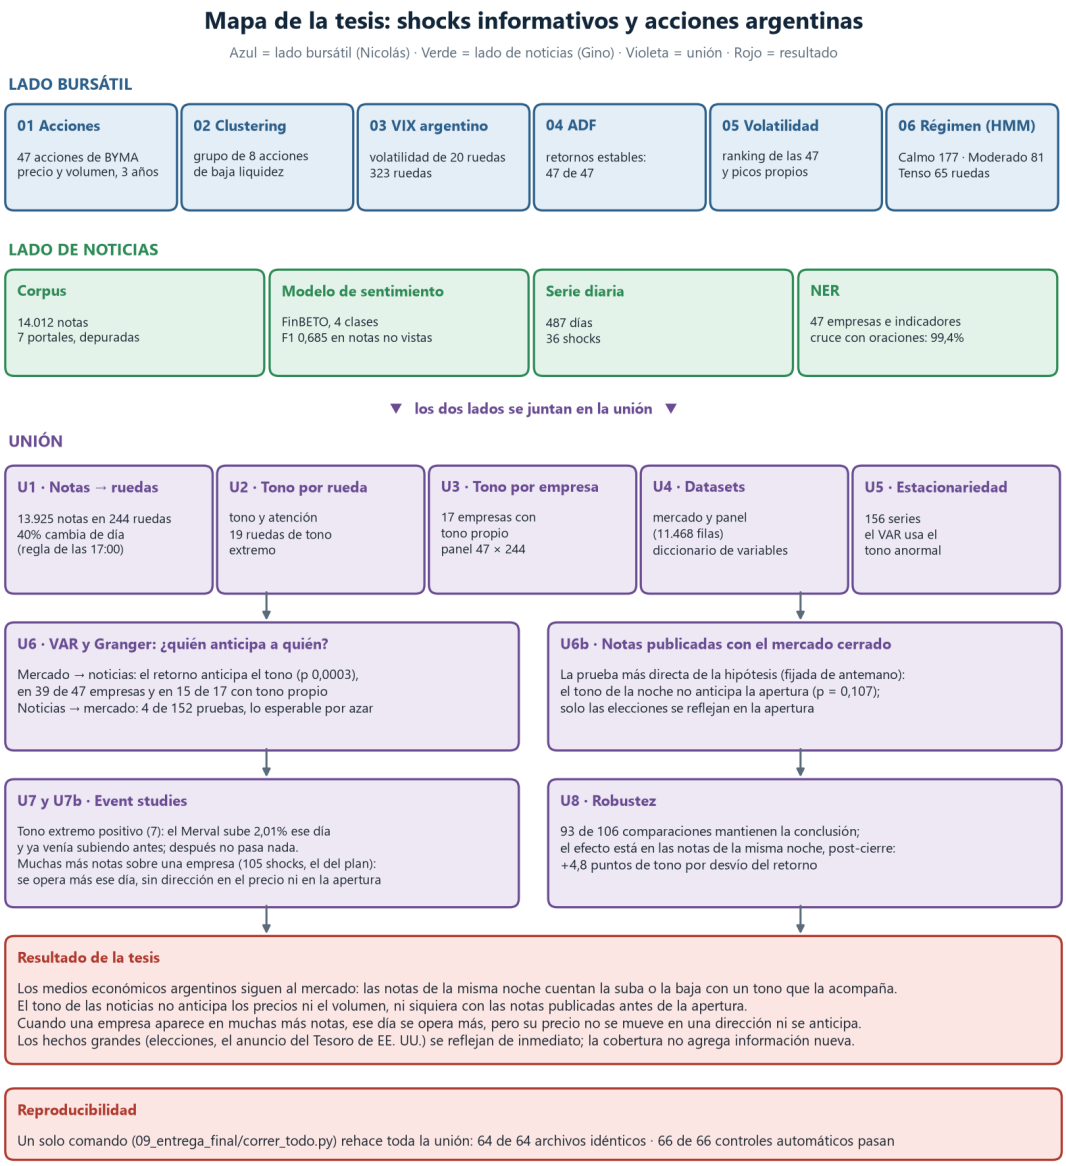


Figura 4.1. Mapa de la tesina: el lado bursátil (azul), el lado de noticias (verde), la unión (violeta) y el resultado (rojo). Fuente: elaboración propia (`Unión/09_entrega_final/mapa_tesis.py`, que lee los resultados de cada carpeta).

4.1 Adquisición de datos

4.1.1 Web scraping de noticias

El *web scraping* es la extracción automática de información de páginas web. Para un corpus histórico de noticias hay dos caminos. El primero es Internet Archive: su *Wayback Machine* guarda capturas de millones de páginas y su API CDX permite listar las capturas de un sitio en un rango de fechas; así se puede reconstruir una ventana más larga que la que exponen los propios portales, a costa de depender de qué capturó un tercero (Garg et al., 2025). El segundo son los *mapas del sitio* (`sitemap.xml`), que los portales publican para los buscadores y que listan sus notas recientes. Una vez obtenida la página, hay que separar el texto de la

nota del «relleno» (menús, publicidad, firmas) y extraer sus metadatos (título, fecha, autor). Se usó una estrategia en capas: los datos estructurados JSON-LD primero, después las metaetiquetas Open Graph, el título `<h1>`, la librería `trafilatura` (Barbaresi, 2021) y, como último recurso, reglas sobre el HTML con BeautifulSoup. Las herramientas de extracción de contenido fallan con frecuencia en el relleno y en los metadatos (Foley, 2026; Hatwar et al., 2024), por lo que un corpus web tiene que auditarse antes de usarse: buscar plantillas, duplicados y contenido que no corresponde (Dodge et al., 2021). Los duplicados, además, distorsionan cualquier modelo que se entrene con ese texto (Lee et al., 2021). Como fuente alternativa para ampliar un corpus de noticias, Fronzetti Colladon y Vestrelli (2026) reconstruyen el texto completo de notas a partir de la base GDELT.

4.1.2 Precios de acciones

Los precios diarios (apertura, máximo, mínimo, cierre y volumen) se descargaron de Yahoo Finance con la librería `yfinance`, para cada acción (`TICKER.BA`) y para el índice (`^MERV`). Yahoo entrega precios ajustados por divisiones y dividendos en acciones, pero tiene tres problemas conocidos que se trataron en la limpieza: agrega filas «fantasma» en los feriados, falla de forma intermitente para algunos tickers y, en algunos casos, aplica mal los ajustes por eventos corporativos.

4.2 Análisis exploratorio de series de tiempo

4.2.1 Estacionariedad: ADF y KPSS

Un VAR necesita series estacionarias, que oscilen alrededor de un nivel estable. Si se usan series con tendencia, dos variables que suben juntas parecen relacionadas aunque no lo estén. La prueba de Dickey-Fuller aumentada (ADF; Dickey y Fuller, 1979) tiene como hipótesis nula que la serie tiene raíz unitaria (no es estacionaria); un p-valor menor a 0,05 permite rechazarla. La prueba KPSS (Kwiatkowski et al., 1992) hace la pregunta al revés: parte de suponer que la serie es estacionaria y busca evidencia en contra. Usadas juntas dan cuatro resultados posibles (tabla 4.1). Los rezagos del ADF se eligen con el criterio de Akaike.

ADF	KPSS	Conclusión
Rechaza la raíz unitaria	No rechaza la estacionariedad	Estacionaria
Rechaza la raíz unitaria	Rechaza la estacionariedad	Estacionaria con memoria (persistente)
No rechaza	No rechaza	Inconclusa: los datos no alcanzan para decidir
No rechaza	Rechaza	No estacionaria

Tabla 4.1. Lectura conjunta de las pruebas ADF y KPSS. Fuente: elaboración propia.

4.2.2 Volatilidad realizada

La volatilidad realizada de un activo en el día t es el desvío estándar de sus retornos diarios en las últimas 20 ruedas, anualizado:

$$\sigma_t = \sqrt{252} \cdot \text{desv}\,(r_{t-19}, \ldots, r_t) \cdot 100, \qquad r_t = \frac{P_t - P_{t-1}}{P_{t-1}}. \tag{4.1}$$

Aplicada al índice da el VIX argentino; aplicada a cada acción, su volatilidad propia. El factor $\sqrt{252}$ es la convención internacional de ruedas por año. BYMA tiene unas 244 ruedas por año por sus feriados; usar ese número bajaría todos los valores un 1,5 %, sin cambiar ninguna comparación. La volatilidad de las acciones individuales tiene además un componente común entre empresas (Kalnina y Tewou, 2024).

4.2.3 Clustering de acciones

El clustering agrupa elementos parecidos sin etiquetas previas. Para series financieras, la distancia habitual entre dos acciones es $1 - \rho$, donde ρ es la correlación de sus retornos (Mantegna, 1999; Marti et al., 2021). Se usaron tres algoritmos: K-Means, que forma k grupos minimizando la distancia de cada elemento al centro de su grupo; el jerárquico, que va uniendo los elementos más cercanos; y el árbol de expansión mínima (MST), que conecta todas las acciones con la menor distancia total y que en los mercados tiende a agrupar por sector (Mantegna, 1999; Onnela et al., 2003). La cantidad de grupos se eligió con el índice de silueta (Rousseeuw, 1987), que compara para cada elemento qué tan cerca está de su propio grupo y qué tan lejos del más cercano. El clustering de acciones se aplicó en mercados emergentes de tamaño comparable (Ghosh, 2025; Ramírez-Carrillo et al., 2025; Alexandre et al., 2021), y se sabe que los grupos cambian entre períodos (Arratia y Cabaña, 2013; Pharasi et al., 2020).

La liquidez es un problema central para estas técnicas. Cuando una acción no opera, Yahoo Finance repite el precio del día anterior con volumen cero. Esos días de precio «quieto» bajan artificialmente la correlación medida con las demás acciones (Nanyonga et al., 2025; Busca y Thomir, 2023) y pueden generar adelantos y retrasos espurios entre acciones (Lo y MacKinlay, 1990; Huth y Abergel, 2011). La frecuencia de días sin movimiento es, de hecho, una medida clásica de iliquidez (Lesmond et al., 1999).

4.2.4 Regímenes de mercado

Un modelo de cambio de régimen de Markov supone que la serie (aquí, el VIX argentino) tiene una media y una varianza distintas en cada uno de k estados ocultos, y que el mercado pasa de un estado a otro según una matriz de probabilidades de transición (Hamilton, 1989; Kim, 1994). En la literatura de mercados se lo suele llamar HMM (Rabiner, 1989). Se estimó con `MarkovRegression` de `statsmodels` para $k = 2$ a 6 y se eligió k por el criterio bayesiano de información (BIC; Schwarz, 1978), descartando los ajustes que no convergen o que crean un régimen de menos de cinco días (estados degenerados, una falla conocida de los modelos de mezcla). A cada día se le asigna el régimen de mayor probabilidad *suavizada*, que usa toda

la serie; se guarda también la versión *filtrada*, que solo usa la información disponible hasta ese día y es la adecuada si el régimen se usa para pronosticar (Majumder et al., 2023).

4.3 Modelos de lenguaje

4.3.1 FinBETO: BETO adaptado al dominio

BERT (Devlin et al., 2019) es un modelo de lenguaje preentrenado con la tarea de adivinar palabras ocultas en un texto (*masked language modeling*, MLM). BETO es su versión entrenada en español (Cañete et al., 2020). Para clasificar sentimiento se le agrega una capa de salida y se lo ajusta con oraciones etiquetadas (*fine-tuning*), como hizo FinBERT en inglés (Araci, 2019). Antes del ajuste, conviene seguir el preentrenamiento con texto del propio dominio, porque mejora el desempeño en la tarea final (Gururangan et al., 2020). FinBETO es el resultado de los dos pasos sobre la prensa económica argentina.

Para el ajuste fino hacen falta oraciones etiquetadas, y no existía un conjunto público de prensa económica argentina. Se usó un modelo de lenguaje como etiquetador, una práctica que puede igualar o superar a anotadores contratados (Gilardi et al., 2023) y que también se evaluó en textos financieros (Aguda et al., 2024). El etiquetador fue Gemma (Gemma Team, 2026), ejecutado localmente. La condición para que esa práctica sea válida es contrastar el modelo con anotadores humanos en una muestra; Calderon et al. (2025) proponen una prueba estadística para hacerlo con pocas oraciones.

La evaluación tiene una trampa conocida: la *fuga de información* (*leakage*), cuando datos de prueba también están, total o parcialmente, en el entrenamiento, lo que infla los resultados (Kapoor y Narayanan, 2023). Con noticias, la forma de dividir los datos cambia mucho el resultado (Xue et al., 2026). La métrica principal es el F1 macro: el promedio simple del F1 de cada clase, que no premia acertar solo la clase más frecuente. El modelo de referencia fue `finiteautomata/beto-sentiment-analysis`, de la librería pysentimiento (Pérez et al., 2021), un BETO ajustado con tuits.

4.3.2 Reconocimiento de entidades nombradas

El reconocimiento de entidades nombradas (NER) identifica en un texto los nombres de personas, organizaciones, lugares y otras entidades. Los cuatro tipos que usan los modelos en español (PER, ORG, LOC y MISC) vienen de la tarea compartida CoNLL-2002 (Tjong Kim Sang, 2002). Se usó el modelo `es_core_news_lg` de spaCy (Honnibal et al., 2020), combinado con un *gazetteer*: un diccionario curado de nombres que se buscan literalmente en el texto y se unen a un identificador único, como se hace en otros dominios (Ujiie et al., 2021). Las alternativas con modelos de lenguaje como etiquetadores (Golde et al., 2025) y la detección de las entidades centrales de una nota (Asgarieh et al., 2024) quedan como mejoras posibles.

4.4 Modelos de series de tiempo y pruebas

4.4.1 VAR, causalidad de Granger e impulso-respuesta

Un VAR con p rezagos explica el vector de variables de hoy, y_t, con sus valores de las p ruedas anteriores:

$$y_t = c + A_1\, y_{t-1} + A_2\, y_{t-2} + \cdots + A_p\, y_{t-p} + \varepsilon_t. \tag{4.2}$$

En el VAR del mercado, por ejemplo, y_t contiene el tono anormal de las noticias, la atención anormal, el retorno del S&P Merval y el monto operado anormal. Los rezagos se eligen entre 1 y 5 con el criterio de Akaike (Lütkepohl, 2005). La prueba de Granger de «tono $\rightarrow$ retorno» es una prueba F de que todos los coeficientes del tono rezagado en la ecuación del retorno valen cero (Granger, 1969): si se rechaza, el pasado del tono ayuda a anticipar el retorno. La función de impulso-respuesta muestra cómo responde cada variable, rueda a rueda, a un golpe de un desvío en otra; su banda del 95 % indica si la respuesta es distinta de cero. Para ordenar el golpe dentro de una misma rueda, las noticias van primero, porque el precio de una rueda no puede cambiar una nota ya publicada.

4.4.2 Estudio de eventos

En el estudio de eventos, la rueda del evento es la 0. El retorno normal se estima en la ventana $[-25, -4]$, que termina antes del evento para que no contamine su propia comparación, y el retorno anormal se mide en $[-3, +5]$ (MacKinlay, 1997). Para una acción se usa el modelo de mercado:

$$RA_{i,t} = r_{i,t} - \left(\hat{\alpha}_i + \hat{\beta}_i\, r_{M,t}\right), \qquad CAR_i[t_1, t_2] = \sum_{t=t_1}^{t_2} RA_{i,t}, \tag{4.3}$$

donde $r_{M,t}$ es el retorno del S&P Merval. Para el propio índice, que no tiene contra qué compararse, se usa el modelo de media constante: el retorno menos su promedio en la ventana de estimación (Brown y Warner, 1985). Con pocos eventos, además del test t y del test de signo, se compara contra fechas al azar: se sortean 5.000 veces tantas fechas como eventos y se cuenta qué proporción de los sorteos da un promedio al menos tan extremo como el observado.

4.4.3 Pruebas múltiples

Cuando se hacen muchas pruebas, algunas salen significativas por azar: con 100 pruebas al 5 %, se esperan unas 5 aunque no haya ningún efecto real. En finanzas este problema es especialmente grave (Harvey et al., 2016; Harvey y Liu, 2020), y probar muchas variantes hasta que una «funcione» genera resultados falsos (Nikolopoulos, 2026). Se usaron dos defensas. La primera es la corrección de Benjamini-Hochberg (Benjamini y Hochberg, 1995), que ajusta los p-valores de cada familia de pruebas para controlar la proporción esperada de falsos descubrimientos. La segunda es escribir la especificación antes de ver los resultados en las pruebas más importantes, y cambiar una sola decisión por vez en las de robustez.

4.4.4 Encogimiento hacia el promedio

El tono de una empresa en una rueda con una sola oración es muy ruidoso: vale $+100$, -100 o 0. Para no confiar lo mismo en una oración que en treinta, el tono propio de cada empresa se *encoge* hacia el tono del mercado con un peso que crece con la cantidad de oraciones, según el principio del estimador de Stein y de Bayes empírico (Efron y Morris, 1975):

$$\text{tono propio}_{i,t} = \frac{n_{i,t}}{n_{i,t} + K}\left(\text{tono}_{i,t} - \text{tono}_{M,t}\right), \tag{4.4}$$

donde $n_{i,t}$ es la cantidad de oraciones que mencionan a la empresa i en la rueda t y K es la varianza de una oración suelta dividida por la varianza real del tono entre días, estimada de los datos ($K = 10{,}9$). Con una oración se confía un 8 % en el tono de la empresa; con diez, un 48 %; con treinta, un 73 %.

Capítulo 5

Desarrollo Experimental

Este capítulo describe qué datos se usaron, cómo se limpiaron y unieron, qué mostró el análisis exploratorio y cómo se especificó cada modelo. Los resultados de los modelos que responden la pregunta de la tesina se presentan en el capítulo 6.

5.1 Materiales y métodos

Fuentes de datos. La tabla 5.1 resume las fuentes y sus ventanas. El lado bursátil trabaja con dos ventanas: tres años para seleccionar las acciones y estudiar su liquidez, y la ventana del corpus de noticias para la volatilidad y el régimen. La unión usa el tramo en el que ambos lados tienen datos: aunque el corpus abarca desde enero de 2025, el 99,9 % de sus notas es posterior al 1 de mayo de 2025, de modo que la ventana común empieza en la rueda del 5 de mayo de 2025.

Fuente	Qué aporta	Ventana
Yahoo Finance, `TICKER.BA`	Precio de apertura, máximo, mínimo, cierre y volumen de 53 candidatas (47 seleccionadas)	03/05/2023 al 30/04/2026 (731 ruedas)
Yahoo Finance, `^MERV`	Cierre del S&P Merval y calendario de ruedas de BYMA	02/01/2025 al 30/04/2026 (323 ruedas)
Internet Archive (API CDX)	Capturas históricas de las secciones de economía de Ámbito, Clarín, Infobae, La Nación y TN	Enero de 2025 a mayo de 2026
Mapas del sitio	Notas de Clarín, El Economista e iProfesional	Enero de 2025 a mayo de 2026
Unión de ambos lados	Notas asignadas a ruedas, tono, atención y variables de mercado	05/05/2025 al 30/04/2026 (244 ruedas)

Tabla 5.1. Fuentes de datos y ventanas temporales. Fuente: elaboración propia.

Entorno. Python 3 con `pandas`, `numpy`, `scipy`, `statsmodels` 0.14.6 y `matplotlib` para el lado bursátil y la unión; `yfinance` para la descarga de precios. El lado de noticias tiene su propio entorno (Python 3.13) con `requests`, `beautifulsoup4`, `trafilatura`, `spacy` 3.8 con el modelo `es_core_news_lg`, `transformers` y `torch` con aceleración por GPU. El etiquetado de oraciones y la verificación de duplicados semánticos se hicieron con modelos de lenguaje abiertos (Gemma y Qwen3) servidos localmente con Ollama.

Organización y reproducibilidad. Cada paso es una carpeta con un único script, sus resultados en CSV, un archivo de controles automáticos (`verificaciones.csv`) y su documentación en PDF. Ningún paso modifica los archivos de otro: cada uno lee lo que necesita y escribe en su propia carpeta. La unión completa se rehace con un solo comando (`python correr_todo.py`, en `Unión/09_entrega_final`), que corre los pasos en orden, verifica los controles y compara la huella de cada archivo de resultados con la corrida anterior: los 64 archivos salen idénticos y los 66 controles pasan. El anexo F detalla la estructura de carpetas.

Datos de terceros. Las notas periodísticas pertenecen a sus medios y se usaron únicamente con fines académicos: el análisis trabaja con medidas agregadas (tono, cantidad, menciones) y no reproduce las notas. Los precios provienen de Yahoo Finance, también con fines académicos. El acceso autenticado a la API de Internet Archive usa credenciales guardadas en un archivo de configuración externo, fuera del código.

5.1.1 Recolección de los datos

Corpus de noticias

El corpus se recolectó de las secciones de economía y finanzas de siete portales, con dos métodos según la disponibilidad de cada fuente (sección 4.1): la Wayback Machine para Ámbito Financiero (Economía y Finanzas), Clarín (Economía), Infobae, La Nación y TN, y los mapas del sitio para Clarín, El Economista e iProfesional. Clarín se cubrió con ambos métodos: la ventana más profunda por Wayback Machine y las notas más recientes por el mapa del sitio. Cada nota se guardó con su sitio, fecha y hora de publicación, título, bajada, contenido y etiquetas. El corpus final tiene 14.012 artículos, unos 63 millones de caracteres (alrededor de 4.500 por artículo), publicados entre enero de 2025 y mayo de 2026 (tabla 3.4). En la práctica empieza en mayo de 2025: 14.001 de los 14.012 son del 1 de mayo de 2025 en adelante, probablemente porque tanto la retención de los mapas del sitio como las capturas de la Wayback Machine se concentran en los meses más recientes.

Panel de acciones

Se partió de 53 candidatas del Panel General y del Panel Líderes de BYMA: las 20 del S&P Merval más 33 de sectores similares. Para cada una se descargó la serie diaria de tres años y se midieron dos cosas: cuántas ruedas tiene y qué porcentaje de ellas tuvo volumen mayor que cero. El criterio de selección exige las dos condiciones a la vez:

- **Cobertura completa del calendario:** las 731 ruedas de la ventana, sin excepciones.
- **Al menos 90 % de días con volumen real.** Un día con volumen cero no es un dato faltante: Yahoo entrega la fila, con el precio pegado al último que operó. Por eso el criterio no puede mirar solo el calendario.

Pasaron 47 de las 53, incluidas las 20 del S&P Merval. Las seis que quedaron afuera son Carboclor (462 ruedas y 39 % de días con volumen), Holcim Argentina (67,2 %), Polledo (50,2 %), Instituto Rosenbusch (87,3 %) y dos tickers sin datos en Yahoo: NII Holdings y TGLT, que es

la misma empresa que hoy cotiza como GCDI, incluida en el panel. Los nombres y sectores se verificaron contra la ficha de cada ticker; los *holdings* diversificados (Cresud, Sociedad Comercial del Plata, Garovaglio y Zorraquín) se clasificaron como Conglomerado.

5.1.2 Limpieza y preparación de los datos

Depuración del corpus

La auditoría del corpus encontró cinco problemas, cada uno con su solución (tabla 5.2).

Problema	Qué se encontró	Solución
Duplicados exactos	205 notas de Clarín descargadas dos veces, por Wayback Machine y por el mapa del sitio	Una copia por URL (la del sitio); los recolectores verifican la URL contra todo el corpus
Publicación cruzada	208 grupos de título repetido; 175 se descartaron por estar a más de 48 horas (columnas recurrentes)	Los 33 grupos restantes (68 notas) se verificaron con Qwen3: 14 republicaciones reales
Metadatos faltantes	Sin autor ni palabras clave en iProfesional y sin fecha en 194 notas de El Economista, por un error de parseo del JSON-LD	Parseo tolerante; 192 notas reales se volvieron a descargar y recuperaron su fecha
Contenido que no es noticia	2 páginas índice, 9 páginas de suscripción y 6 notas fuera de la ventana (fechadas por su última modificación)	Se eliminaron; los recolectores filtran por fecha de publicación efectiva
Plantillas	65 grupos (479 notas) con el mismo comienzo; cuatro plantillas de El Economista concentran 325 notas con sentimiento constante	Se eliminaron 419 notas (2,9 %): el corpus pasó de 14.431 a 14.012

Tabla 5.2. Problemas del corpus y cómo se resolvieron. Fuente: elaboración propia a partir de la auditoría del lado de noticias (`Lado Noticias/noticias`).

Las plantillas merecen un comentario. Notas como el reporte diario «Dólar hoy» tienen fecha y cotizaciones propias, pero el modelo de sentimiento les asignaba siempre el mismo valor, con desvío cero entre decenas de notas: el valor dependía de la parte fija del texto y no de la información del día. Replicado durante meses, ese valor sesgaba el promedio diario. En los grupos de menos de 11 notas se conservó la más antigua (83 eliminadas); en los de 11 o más, cuyo cuerpo es relleno, se eliminaron todas (336). Una sola nota de 2014 mal fechada, además, estiraba la serie diaria a 4.186 días; tras la depuración la serie abarca 487 días.

Depuración de los precios

- **Calendario real de BYMA.** Yahoo agrega a cada acción una fila en los feriados (precio pegado, volumen cero) que el índice no tiene. Se descargó primero el `^MERV` y se usó su lista de fechas como calendario para todas las acciones.

- **Fallas intermitentes.** Algunos tickers daban «sin datos» en una corrida y datos completos en la siguiente; el script reintenta hasta tres veces antes de descartarlos.
- **Eventos corporativos mal ajustados.** Buscando retornos diarios mayores a ± 50 % aparecieron dos errores de Yahoo: el 16/12/2024 de SEMI quedó sin dividir por el *split* de 4,227 (se corrigió ese día), y el dividendo en acciones de AGRO de noviembre de 2023 no se aplicó a los precios anteriores, lo que mostraba una caída falsa de 88 % (los precios hasta el 02/11/2023 se dividieron por 2,1). Los saltos grandes de GCDI, CELU y RIGO se verificaron como reales: el precio se sostiene o viene con volumen muy por encima de lo normal.

Cada nota a su rueda

Las noticias se publican a cualquier hora, pero el precio se forma solo en las ruedas, de lunes a viernes de 11:00 a 17:00. Para medir si una nota mueve el precio hay que compararla con el primer precio que pudo verse afectado por ella. Una nota del martes a las 20:00 sale con el mercado cerrado: la primera vez que alguien puede operar con esa información es el miércoles. Se aplicó la siguiente regla:

- Todas las horas se pasaron a hora argentina: Clarín, Infobae y La Nación informan la hora en UTC, y 95 notas nocturnas cambian de fecha con la conversión.
- Una nota publicada antes de las 17:00 de un día con rueda cuenta para esa rueda.
- Una nota publicada a las 17:00 o después cuenta para la rueda siguiente.
- Una nota publicada en un día sin rueda (fin de semana o feriado) cuenta para la primera rueda posterior.

El 59,8 % de las notas quedó en su mismo día, el 24,8 % pasó a la rueda siguiente por salir después del cierre y el 15,4 % por salir en un día sin rueda (tabla 5.3). Dentro de la ventana quedaron 13.925 notas; las 10 de enero a marzo de 2025 y las 77 del cierre del 30/04/2026 en adelante quedan afuera. Las 244 ruedas reciben noticias: mínimo 12, mediana 55 y máximo 145 (figura 5.1).

Dónde quedó cada nota	Notas	%
En su mismo día (antes de las 17:00 de un día con rueda)	8.332	59,8
En la rueda siguiente, por salir después del cierre	3.451	24,8
En la rueda siguiente, por salir en un día sin rueda	2.142	15,4
Total dentro de la ventana	13.925	100,0

Tabla 5.3. Asignación de las notas a las ruedas con la regla de las 17:00. Fuente: elaboración propia (`Unión/01_alineacion_noticias_ruedas`).

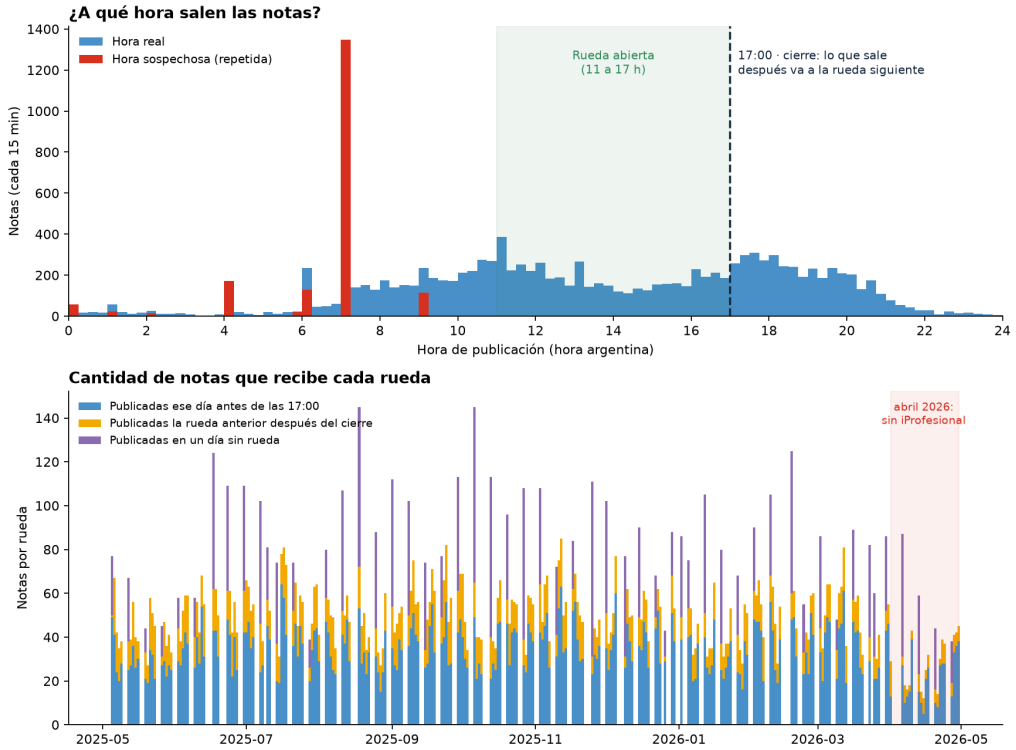


Figura 5.1. Arriba: hora de publicación de las notas, con la rueda sombreada y el cierre de las 17:00; en rojo, horas repetidas que no pueden ser reales. Abajo: notas que recibe cada rueda, según de dónde vienen. Fuente: elaboración propia (`Unión/01_alineacion_noticias_ruedas`).

Horas sospechosas. El 13,4 % de las notas (1.881) tiene una hora que se repite demasiado dentro de su portal —más del 3 % de sus notas a un mismo minuto—, como las 07:00 de Clarín o las 00:00 de Ámbito. No es la hora real sino una hora por defecto del sitio. Esas notas se marcaron y, en la prueba de robustez, los resultados se repitieron sin ellas (sección 6.5). El anexo C lista las horas detectadas.

Tono, atención y ruedas de tono extremo

Con cada nota asignada a su rueda se armaron tres series por rueda:

- **Tono:** el promedio del sentimiento neto de las notas de la rueda, con igual peso por nota. El sentimiento neto de una nota es el porcentaje de sus oraciones positivas menos el de negativas (sección 5.1.5). Como cada portal tiene su propio tono promedio, se armó también una versión *ajustada por portal*, restando a cada nota el promedio de su portal; las dos versiones tienen correlación 0,995.
- **Atención:** la cantidad de notas de la rueda comparada con lo habitual. Una rueda que viene de un fin de semana junta más notas (mediana de 50 notas en ruedas que cubren un día, 83 en las que cubren tres y 111 en las que cubren cuatro). Por eso la cantidad se compara primero con la mediana de las ruedas que cubren los mismos días y después con el nivel de las 20 ruedas previas. En la *atención anormal* resultante, 0 es lo habitual, $+0{,}69$ el doble de notas y $-0{,}69$ la mitad.
- **Ruedas de tono extremo:** las ruedas cuyo tono se aparta mucho de lo habitual.

Para elegir la regla de las ruedas de tono extremo se compararon dos familias (tabla 5.4). La primera mide lo habitual con el desvío de los días previos, como la serie diaria del lado de noticias; la segunda, *por muestreo*, pregunta cuánto podría moverse el promedio del día solo por azar, según cuántas notas tiene: con 100 notas, una diferencia de 9 puntos es creíble; con 16, puede ser casualidad, como el margen de error de una encuesta. Para saber si una regla detecta algo se mezclaron las notas al azar entre las ruedas, conservando cuántas tiene cada una, y se contó cuántos shocks marcaba cada regla. El criterio, fijado antes de mirar el resultado, fue usar 20 ruedas de referencia y el umbral que más shocks detecta con a lo sumo 20 % de falsos esperados.

Regla	Umbral	Noticias reales	Notas mezcladas al azar
Desvío de los días previos	1,5	50	35,4
Desvío de los días previos	2,0	15	16,1
Desvío de los días previos	2,5	4	7,1
Por muestreo	2,0	35	11,6
Por muestreo (elegida)	**2,5**	**19**	**3,5**
Por muestreo	3,0	8	0,8
Regla de la serie diaria (7 días, incluye el día)	1,5	33	25,8

Tabla 5.4. Shocks de tono que marca cada regla con las noticias reales y con las notas mezcladas al azar (promedio de 300 mezclas). Fuente: elaboración propia (`Unión/02_sentimiento_por_rueda`).

La regla por desvío de los días previos marca casi lo mismo que el azar. La regla por muestreo con umbral 2,5 marca 19 ruedas de tono extremo (10 positivas y 9 negativas), contra 3,5 esperables por azar. Hay un matiz: las notas de un mismo día no son independientes, porque todos los medios hablan de los mismos temas, y por eso los días varían más de lo que predice su cantidad de notas. Teniéndolo en cuenta, se esperarían unas 19 ruedas así. Por eso las 19 se interpretan como *las ruedas de tono más extremo del período* (el 8 % más alejado de lo habitual) y no como días estadísticamente excepcionales. El análisis principal (VAR y Granger) no depende de esta regla: usa la serie completa de tono.

La regla de la serie diaria original incluye al propio día en la ventana de siete días con que se calcula lo habitual. Eso acota el desvío máximo alcanzable a $(7-1)/\sqrt{7} \approx 2{,}27$ (Shiffler, 1988), y es uno de los motivos por los que la unión redefinió la banda sin el día evaluado.

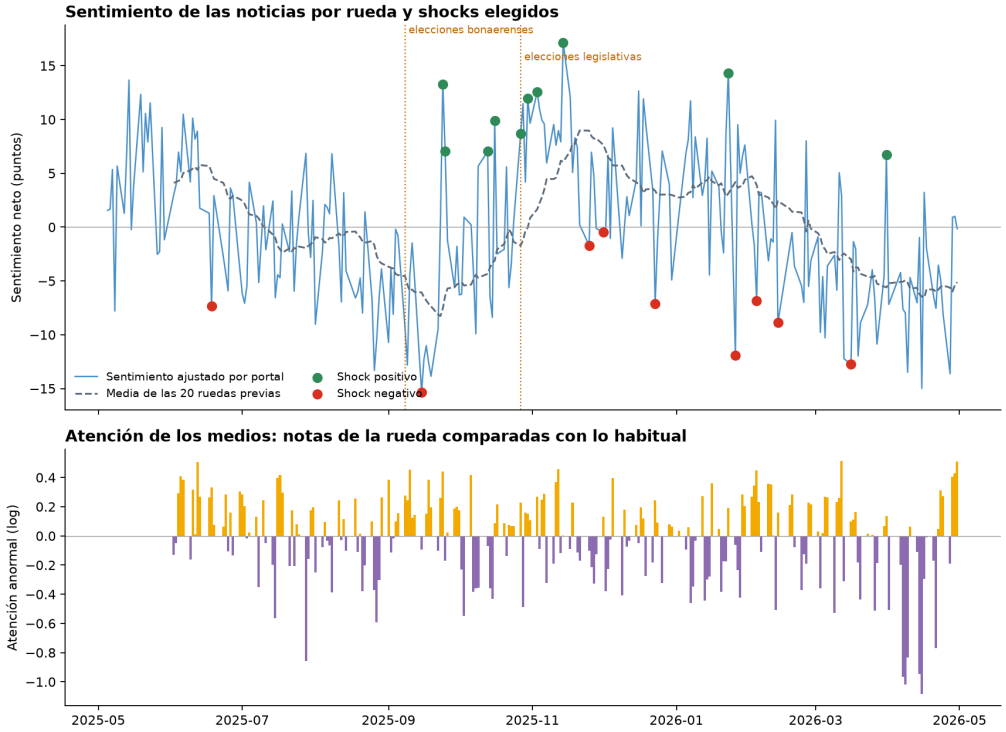


Figura 5.2. Arriba: tono de cada rueda (ajustado por portal), su media de las 20 ruedas previas y las ruedas de tono extremo. Abajo: atención anormal de los medios. Fuente: elaboración propia (`Unión/02_sentimiento_por_rueda`).

Tono de cada empresa

El tono de una empresa en una rueda se calculó con el cruce entre las menciones del NER y el sentimiento de cada oración (sección 5.1.5): (oraciones positivas − oraciones negativas) / oraciones que mencionan a la empresa × 100. Cada oración cuenta para la rueda de su nota, y una oración que menciona dos veces a la misma empresa cuenta una sola vez. Se unieron 240.811 de 242.312 oraciones con entidades (99,38 %). Si una empresa no aparece en una rueda, su tono queda vacío y la marca `hubo_noticia` vale 0: completar con 0 la haría parecer neutra. Agrupando por fecha en lugar de por rueda, el cálculo reproduce fila por fila la serie diaria por empresa del lado de noticias.

Un aviso para los modelos: en las 17 empresas con tono propio, una rueda con noticias tiene una mediana de dos oraciones que la mencionan, y en el 37 % de esas ruedas hay una sola. Ese día el tono sale todo o nada ($+100$, -100 o 0). Por eso el modelo usa el *tono propio* encogido hacia el mercado (ecuación de la sección 4.4), que vale 0 cuando no hay noticias y confía más en las ruedas con más oraciones.

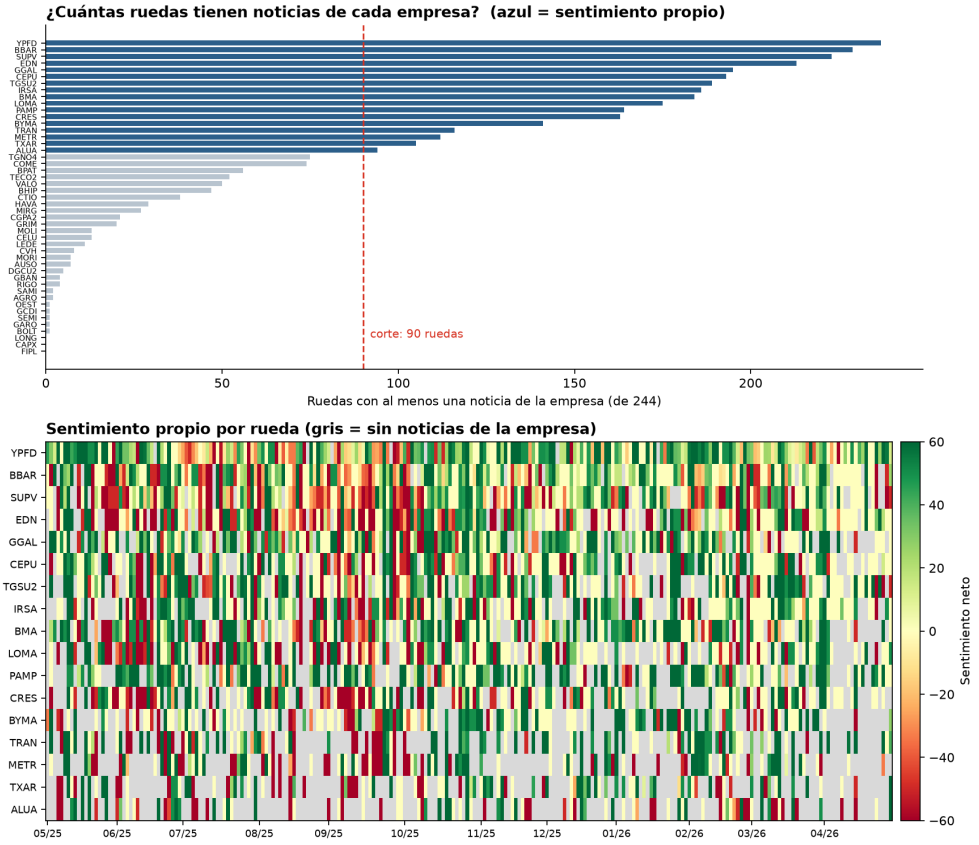


Figura 5.3. Arriba: ruedas con al menos una noticia de cada empresa (en azul, las 17 con tono propio). Abajo: tono propio de esas 17 empresas en cada rueda. Fuente: elaboración propia (`Unión/03_sentimiento_por_empresa`).

Datasets unificados

Todo lo que usan los modelos quedó en dos tablas, para que ningún modelo arme su propio cruce: `dataset_mercado.csv`, con una fila por rueda (244 filas), y `dataset_panel.csv`, con una fila por acción y rueda (11.468 filas). El diccionario de variables está en el anexo B. Tres decisiones definen sus variables:

- **Volumen anormal.** El volumen en bruto no sirve para comparar: cada acción tiene su propio nivel y los montos en pesos crecen con la inflación. Se usa $\log(1 + \text{volumen}_t)$ menos el promedio de esa cantidad en las 20 ruedas previas de la misma acción; para el mercado, lo mismo con el monto operado total de las 47.
- **Tono anormal.** El tono de la rueda menos el promedio de las 20 ruedas previas. Es la variable de tono del VAR (sección 5.1.4).
- **Marcas de días especiales.** Se marcaron las dos ruedas electorales (08/09 y 27/10/2025), las 40 ruedas de su eco en el VIX y el régimen, y las 20 ruedas de abril de 2026, cuando el corpus casi no tiene notas de iProfesional por un hueco de recolección. Las marcas no cambian ningún dato: sirven para analizar esos días aparte.

5.1.3 Análisis univariado

Retorno del mercado. En las 244 ruedas de la unión, el retorno diario del S&P Merval promedió 0,16 %, con un desvío de 2,79 %. Los extremos son los dos días electorales: $-13{,}25$ % el 08/09/2025 y $+21{,}77$ % el 27/10/2025. El VIX argentino promedió 41,9 % en esa ventana (tabla 5.5).

Volatilidad por acción. La volatilidad promedio de las 47 acciones fue de 55,1 %, contra 44,0 % del VIX en los mismos 323 días: cada acción sola es más nerviosa que el índice, que diversifica. La más calma fue Mirgor (36,2 %) y la más volátil, Celulosa Argentina (104,6 %) (figura 5.4). Por sector, Real Estate fue el más calmo (42,5 %) y Utilities el más volátil (60,5 %).

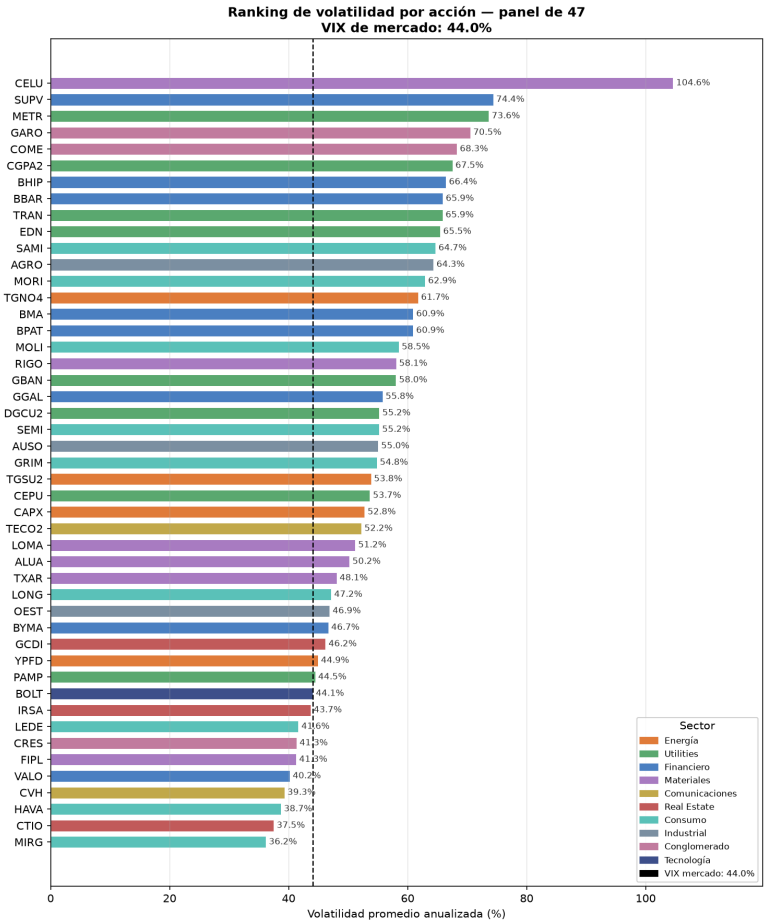


Figura 5.4. Volatilidad promedio de las 47 acciones, coloreada por sector, con el VIX argentino como referencia (2/1/2025 al 30/4/2026). Fuente: elaboración propia (`Lado Bursatil/05_volatilidad_ranking`).

Se marcaron como *picos propios* los tramos de tres días o más en que la volatilidad de una acción supera al VIX por más de 60 puntos mientras el VIX está por debajo de 50 %: la acción muy alterada en un mercado tranquilo. De 19 tramos, 12 empiezan justo cuando el VIX cae de golpe por el eco de 20 ruedas, y no se cuentan. Quedan 7 tramos genuinos en cuatro acciones (CELU, SAMI, GARO y RIGO), candidatos a eventos propios de cada empresa.

Tono de las noticias. El tono medio de las 244 ruedas fue de 3,9 puntos, con un desvío de

7,0: las noticias económicas son, en promedio, levemente positivas. La rueda más negativa fue la del 15/04/2026 ($-13{,}5$) y la más positiva, la del 14/11/2025 ($+22{,}1$). El tono de una rueda se parece al de la anterior (autocorrelación 0,47): el clima de las noticias cambia de a poco. A nivel de oración, de las 399.803 oraciones clasificadas, el 36,7 % es neutra, el 27,1 % positiva, el 24,1 % negativa y el 12,1 % mixta.

Cantidad de notas. Las ruedas reciben entre 12 y 145 notas, con mediana de 55. Los lunes reciben el fin de semana: mediana de 85 notas, contra 50 el resto de los días. La rueda con más notas es la del 18/08/2025 (145), que junta cuatro días porque el viernes anterior fue feriado. Abril de 2026 recibe menos notas por el hueco de recolección de iProfesional.

Menciones de empresas. YPF es la empresa más mencionada: aparece en 237 de las 244 ruedas. Le siguen BBVA (229), Supervielle (223), Edenor (213) y Galicia (195). Tres empresas del panel no tienen ninguna mención (CAPX, FIPL y LONG) y otras 16 tienen menos de 10 ruedas con noticias. El tono acumulado de las oraciones que mencionan a cada empresa va de $-0{,}5$ (Aluar) a $+40{,}8$ (Pampa Energía).

Variable	Filas	Media	Desvío	Mínimo	Máximo
Retorno del S&P Merval (%)	244	0,16	2,79	−13,25	21,77
VIX argentino (%)	244	41,87	17,04	15,40	90,99
Monto operado anormal (log)	244	0,00	0,46	−2,21	1,44
Tono de las noticias	244	3,91	7,00	−13,54	22,10
Tono ajustado por portal	244	−0,07	6,87	−15,34	17,15
Tono anormal	224	−0,51	6,01	−16,94	20,97
Notas por rueda	244	57,07	22,87	12,00	145,00
Atención anormal (log)	224	−0,01	0,30	−1,08	0,51
Retorno de cada acción (%)	11.468	0,12	3,86	−39,57	53,96
Volumen anormal de cada acción (log)	11.468	−0,02	0,77	−12,68	4,79
Tono de la empresa (si hubo noticia)	3.489	12,57	62,39	−100,00	100,00
Oraciones que mencionan a la empresa	11.468	0,96	3,13	0,00	185,00
Tono propio (17 empresas)	4.148	1,67	9,17	−40,67	49,05

Tabla 5.5. Estadísticos descriptivos de las variables principales en la ventana de la unión (05/05/2025 al 30/04/2026). El tono anormal y la atención tienen 224 filas porque las primeras 20 ruedas no tienen 20 ruedas previas de referencia. Fuente: elaboración propia (`Unión/04_dataset_unificado`).

5.1.4 Análisis multivariado

¿Hay familias de acciones?

Si existieran grupos de acciones que reaccionan de forma parecida, el impacto de las noticias podría analizarse por familia, con más señal y menos ruido. Se probaron tres representaciones de comportamiento (retornos normalizados, log-volumen normalizado y 13 características como volatilidad, asimetría, beta y correlación volumen-retorno), tres algoritmos

(K-Means, jerárquico y MST) y dos ventanas (tres años y la del corpus): 18 combinaciones. La mejor silueta (0,567, MST) es un caso degenerado: aísla a AGRO sola contra las otras 46. La mayoría de las mejores combinaciones tiene esa firma —uno o dos casos aislados contra el resto—, salvo una: K-Means con las 13 características a tres años separa un grupo de 8 acciones (silueta 0,406), y el jerárquico encuentra prácticamente el mismo.

Lo que más distingue a ese grupo no es la volatilidad sino la liquidez: las características que más lo separan del resto son una baja correlación con el promedio del panel y un volumen irregular. Para comprobarlo se repitió el ejercicio en tres versiones (tabla 5.6). Tratar los días sin operación como faltantes casi no cambia el grupo; sacar las cuatro acciones con más días sin operar (GCDI, RIGO, GRIM y GARO) lo deshace.

Prueba	Acciones	Silueta	Coincidencia con el grupo
A) Como está	47	0,406	8 de 8
B) Días sin operación como faltantes	47	0,400	7 de 8
C) Sin GCDI, RIGO, GRIM y GARO	43	0,219	4 de 8

Tabla 5.6. Robustez del grupo de 8 acciones del clustering. Fuente: elaboración propia (`Lado Bursatil/02_clustering_acciones`).

La conclusión es que no hay familias de comportamiento bien definidas: el único grupo de tamaño real existe, sobre todo, porque existen acciones poco líquidas, cuyo precio congelado las hace «no acompañar» al resto (Nanyonga et al., 2025; Huth y Abergel, 2011). Por eso el análisis con noticias se hizo acción por acción y por sector, y los resultados de esas cuatro acciones se leen con cautela, porque un precio atrasado puede parecer una reacción con retraso (Lo y MacKinlay, 1990). Dentro de la ventana de la unión, de todos modos, esas cuatro acciones casi no tienen días sin operar (3 entre las cuatro).

Regímenes de mercado

El modelo de cambio de régimen sobre el VIX argentino eligió tres regímenes: con $k = 3$ el BIC es el menor entre los ajustes que convergen sin estados degenerados (2.119,4), y el resultado es idéntico con diez semillas distintas. Con $k = 4$ aparecen los mismos tres regímenes más un «régimen» de un solo día; con $k = 5$ el ajuste se rompe. La tabla 5.7 describe los tres regímenes.

Régimen	VIX promedio	Retorno diario promedio	Días	% del período
Calmo	33,0 %	−0,074 %	177	54,8
Moderado	46,6 %	0,053 %	81	25,1
Tenso	70,8 %	0,518 %	65	20,1

Tabla 5.7. Regímenes del mercado entre el 2/1/2025 y el 30/4/2026 (323 ruedas). Fuente: elaboración propia (`Lado Bursatil/06_hmm_regimen_mercado`).

Los regímenes son muy persistentes: la probabilidad de seguir en el mismo régimen al día siguiente es de 98,0 % en Calmo, 95,8 % en Moderado y 95,1 % en Tenso. La salida del estrés es gradual —de Tenso siempre se pasó a Moderado antes de volver a Calmo—, pero la entrada no: las dos veces que el mercado salió de Calmo saltó directo a Tenso (08/09 y 27/10/2025). El régimen Tenso tiene el retorno promedio más alto, porque incluye la fuerte suba posterior a las legislativas. Las versiones suavizada y filtrada coinciden en el 98,5 % de los días (figura 5.5). En la ventana de la unión, Moderado tiene solo 18 ruedas, por lo que el análisis por régimen compara Calmo contra Tenso.

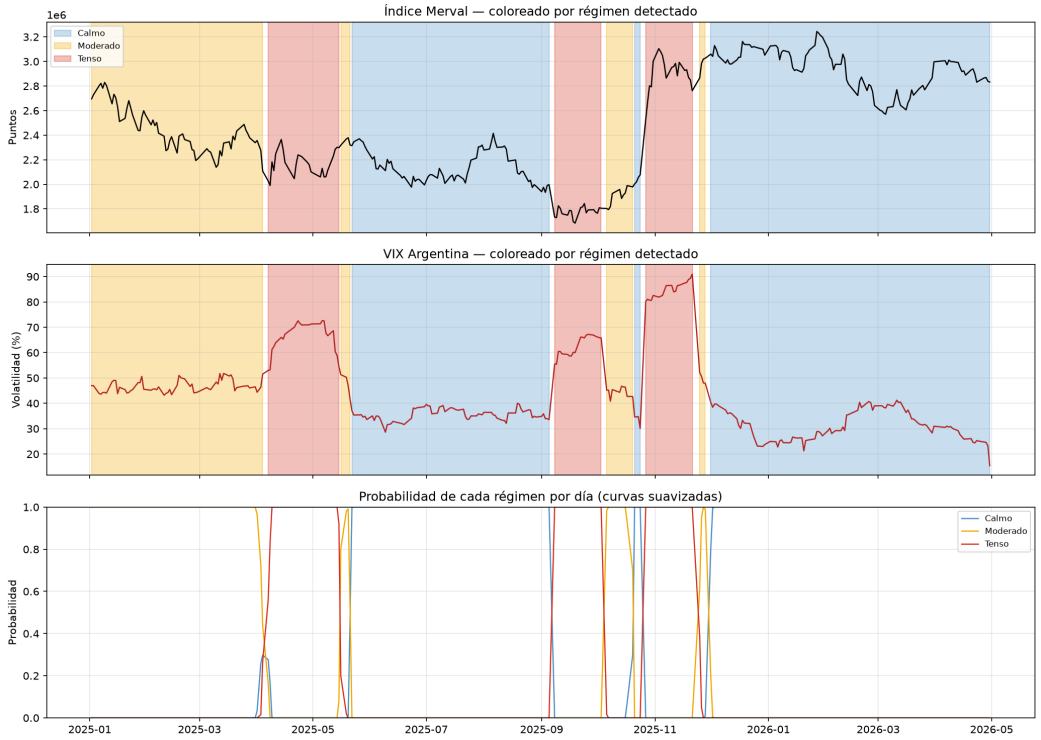


Figura 5.5. S&P Merval y VIX argentino coloreados por régimen, y probabilidad suavizada de cada régimen por día. Fuente: elaboración propia (`Lado Bursatil/06_hmm_regimen_mercado`).

Estacionariedad

Con tres años de datos, 46 de los 47 precios no son estacionarios (ADF con constante y tendencia) y los 47 retornos sí lo son (ADF con constante; 43 con $p < 0{,}0001$ y el más alto con $p = 0{,}006$). La única excepción en precios, TGSU2 ($p = 0{,}047$), está dentro de lo que se espera por azar en 47 pruebas. Los modelos usan, entonces, retornos y no precios (Zablotsky, 2002; Worthington y Higgs, 2003).

En la ventana de la unión se repitió la prueba con ADF y KPSS sobre 156 series (tabla 5.8). Retornos, volumen anormal y tono de cada empresa son estables. El tono de las noticias en nivel dio *inconcluso* ($p = 0{,}35$ en el ADF, sin problemas en el KPSS) porque cambia en ciclos de meses: el promedio trimestral fue de $+7{,}5$ en el segundo trimestre de 2025, $+0{,}5$ en el tercero, $+7{,}6$ en el cuarto, $+3{,}7$ en el primero de 2026 y $-2{,}9$ en abril de 2026. Con un año de datos, la prueba no distingue un clima que va y viene de uno que se va corriendo, un rasgo conocido de las series de tono (Correa Rocha, 2026). Por eso el VAR usa el *tono anormal*,

que es estable sin discusión ($p < 0{,}0001$) y mide la sorpresa —lo que puede mover precios— en lugar del clima de fondo; el tono en nivel quedó como prueba de robustez. El VIX también dio inconcluso, por la misma razón, y entra a los modelos solo a través del régimen.

Serie	Datos	ADF (p)	KPSS (p)	Conclusión
Retorno del S&P Merval	244	<0,0001	≥0,10	Estacionaria
Monto operado anormal	244	<0,0001	≥0,10	Estacionaria
Atención anormal	224	0,0014	0,077	Estacionaria
Notas por rueda	244	0,0044	≤0,01	Estacionaria con memoria
Tono anormal (variable del VAR)	224	<0,0001	≥0,10	Estacionaria
Tono en nivel	244	0,3492	≥0,10	Inconclusa
Cambio de tono	243	<0,0001	≥0,10	Estacionaria
VIX argentino	244	0,1545	0,095	Inconclusa
Retorno (47 acciones)	47 series	47 estacionarias		
Volumen anormal (47 acciones)	47 series	46 estacionarias y 1 con memoria		
Tono propio (17 empresas)	17 series	14 estacionarias y 3 con memoria		

Tabla 5.8. Estacionariedad de las series en la ventana de la unión. Fuente: elaboración propia (`Unión/05_adf_union`).

Relaciones entre tono, retorno y volumen

Dos correlaciones adelantan los resultados. En el VAR del mercado, las sorpresas del tono y del retorno de una misma rueda están correlacionadas (0,19): se mueven juntas dentro de la rueda. Y el tono de las notas publicadas de noche, con el mercado cerrado, tiene una correlación de 0,42 con el retorno de ese mismo día: después de una rueda buena, las notas de la noche son más positivas. Con datos diarios, la primera correlación no dice quién movió a quién; la segunda ya sugiere que las notas de la noche cuentan cómo cerró el mercado. La figura 5.6 muestra las series juntas.

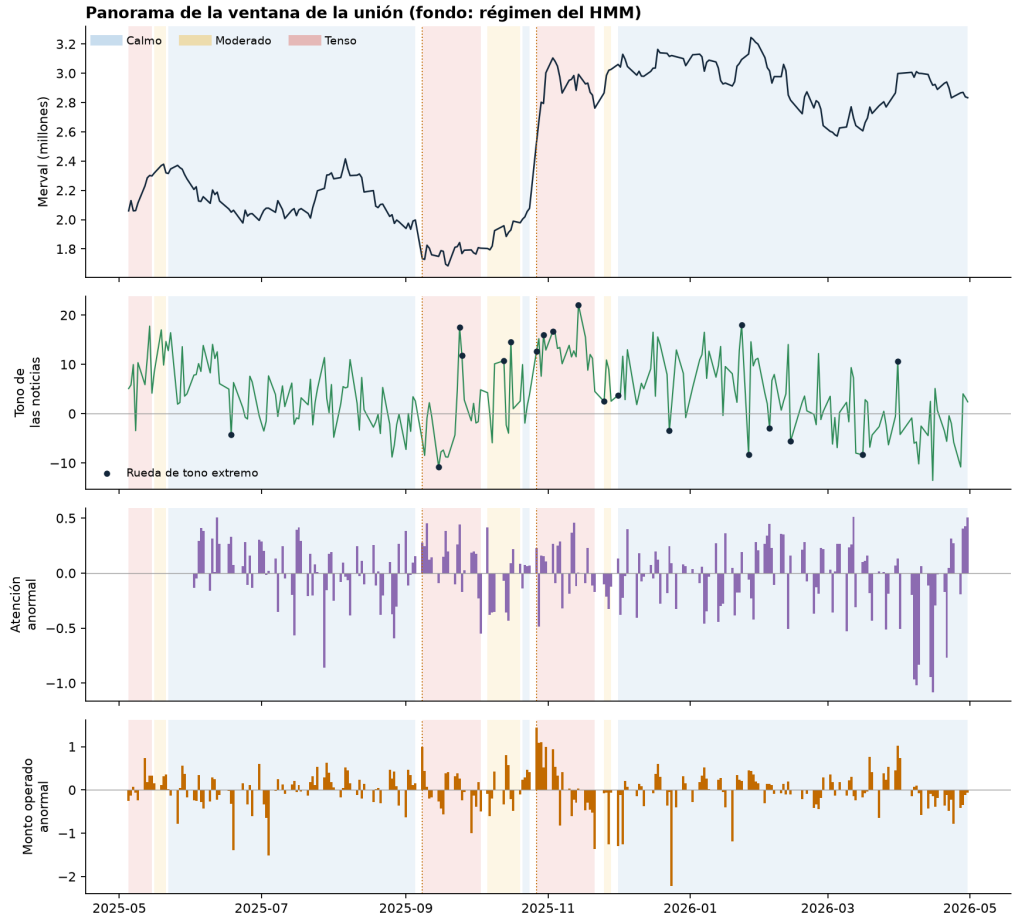


Figura 5.6. S&P Merval, tono de las noticias, atención de los medios y monto operado anormal en la ventana de la unión. El color de fondo es el régimen; las líneas punteadas, los días electorales. Fuente: elaboración propia (`Unión/04_dataset_unificado`).

5.1.5 Modelado

FinBETO: etiquetado, entrenamiento y evaluación

Clases. Se trabajó con cuatro clases: positiva (POS), negativa (NEG), neutra (NEU) y mixta (MIXTO). Una parte de las oraciones de la prensa económica combina señales de ambos signos —por ejemplo, un dato de actividad que mejora mientras la inflación se acelera— y forzarlas a una sola clase habría sido arbitrario.

Etiquetado. Se etiquetó con Gemma (`gemma4:26b`, temperatura 0,1) en dos pasos por noticia. Primero, el modelo leyó el título, la bajada y los primeros 3.000 caracteres, y produjo un análisis de contexto (tema central, encuadre, actores y tono general). Después etiquetó cada oración de al menos 30 caracteres, con ese contexto como referencia y la instrucción de que el sentimiento surgiera de lo que la oración expresa por sí misma. El criterio es, por lo tanto, relativo al encuadre de cada nota. Se tomó un artículo de cada una de las nueve fuentes por lote, hasta 408 noticias (45 o 46 por fuente) y 11.605 filas etiquetadas: 46,4 % NEU, 23,8 % POS, 20,8 % NEG y 8,9 % MIXTO.

Entrenamiento. Para que la clase neutra no dominara, se tomó una muestra balanceada de

hasta 2.400 oraciones por clase (todas las de MIXTO), dividida en 80 % para entrenamiento, 10 % para validación y 10 % para prueba (6.588, 824 y 824 oraciones). La pérdida se ponderó por la raíz cuadrada de la frecuencia inversa de cada clase. El preentrenamiento continuado se hizo con la tarea MLM (15 % de los tokens enmascarados) sobre el texto de los 14.667 artículos del corpus antes de su depuración final: 3 épocas, segmentos de 128 tokens y tasa de aprendizaje $2 \cdot 10^{-5}$. La pérdida de evaluación bajó de 1,233 a 1,121, y ante la frase «La [MASK] llegó al 3 % mensual según el INDEC» el modelo propuso «inflación» con probabilidad 0,81. El ajuste fino usó 5 épocas, lotes de 32, tasa de aprendizaje $2 \cdot 10^{-5}$ con 10 % de calentamiento, decaimiento de pesos 0,01 y selección de la mejor época por F1 macro en validación.

Problemas de la evaluación original. La primera evaluación informó un F1 macro de 0,7296 en cuatro clases, frente a 0,6201 del modelo de referencia. Al revisarla se encontraron tres problemas: la división se había hecho por oración y no por noticia (las 824 oraciones de prueba venían de 337 noticias que también aportaban oraciones al entrenamiento); había textos repetidos (41 oraciones de prueba, el 5 %, estaban también en entrenamiento); y había restos del *scraping* etiquetados como neutros («PUBLICIDAD PUBLICIDAD PUBLICIDAD», «Sobre la firma Newsletter Clarín»). Es el problema de fuga de información descrito por Kapoor y Narayanan (2023).

Nueva medición. Sin modificar el modelo en uso, se limpió el conjunto etiquetado (se descartaron 750 filas de relleno o repetidas y quedaron 10.855 oraciones), se lo dividió *por noticia* (330 noticias para entrenamiento, 39 para validación y 39 para prueba, sin textos compartidos) y se reentrenó solo para medir, con tres semillas por división. El código reproduce el resultado original (0,732 con la división por oración). Con la división por noticia, el F1 macro es de 0,685 (tabla 5.9). Para comparar en igualdad de condiciones con el modelo de referencia, que tiene tres clases, se usaron solo las oraciones POS, NEG y NEU, contando como error cada predicción MIXTO de FinBETO: sobre noticias no vistas, FinBETO obtiene 0,724 y el de referencia 0,546. El de referencia, entrenado con tuits, clasifica como neutras 411 de las 662 oraciones.

Medida (prueba, media de 3 semillas)	División por oración	División por noticia
F1 macro, 4 clases	0,732 ± 0,012	**0,685 ± 0,009**
Exactitud	0,743	0,691
F1 POS / NEG / NEU / MIXTO	0,752 / 0,760 / 0,754 / 0,663	0,694 / 0,677 / 0,725 / 0,645
F1 macro, 3 clases: FinBETO	0,773	**0,724**
F1 macro, 3 clases: modelo de referencia	0,620	0,546

Tabla 5.9. Calidad de FinBETO según cómo se dividen los datos. La estimación que corresponde informar es la de la división por noticia. Fuente: elaboración propia a partir de `Lado Noticias/sentimiento_finbert`.

Aplicación al corpus. El modelo se aplicó a todas las oraciones del corpus de entre 30 y 600 caracteres, incluido el título. Se excluyeron 2.438 oraciones de relleno (firmas de Clarín, marcas de publicidad de Infobae) y quedaron 399.803. Para cada artículo se calculó el sentimiento neto: el porcentaje de oraciones positivas menos el de negativas; las mixtas y

las neutras no suman ni restan. La serie diaria original promedia ese valor por fecha: abarca 487 días, 377 con datos, y marca 36 shocks (17 positivos y 19 negativos) con una banda de 1,5 desvíos sobre los siete días previos. La unión no usa esa serie sino la clasificación por oración, reagrupada por rueda.

Reconocimiento de entidades y cruce con el sentimiento

El NER combinó el modelo estadístico de spaCy con dos *gazetteers*: uno de 160 indicadores económicos en seis categorías (macroeconomía, política monetaria, política fiscal, mercado financiero, mercado laboral y precios y pobreza) y uno de las 47 empresas del panel, *canonicalizado*: cada alias (razón social, nombre comercial, ticker) se resuelve al ticker, para que «Banco Galicia», «Grupo Financiero Galicia» y «GGAL» cuenten como una sola entidad. Para limitar los falsos positivos, los alias en mayúsculas se buscan respetando mayúsculas (sin esta regla, el alias AGRO coincidía con la palabra «agro» en 920 artículos), se excluyeron alias que son palabras comunes («Hipotecario», «Molinos») y las entidades del modelo que coinciden con un término del *gazetteer* no se cuentan dos veces.

La limpieza del NER resolvió tres tipos de ruido (tabla 5.10): el texto de relleno del *scraping* («PUBLICIDAD» era la organización más mencionada del corpus), las autorreferencias de cada medio y los fragmentos sin valor informativo que detecta el modelo estadístico. Para el modelo estadístico se exigió una forma válida (no solo números ni más de seis palabras), al menos dos artículos con la entidad y un único tipo por cadena.

	Antes del filtrado	**Después**
Entidades únicas	65.352	17.894
Menciones de «PUBLICIDAD» como entidad	2.258 (primera del ranking)	0
«newsletter clarín» como entidad	2.134 artículos	0
Empresas del panel	20, fragmentadas en variantes	47, canonicalizadas por ticker
Tickers con menciones en el corpus	—	44 de 47
Falsos positivos del alias AGRO	920 artículos	0

Tabla 5.10. Efecto de la limpieza del reconocimiento de entidades. Fuente: elaboración propia a partir de `Lado Noticias/ner_entidades`.

Cada mención se unió con el sentimiento de la oración que la contiene, por artículo y número de oración y exigiendo que el texto coincida: se cruzaron 243.265 de las 244.809 oraciones con entidades (99,37 %). Antes de agregar, 24 variantes de indicadores se unificaron en su forma más frecuente (por ejemplo, «PIB» y «producto bruto interno» en «PBI»; «CCL» y «contado con liquidación»). Entre las empresas más mencionadas, el sentimiento neto fue de $+28{,}9$ para Galicia, $+25{,}0$ para Macro y $+17{,}4$ para YPF, y cercano a cero para Supervielle ($+1{,}4$) y Edenor ($+0{,}9$). Debe leerse como el tono del contexto en que aparece la entidad y no como una opinión sobre ella.

VAR, Granger e impulso-respuesta

Se usaron las 224 ruedas del 02/06/2025 al 30/04/2026: las 244 de la unión menos las primeras 20, que no tienen tono anormal ni atención. Se estimaron VAR en cinco niveles (tabla 5.11), siempre en las dos direcciones y para precio y volumen. En total se hicieron 304 pruebas de Granger, corregidas por Benjamini-Hochberg dentro de cada nivel.

Nivel	Variables del VAR	Modelos
Mercado	Tono anormal, atención anormal, retorno del S&P Merval y monto operado anormal	1
Empresa	Tono anormal del mercado, retorno y volumen anormal de la acción	47
Tono propio	Lo anterior más el tono propio de la empresa	17
Sector	Tono anormal, retorno y volumen anormal promedio del sector	10
Régimen	Todas las ruedas, con una marca de día Tenso que interactúa con los rezagos	4 regresiones

Tabla 5.11. Niveles del análisis VAR. Fuente: elaboración propia (`Unión/06_var_granger`).

Para el régimen no se separaron los días de cada uno, porque eso pegaría días no consecutivos. Se usaron todos los días con una marca de día Tenso y se probó el efecto en los días Calmo, en los Tenso y la diferencia. Como control de calibración, el test por empresa se repitió con el tono mezclado al azar (1.880 pruebas): debería dar $p < 0{,}05$ en alrededor del 5 % de los casos si el test no inventa resultados. Todos los VAR resultaron estables (raíces dentro del círculo unitario).

Notas publicadas con el mercado cerrado

Dentro de una misma rueda el tono y el retorno se mueven juntos, y con datos diarios no se sabe quién movió a quién. Para resolverlo se usó la hora de cada nota. Las notas publicadas entre el cierre de la rueda anterior y la apertura salen antes de cualquier operación de la rueda: el precio de esa rueda no puede haberlas causado. Si su tono anticipa el salto de apertura, eso es noticias $\rightarrow$ mercado sin ambigüedad, en la línea de Glasserman et al. (2025). La especificación se escribió y guardó antes de correr ningún cálculo (anexo E):

- **Notas:** las asignadas a la rueda que no se publicaron durante la sesión (11:00 a 17:00), sin las de hora sospechosa: 8.069 notas; todas las ruedas tienen alguna (mediana 29).
- **Variables:** el tono anormal de esas notas y, para las 17 empresas, su tono propio con solo esas notas; el retorno de apertura (del cierre de ayer a la apertura de hoy) y el de la sesión (de la apertura al cierre). El mercado es el promedio de las 47 acciones, porque los datos no traen la apertura del índice.
- **Modelo:** mínimos cuadrados con errores robustos; controla por el retorno del día anterior, porque muchas notas de la noche cuentan cómo cerró el mercado, y por si la rueda viene de un día sin mercado. En el panel de empresas, con efecto fijo por empresa y errores agrupados por rueda.

- **Evidencia a favor de la hipótesis:** que el tono anticipe el retorno de apertura con signo positivo y $p < 0{,}05$ tras la corrección. Se informa también el resultado sin los dos días electorales.

Estudios de eventos

Ruedas de tono extremo (U7). Se usaron dos tipos de eventos. Para el mercado, las ruedas de tono extremo de la sección 5.1.2 (18 eventos, contando como uno las ruedas seguidas del mismo signo), medidas sobre el propio S&P Merval con el modelo de media constante: un modelo de mercado restaría justamente el movimiento del índice y el efecto buscado desaparecería por construcción. Para las 17 empresas, las ruedas en que se habló de ellas mucho mejor o peor que del mercado (más de 2,5 desvíos de su propio tono propio): 88 eventos, medidos con el modelo de mercado de cada acción. La ventana $[-3, +5]$ se partió en antes $[-3, -1]$, día $[0]$ y después $[+1, +5]$.

Una primera corrida mostró una suba de 6,3 % en las ruedas previas a los eventos positivos, generada casi entera por un solo evento cuya ventana incluía el salto de 21 % posterior a las legislativas. Un salto así, además, infla el «promedio normal» de los eventos siguientes. Por eso los dos días electorales se excluyeron de las ventanas de estimación y los eventos cuya ventana incluye uno se analizaron aparte. Quedaron 16 eventos de mercado: 7 positivos y 9 negativos.

Shock de cantidad de noticias (U7b). Es la prueba con la definición literal del plan: el puntaje z de la cantidad de notas de la rueda contra las 30 ruedas previas, con umbral $z > 2$; para cada empresa, la cantidad de artículos que la mencionan, con al menos 3 en la rueda. Un shock de cantidad no tiene signo —muchas notas pueden ser buenas o malas—, así que la medida central es el tamaño del movimiento del precio el día del shock, en valor absoluto, además del volumen. La significancia se evalúa contra fechas al azar y con Benjamini-Hochberg sobre las 14 pruebas principales. La especificación se escribió antes de calcular los resultados.

La versión original mostró un problema: los 13 eventos de mercado caían todos en la primera rueda después de un día sin mercado. Por la regla de las 17:00, esa rueda junta las notas de tres o cuatro días, de modo que casi siempre «tiene muchas más notas». La regla marcaba fines de semana, no noticias. Se corrigió midiendo la cantidad *por día de calendario* (la cantidad de la rueda dividida por los días que cubre), lo más fiel al «volumen diario» del plan. El cambio quedó registrado con su fecha y su motivo, y la versión original se informa también. Se agregó, antes de correrla, una prueba que cuenta solo las notas publicadas con el mercado cerrado y mide el salto de apertura, el único precio que se forma después de esas notas y antes de las de la sesión.

Robustez

La prueba de robustez (U8) cambia una sola decisión por vez y mira si la conclusión sigue en pie: tono ajustado por portal, tono en nivel, sin notas de hora sospechosa, fecha de calendario en lugar de la regla de las 17:00, solo notas del día antes del cierre, sin abril de 2026, días electorales como control, sin las cuatro acciones ilíquidas, régimen filtrado, Calmo con-

tra No calmo y umbrales 2 y 3 para las ruedas de tono extremo. Antes de cambiar nada, el script rearma todo con las decisiones originales y comprueba que reproduce los resultados principales, de modo que las diferencias se deben a la decisión cambiada y no al código.

Capítulo 6

Resultados y Discusión

Los resultados se presentan en el orden de la pregunta. Primero, qué dirección aparece en el VAR y en las pruebas de Granger (sección 6.1); después, la prueba más favorable a la hipótesis, con las notas publicadas con el mercado cerrado (sección 6.2); luego, los estudios de eventos con las dos definiciones de shock (secciones 6.3 y 6.4); la robustez (sección 6.5) y, por último, la discusión con la literatura (sección 6.6). En todas las tablas, «significativo» quiere decir significativo al 5 % después de la corrección de Benjamini-Hochberg.

6.1 ¿Quién anticipa a quién? VAR y causalidad de Granger

6.1.1 El mercado

De las ocho pruebas del VAR del mercado, una sola es significativa, y es fuerte: el retorno del S&P Merval anticipa el tono de las noticias (p corregido 0,0003). Ninguna prueba en la dirección de las noticias hacia el mercado llega a ser significativa, tampoco la de la atención de los medios hacia el volumen operado (tabla 6.1).

Prueba	Dirección	p	p corregido	Significativo
tono → retorno	Noticias → mercado	0,2119	0,4238	No
retorno → tono	Mercado → noticias	<0,0001	0,0003	**Sí**
tono → volumen	Noticias → mercado	0,0632	0,2528	No
volumen → tono	Mercado → noticias	0,3617	0,4823	No
atención → retorno	Noticias → mercado	0,9293	0,9293	No
retorno → atención	Mercado → noticias	0,1479	0,3944	No
atención → volumen	Noticias → mercado	0,3377	0,4823	No
volumen → atención	Mercado → noticias	0,5918	0,6764	No

Tabla 6.1. Pruebas de causalidad de Granger en el VAR del mercado (224 ruedas). Fuente: elaboración propia (`Unión/06_var_granger`).

La impulso-respuesta dimensiona el efecto (figura 6.1). Un día en que el S&P Merval sube un desvío (2,8 %), el tono anormal de las noticias sube 1,84 puntos en la rueda siguiente y 1,23 en la segunda, ambos distintos de cero; a la tercera (0,56) ya no se distingue de cero. Como un desvío del tono anormal son 6,0 puntos, la suba de la rueda siguiente es de un tercio de desvío. El tono y el retorno de una misma rueda también se mueven juntos (correlación de las sorpresas: 0,19). La impulso-respuesta atribuye ese movimiento conjunto a las noticias, pero solo porque se las ordenó primero: con datos diarios no se puede saber quién movió a

quién dentro de la rueda. Desde la rueda siguiente, el efecto del tono sobre el retorno ya no se distingue de cero.

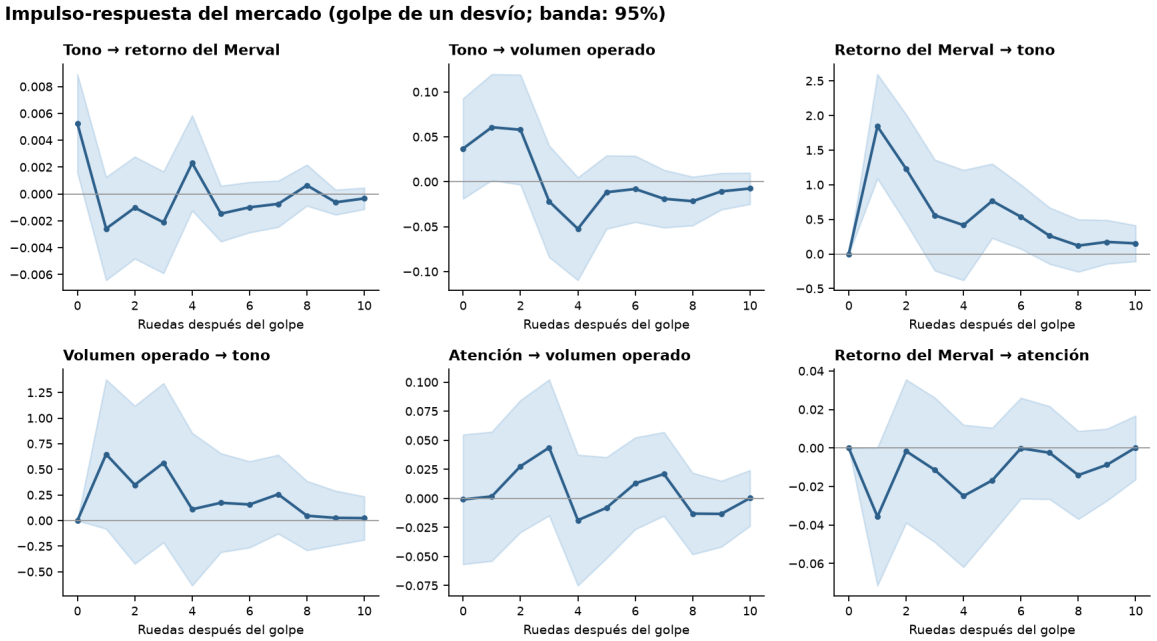


Figura 6.1. Funciones de impulso-respuesta del VAR del mercado ante un golpe de un desvío, con banda del 95 %. Si la banda no toca el cero, la respuesta es distinta de cero. Fuente: elaboración propia (`Unión/06_var_granger`).

6.1.2 Las empresas

El retorno de casi todas las empresas anticipa el tono de las noticias: 39 de 47, todas con signo positivo (tabla 6.2). Hay que leerlo con cuidado: en este nivel el tono es el del mercado, y los retornos de las empresas se mueven con el índice, de modo que en buena parte es el mismo hallazgo del mercado repetido 47 veces. En la dirección contraria, 7 de 94 pruebas dan $p < 0{,}05$ sin corregir, cuando por azar se esperarían unas 9,4; después de la corrección quedan dos (LONG y SUPV, tono → volumen), sin un patrón. El detalle por empresa está en el anexo D.

Prueba	Pruebas	$p < 0{,}05$ sin corregir	Significativas	Signo
47 empresas, con el tono del mercado				
tono → retorno	47	1	0	—
tono → volumen	47	6	2	2 positivas
retorno → tono	47	43	**39**	39 positivas
volumen → tono	47	11	3	3 positivas
17 empresas, con su tono propio				
tono propio → retorno	17	0	0	—
tono propio → volumen	17	2	1	1 positiva
retorno → tono propio	17	16	**15**	15 positivas
volumen → tono propio	17	1	0	—

Tabla 6.2. Pruebas de Granger por empresa. Fuente: elaboración propia (`Unión/06_var_granger`).

La prueba más exigente es la del tono propio, que descuenta el clima general de las noticias. En 15 de las 17 empresas, cuando la acción sube, en las ruedas siguientes se habla de ella mejor que del resto del mercado: BBAR, BMA, BYMA, CEPU, CRES, EDN, GGAL, IRSA, LOMA, METR, SUPV, TGSU2, TRAN, TXAR e YPFD. No aparece en ALUA ni en PAMP. Es el resultado más fuerte de la tesina, porque es específico de cada empresa. En la dirección contraria queda una sola prueba significativa (IRSA, tono propio → volumen), aislada: el tono propio no anticipa ni el retorno ni el volumen.

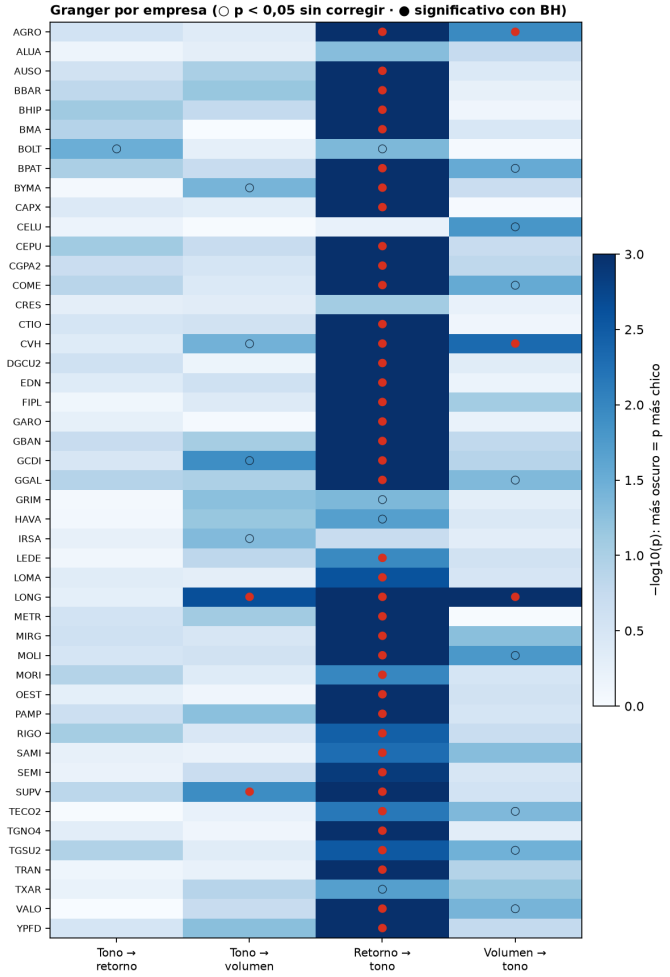


Figura 6.2. Pruebas de Granger por empresa. Cada fila es una empresa y cada columna una prueba; más oscuro, p más chico; ○ $p < 0{,}05$ sin corregir; ● significativo después de la corrección. Fuente: elaboración propia (`Unión/06_var_granger`).

6.1.3 Los sectores y el régimen

El retorno anticipa el tono en 9 de los 10 sectores; la excepción es Tecnología, que tiene una sola acción (BOLT). En la otra dirección, solo en Conglomerado el tono anticipa el volumen, y con signo negativo: un resultado aislado. Sumando todos los niveles, de las 152 pruebas en la dirección noticias → mercado solo 4 son significativas, lo esperable por azar.

Prueba	Días Calmo	Días Tenso	Diferencia
tono → retorno	0,2721	0,8436	0,9516
tono → volumen	0,0498	0,2778	0,2810
retorno → tono	**0,0011**	**0,0006**	0,6762
volumen → tono	0,4521	**0,0021**	0,0496

Tabla 6.3. Pruebas de Granger según el régimen (p; en negrita, significativas después de la corrección). Fuente: elaboración propia (`Unión/06_var_granger`).

El retorno anticipa el tono tanto en los días Calmo como en los Tenso, sin diferencia entre ellos (tabla 6.3). El volumen anticipa el tono solo en los días Tenso, pero la diferencia con los Calmo no es significativa tras la corrección; con 40 días Tenso, es poco para afirmar diferencias entre regímenes. En ningún régimen el tono anticipa al mercado. La prueba de calibración, con el tono mezclado al azar, dio $p < 0{,}05$ en el 6,9 % de los casos, cerca del 5 % esperado: el test no inventa resultados.

6.2 La prueba más directa: notas publicadas con el mercado cerrado

El tono de las 8.069 notas publicadas con el mercado cerrado va en la dirección de la hipótesis: con notas de la noche más positivas, el mercado abre algo más arriba (0,18 % por cada desvío del tono, cuando el retorno de apertura promedio varía 1,1 % de un día a otro). Pero no llega a ser significativo: $p = 0{,}107$ en el mercado y $0{,}105$ en el panel de empresas (tabla 6.4). Sin los dos días electorales, el efecto del mercado se achica a 0,06 % y el de las empresas a 0,02 %. Durante la sesión no hay nada. Por empresa, 1 de 34 pruebas da $p < 0{,}05$ sin corregir y ninguna después de la corrección. La calibración con el tono mezclado al azar dio 4,7 % de $p < 0{,}05$.

Muestra	Nivel	Retorno	Efecto por desvío	p	p corregido
Todas las ruedas	Mercado	Apertura	+0,181 %	0,107	0,213
Todas las ruedas	17 empresas	Apertura	+0,073 %	0,105	0,213
Todas las ruedas	Mercado	Sesión	+0,201 %	0,267	0,356
Todas las ruedas	17 empresas	Sesión	+0,041 %	0,656	0,656
Sin días electorales	Mercado	Apertura	+0,059 %	0,154	0,534
Sin días electorales	17 empresas	Apertura	+0,023 %	0,391	0,534
Sin días electorales	Mercado	Sesión	+0,148 %	0,401	0,534
Sin días electorales	17 empresas	Sesión	+0,016 %	0,861	0,861

Tabla 6.4. Tono de las notas publicadas con el mercado cerrado y retorno de la rueda siguiente. Fuente: elaboración propia (`Unión/06b_noticias_preapertura`).

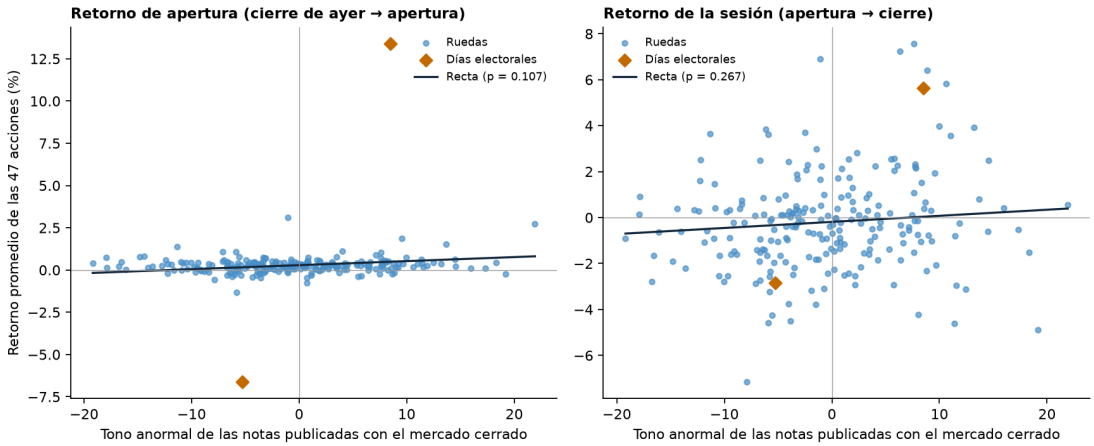


Figura 6.3. Cada punto es una rueda. Horizontal: tono anormal de las notas publicadas con el mercado cerrado. Vertical: retorno promedio de las 47 acciones, de apertura (izquierda) y de la sesión (derecha). Fuente: elaboración propia (`Unión/06b_noticias_preapertura`).

Los dos días electorales son exactamente el caso que plantea la hipótesis: noticias de la noche muy negativas o muy positivas y una apertura que salta en la misma dirección (tabla 6.5). Pero lo que mueve al mercado ahí es el resultado de la elección, no el tono con que los medios lo cuentan. Fuera de esos dos días, el tono de la noche casi no se relaciona con la apertura. En cambio, el tono de esas mismas notas se relaciona fuerte con cómo cerró el mercado el día anterior (correlación 0,42): es el resultado del VAR visto desde otro ángulo.

Rueda	Notas de la noche	Tono anormal	Apertura	Sesión
08/09/2025 (tras las bonaerenses)	66	−5,3	−6,6 %	−2,8 %
27/10/2025 (tras las legislativas)	81	+8,5	+13,4 %	+5,6 %

Tabla 6.5. Los dos días electorales en la prueba pre-apertura. Fuente: elaboración propia (`Unión/06b_noticias_preapertura`).

6.3 Estudio de eventos: ruedas de tono extremo

En las ruedas de tono extremo positivo, el S&P Merval sube 2,01 % el mismo día, en los 7 eventos (p del test t 0,009; contra fechas al azar, 0,018). Y ya venía subiendo: +3,19 % en las tres ruedas previas (contra el azar, $p = 0{,}037$). Después del evento no pasa nada ($-2{,}80$ %, indistinguible del azar). En las ruedas de tono extremo negativo no aparece ningún movimiento (tabla 6.6). El monto operado acompaña al precio: en los eventos positivos ya estaba 0,24 por encima de lo habitual en las tres ruedas previas (contra el azar, $p = 0{,}031$) y vuelve a lo normal después. Dejando solo el primero de cada grupo de eventos solapados quedan 4 eventos positivos, y la suba del día se mantiene (+2,40 %, $p = 0{,}034$ contra el azar).

Eventos	Tramo	CAR medio	Con suba	p (test t)	p (azar)
Positivos (7)	Antes $[-3, -1]$	+3,19 %	5 de 7	0,188	**0,037**
	Día $[0]$	+2,01 %	7 de 7	**0,009**	**0,018**
	Después $[+1, +5]$	−2,80 %	3 de 7	0,345	0,306
Negativos (9)	Antes $[-3, -1]$	−0,84 %	4 de 9	0,633	0,645
	Día $[0]$	−0,01 %	4 de 9	0,988	0,915
	Después $[+1, +5]$	+1,27 %	5 de 9	0,420	0,370

Tabla 6.6. Retorno anormal acumulado del S&P Merval alrededor de las ruedas de tono extremo. Fuente: elaboración propia (`Unión/07_event_study`).

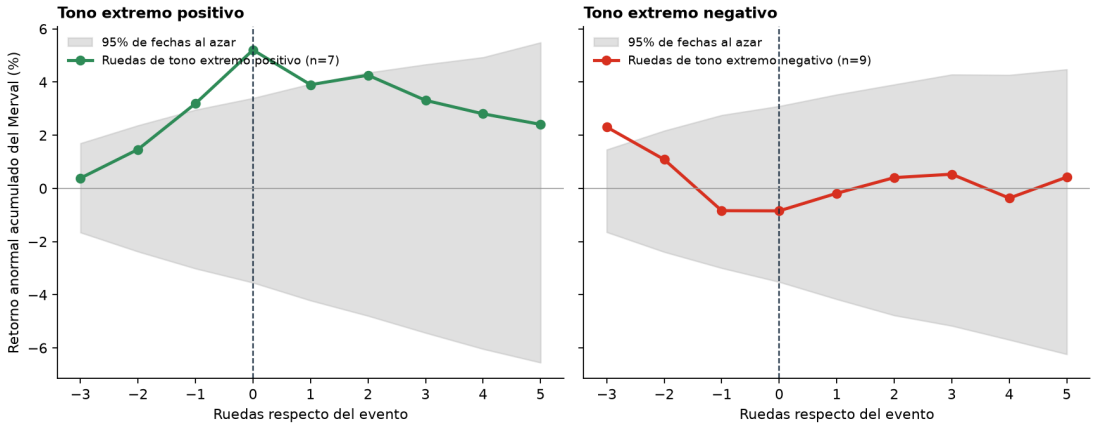


Figura 6.4. Retorno anormal acumulado promedio del S&P Merval desde tres ruedas antes hasta cinco después de las ruedas de tono extremo. La banda gris es el 95 % de lo que da el azar con la misma cantidad de fechas. Fuente: elaboración propia (`Unión/07_event_study`).

Con las empresas ocurre lo mismo. Cuando se habla de una empresa de forma muy positiva, su acción ya había subido 1,24 % más que el mercado en las tres ruedas previas (62 eventos, $p = 0{,}029$), y después no pasa nada ($-0{,}14$ %). Con el tono muy negativo, la acción venía de bajar 2,12 % ($p = 0{,}061$) y después rebota 2,96 % ($p = 0{,}099$), sin llegar al 5 %. El volumen de la empresa no cambia (figura 6.5).

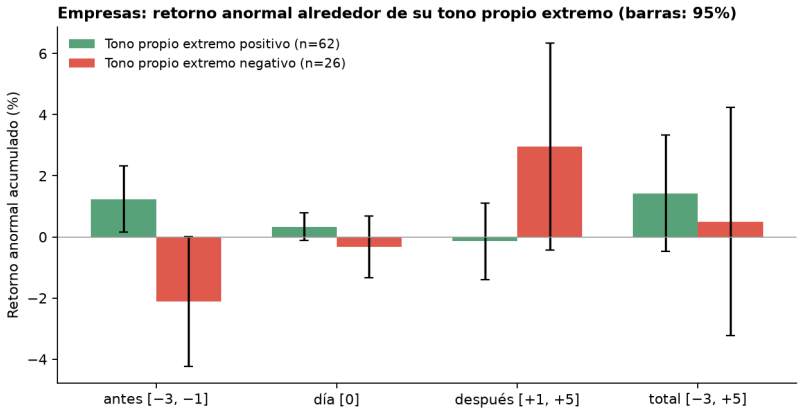


Figura 6.5. Retorno anormal acumulado de cada empresa alrededor de sus ruedas de tono propio extremo, positivo y negativo. Fuente: elaboración propia (`Unión/07_event_study`).

El estudio de eventos cuenta la misma historia que el VAR: el precio y el volumen se mueven antes o junto con las noticias extremas, no después. Las ruedas de tono muy positivo son ruedas de suba del mercado; pasada esa rueda, el tono no deja nada por anticipar. El efecto aparece con el tono positivo y no con el negativo, pero con 7 y 9 eventos no se puede afirmar que la asimetría sea real.

6.4 Estudio de eventos: shocks de cantidad de noticias

Con la definición del plan corregida por día de calendario, el mercado tiene 6 eventos y ninguna medida se distingue de un día cualquiera. En las 17 empresas hay 105 shocks (tabla 6.7). El volumen anormal del día del shock es claramente mayor que en un día cualquiera (0,139 contra $-0{,}054$; p corregido 0,017): cuando una empresa aparece en muchas más notas que lo habitual, ese día su acción se opera más. El precio se mueve algo más, para un lado o para el otro (2,02 % en valor absoluto contra 1,61 %; p corregido 0,059), pero el retorno acumulado no tiene dirección y no hay nada en los días siguientes. Antes del shock no aparece nada significativo: el precio no viene moviéndose antes de que aumente la cantidad de noticias.

Nivel	Medida	Shocks	Día cualquiera	p (azar)	p corregido
Mercado (6)	|RA| día [0]	2,11 %	1,83 %	0,642	0,956
	Vol. anormal día [0]	−0,003	−0,027	0,886	0,956
	CAR día [0]	−1,50 %	−0,07 %	0,127	0,443
Empresas (105)	|RA| día [0]	2,02 %	1,61 %	0,008	0,059
	Vol. anormal antes [−3, −1]	0,038	−0,043	0,051	0,237
	Vol. anormal día [0]	0,139	−0,054	0,001	**0,017**
	Vol. anormal después [+1, +5]	−0,045	−0,052	0,849	0,956
	CAR día [0]	0,13 %	0,01 %	0,591	0,956
	CAR después [+1, +5]	−0,02 %	0,06 %	0,905	0,956

Tabla 6.7. Estudio de eventos de los shocks de cantidad de noticias (selección de las 14 pruebas principales; el resto no es significativo). RA: retorno anormal; Vol.: volumen anormal en logaritmo (0 = lo habitual). La corrección de Benjamini-Hochberg se aplica sobre las 14. Fuente: elaboración propia (`Unión/07b_shock_volumen_noticias`).

La rueda del shock incluye notas publicadas durante la misma sesión, que pueden estar contando la suba o la baja del día. Por eso «el precio se mueve más el día del shock» no dice qué vino primero. La prueba que cuenta solo las notas publicadas con el mercado cerrado lo aclara (tabla 6.8): en las empresas, el salto de apertura no es mayor que en un día cualquiera (0,82 % contra 0,72 %; p corregido 0,544), aunque el volumen del día tiende a ser mayor (p corregido 0,053). En el mercado el salto de apertura sí es mayor (p corregido 0,022), pero con 5 eventos y apoyado en un solo día: sin el 24/09/2025, el del anuncio del Tesoro de Estados Unidos, el promedio baja de 0,95 % a 0,59 % y el p sube a 0,093. Es el mismo patrón de las elecciones: un hecho grande genera muchas noticias y mueve el precio, pero lo que mueve al mercado es el hecho, no la cantidad de cobertura.

Nivel	Medida	Shocks	Día cualquiera	p (azar)	p corregido
Mercado (5)	|Salto de apertura anormal|	0,95 %	0,33 %	0,004	0,022
	|RA| día [0]	1,64 %	1,83 %	0,790	0,875
	Vol. anormal día [0]	−0,057	−0,027	0,875	0,875
Empresas (76)	|Salto de apertura anormal|	0,82 %	0,72 %	0,293	0,544
	|RA| día [0]	1,77 %	1,61 %	0,363	0,544
	Vol. anormal día [0]	0,105	−0,054	0,018	0,053

Tabla 6.8. Shocks de cantidad contando solo las notas publicadas con el mercado cerrado. El salto de apertura del mercado depende del 24/09/2025: sin ese día, $p = 0{,}093$. Fuente: elaboración propia (`Unión/07b_shock_volumen_noticias`).

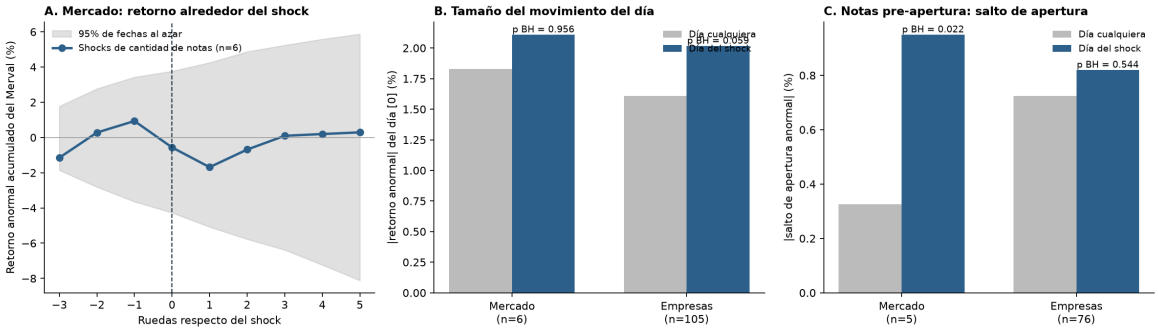


Figura 6.6. A: retorno anormal acumulado del S&P Merval alrededor de los shocks de cantidad, contra el 95 % de fechas al azar. B y C: tamaño del movimiento en los shocks contra un día cualquiera; C cuenta solo las notas publicadas con el mercado cerrado. Fuente: elaboración propia (`Unión/07b_shock_volumen_noticias`).

Los análisis secundarios confirman que el resultado de las empresas no depende de una decisión puntual: el movimiento y el volumen del día son mayores con umbral $z > 2{,}5$ (70 eventos), con el puntaje z sobre $\log(1 + \text{cantidad})$ (63 eventos) y sumando los eventos con una elección en su ventana (114). Separando por el tono de la rueda, el efecto aparece en los shocks de tono negativo (46 eventos) y no en los de tono positivo (59). En la versión original, sin dividir por los días que cubre la rueda, los 12 eventos del mercado son todas ruedas posteriores a un día sin mercado y no muestran nada; en las empresas, el resultado del volumen es el mismo.

Según la regla fijada antes de correr la prueba, el volumen anormal del día del shock en las empresas cuenta como evidencia a favor de H1, y es significativo tras la corrección. La hipótesis encuentra, entonces, un *apoyo parcial, en el volumen*: cuando una empresa está en muchas más notas, ese día se opera más. No hay un efecto con dirección sobre el precio, ni arrastre en los días siguientes, y las notas de la noche no anticipan la apertura.

6.5 Robustez: cuándo siguen los medios al mercado

De 106 comparaciones entre la base y las doce variantes, 93 mantienen la conclusión (tabla 6.9). Dos resultados se sostienen en todas. Primero, el tono no anticipa al mercado: en ninguna variante el tono anticipa el retorno, ni en el mercado ni en ninguna empresa. Es el resultado más firme de la tesina. Segundo, el mercado anticipa al tono con cualquier medida de tono y sin los días dudosos: con el tono ajustado por portal, con el tono en nivel, sin las notas de hora sospechosa, sin abril de 2026, con los días electorales como control y sin las acciones ilíquidas (36 de 43 empresas). Con el régimen filtrado o juntando Moderado con Tenso, el retorno sigue anticipando el tono en los dos tipos de días. En el estudio de eventos, la suba del S&P Merval en las ruedas de tono extremo positivo se mantiene con el umbral 3, que deja solo las cuatro más extremas (+1,50 %, $p = 0{,}038$), con el umbral 2 (+2,42 %, $p = 0{,}009$) y sin las notas de hora sospechosa (+1,95 %, $p = 0{,}025$).

Variante	Ret. → tono (p)	Tono → ret. (p)	Ret. → propio (de 17)	Propio → ret. (de 17)	Ret. → tono (de 47)
Base	0,0003	0,4238	15	0	39
Tono ajustado por portal	0,0003	0,4483	15	0	39
Tono en nivel	0,0002	0,4752	11	0	34
Sin notas de hora sospechosa	0,0002	0,4903	16	0	40
Fecha de calendario	0,3389	0,4183	0	0	0
Solo notas del día, antes del cierre	0,7000	0,4450	0	0	0
Sin abril de 2026	0,0004	0,2239	16	0	39
Días electorales como control	0,0003	0,5602	15	0	38

Tabla 6.9. Resultados principales en cada variante (p corregidos). Fuente: elaboración propia (`Unión/08_robustez`).

Con dos variantes el efecto del retorno sobre el tono desaparece: la fecha de calendario y las notas del día antes del cierre. Las dos tienen algo en común: dejan afuera, o cambian de rueda, las notas publicadas después del cierre. Para ver exactamente dónde está el efecto se separaron las notas según la franja en que se publicaron (tabla 6.10).

Franja de publicación	Notas	Efecto de un desvío del retorno	p
Noche del día de la rueda (17 a 24 h)	3.451	**+4,77 puntos de tono**	<0,0001
Día sin rueda	2.142	+3,11	0,1133
Madrugada y mañana siguientes (antes de las 11)	4.331	+0,54	0,5142
Sesión (11 a 17 h)	4.001	+1,26	0,1028

Tabla 6.10. Relación entre el retorno de una rueda y el tono de las notas según la franja en que se publicaron. Fuente: elaboración propia (`Unión/08_robustez`).

El efecto está en las notas de la misma noche, publicadas entre las 17:00 y la medianoche del día de la rueda: un desvío del retorno sube su tono 4,8 puntos. En las notas de la madrugada y la mañana siguiente es casi nulo. La regla de las 17:00 manda las notas de la noche a la rueda siguiente, y por eso en el VAR el efecto aparece como «el retorno de hoy anticipa el tono de mañana». En realidad es más directo: después del cierre, los medios cuentan cómo le fue al mercado y a cada empresa con un tono que acompaña la suba o la baja, y no hay un arrastre que dure días. Con el tono propio de cada empresa pasa lo mismo: usando solo las notas del día antes del cierre, el efecto desaparece en las 17 empresas.

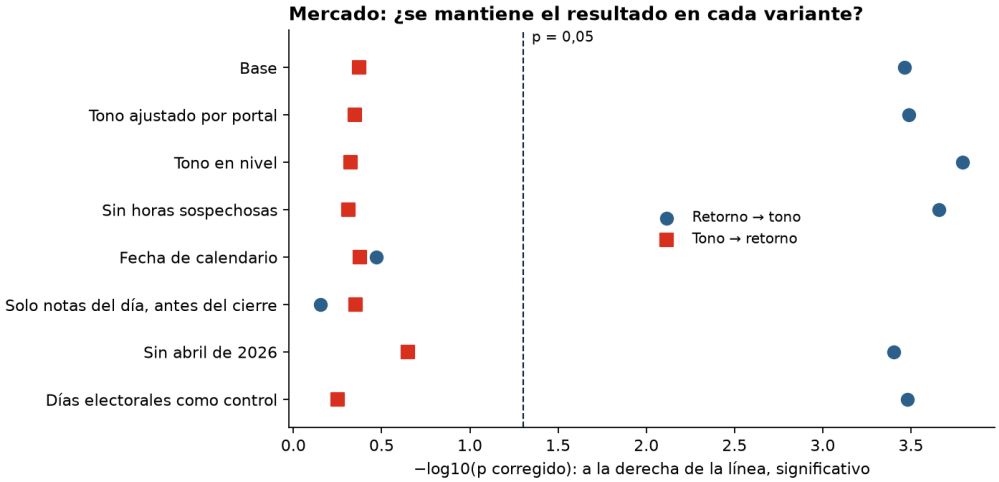


Figura 6.7. Resultados principales en cada variante de robustez. Fuente: elaboración propia (`Unión/08_robustez`).

6.6 Discusión

Los medios siguen al mercado. El resultado central coincide con uno de los dos hallazgos de Tetlock (2007): los retornos anticipan el tono de la cobertura. Que se repita con medios argentinos, en otro idioma y con un modelo de sentimiento distinto, lo hace más creíble. La robustez agrega una precisión que el trabajo de Tetlock, con una columna diaria, no podía dar: el efecto está en las notas publicadas la misma noche, después del cierre, que cuentan la jornada. Es consistente con Verma et al. (2026), para quienes buena parte de la cobertura refleja información que el precio ya incorporó, y con la pregunta de Kargarzadeh et al. (2026) sobre en qué momento una noticia «ya está en el precio»: en las ruedas de tono extremo, el S&P Merval ya venía subiendo antes.

Las noticias no anticipan al mercado. Aquí el resultado difiere de Tetlock (2007) y de Galdi y Gonçalves (2018), que encuentran contenido informativo en el tono de los medios de Estados Unidos y Brasil. La diferencia no contradice a la literatura. Garcia (2013) muestra que el efecto del tono sobre los retornos se concentra en las recesiones, y la ventana de esta tesina es de un solo año; además, el análisis por régimen no encontró efecto ni siquiera en los días de mayor estrés del mercado (régimen Tenso). También es compatible con un mercado que incorpora la información rápido (Fama, 1970): los hechos grandes —las elecciones, el anuncio del Tesoro de Estados Unidos— se reflejan de inmediato en la apertura, y el tono con que los medios los cuentan no agrega información que el precio no tenga. La prueba pre-apertura, la más parecida a la de Glasserman et al. (2025), encuentra un indicio del signo esperado ($p \approx 0{,}1$) que se apoya en los días electorales.

La cantidad de noticias acompaña a la actividad. Que una empresa con muchas más notas se opere más ese día está en línea con la literatura de atención (Da et al., 2011; Fang y Peress, 2009; Cao et al., 2025) y con la evidencia de Engelberg y Parsons (2011) de que la cobertura de medios se asocia con el volumen operado. A diferencia de Coronado et al. (2022; 2023), que encuentran causalidad desde índices de cantidad de noticias del COVID

hacia las bolsas latinoamericanas, aquí la cantidad no anticipa la apertura de cada empresa: el movimiento del día puede ser tanto la reacción a la noticia como la noticia contando el movimiento. La relación entre retorno y volumen, por su parte, es conocida en la región: el retorno tiende a anticipar al volumen (Rojas y Kristjanpoller, 2015).

Tono por empresa. El hallazgo más específico —después de que una acción sube, se habla de esa empresa mejor que del resto— no podría verse con un tono por nota. Respalda medir el sentimiento a nivel de entidad (Tang et al., 2023; Sinha et al., 2023) y descontar el tono general del día, una forma de tono anormal como la de Ardia et al. (2022). El encogimiento hacia el promedio (Efron y Morris, 1975; Carbó Casals, 2026) fue necesario porque en muchas ruedas el tono de una empresa se apoya en una o dos oraciones.

Pruebas múltiples y especificaciones previas. Se hicieron cientos de pruebas. Sin corrección, algunas habrían salido significativas por azar (Harvey et al., 2016; Harvey y Liu, 2020); con ella, la dirección noticias → mercado deja 4 de 152 pruebas, lo esperable por azar. Las dos especificaciones escritas antes de correr y la robustez con una decisión por vez responden a la advertencia de Nikolopoulos (2026) sobre la predictibilidad espuria que aparece al probar variantes hasta que una funciona. El único cambio posterior (la cantidad por día de calendario en U7b) quedó documentado con su motivo, y se informan las dos versiones.

En la región. Los trabajos que cruzan tono de medios y precios en Latinoamérica son pocos (Galdi y Gonçalves, 2018; Cruz Montaña y Tirado León, 2025) y ninguno es argentino. Las elecciones fueron, como en Calandroni (2026), los shocks de información más fuertes del período; y, como sugiere Amburgey (2025) para los sectores, el análisis por sector muestra que la dirección mercado → noticias aparece en casi todos, mientras que la contraria aparece de forma aislada (Conglomerado, con signo negativo).

Capítulo 7

Conclusiones

7.1 Respuesta a los objetivos

1. **Corpus de noticias.** Se construyó un corpus de 14.012 notas de siete portales argentinos, auditado y depurado de duplicados, publicaciones cruzadas, plantillas y contenido que no era noticia, y estructurado como serie temporal por portal, fecha y rueda bursátil. La regla de las 17:00 asignó cada nota a la primera rueda en la que el mercado pudo reaccionar a ella.
2. **Modelo de sentimiento.** FinBETO, un BETO con preentrenamiento continuado sobre el corpus y ajuste fino en cuatro clases, alcanzó un F1 macro de 0,685 sobre noticias no vistas, y de 0,724 frente a 0,546 del modelo de referencia en tres clases. La medición corrigió una fuga de información de la evaluación original, que la sobrestimaba.
3. **Trending topics de X/Twitter.** No se realizó: los datos no llegaron a integrarse al análisis.
4. **Variables de shock.** Se definieron y cuantificaron la atención anormal (volumetría de publicaciones), el tono anormal (temperatura del sentimiento), las ruedas de tono extremo, el tono propio de cada empresa a partir del reconocimiento de entidades, y el shock de cantidad con la definición literal del plan.
5. **Agrupamiento de empresas.** El clustering de las 47 acciones no encontró familias de comportamiento: el único grupo de tamaño real se explica por la baja liquidez de sus integrantes. La sensibilidad al flujo informativo se analizó por empresa y por sector.
6. **Relación con desfases.** Se modeló con VAR, causalidad de Granger, impulso-respuesta, análisis por régimen, una prueba con las notas publicadas con el mercado cerrado, dos estudios de eventos y doce variantes de robustez. El DLM previsto en el plan no se implementó; el VAR ya incorpora los efectos rezagados.

7.2 La hipótesis

La hipótesis H1 sostenía que el shock informativo tiene un impacto medible y significativo sobre el precio o el volumen de las acciones argentinas. **En su forma principal —que el tono de las noticias anticipe los precios— no se sostiene**: el tono no anticipó el retorno ni el volumen en el mercado, en las empresas, en los sectores ni en ningún régimen, ni siquiera con la prueba más favorable, que usa solo las notas publicadas antes de la apertura. Lo que apareció con claridad es la **relación inversa**: el retorno del S&P Merval anticipa el tono de las notas siguientes, en 39 de las 47 empresas y en 15 de las 17 con tono propio, y el efecto se concentra en las notas publicadas la misma noche, después del cierre. Los medios

económicos argentinos, en el período estudiado, contaron lo que el mercado ya había hecho.

Con la definición de shock del plan —muchas más notas que lo habitual— H1 encuentra un **apoyo parcial, en el volumen**: cuando una empresa aparece en muchas más notas, ese día su acción se opera más. Ese mayor volumen no viene con una dirección en el precio, no se arrastra a los días siguientes y no se anticipa con las notas de la noche. La cantidad de cobertura acompaña a la actividad del mercado, pero no la anticipa.

7.3 Aporte

El trabajo aporta el primer cruce, hasta donde se pudo relevar, entre el tono de la prensa económica argentina y el precio y el volumen de las acciones de BYMA; un conjunto de oraciones de prensa económica argentina etiquetadas por sentimiento; una medida de tono por empresa que descuenta el clima general; y un *pipeline* reproducible de punta a punta, con controles automáticos, especificaciones escritas antes de correr los análisis y corrección por pruebas múltiples.

7.4 Limitaciones

- **Un año de datos.** Con 224 ruedas en los modelos, un efecto chico de las noticias sobre los precios podría existir y no detectarse. El indicio de la prueba pre-apertura ($p \approx 0{,}1$) es compatible con un efecto chico o con ninguno.
- **Etiquetas de un modelo, no de personas.** El F1 mide el acuerdo de FinBETO con Gemma, no con un criterio humano, y no se hizo una validación con anotadores. El modelo que clasificó el corpus es el entrenado con la división original; la corrección se aplicó a la medición de su calidad, no al modelo.
- **Tono por empresa.** Es el tono de las oraciones que mencionan a la empresa, no una opinión sobre ella: una oración negativa sobre el sector que la nombra cuenta como negativa para ella. En muchas ruedas se apoya en una o dos oraciones.
- **Hora de publicación.** Es la que informa cada portal. El 13,4 % de las notas tiene horas por defecto; los resultados se repitieron sin ellas.
- **Datos diarios.** No permiten ordenar lo que pasa dentro de una misma rueda; la prueba pre-apertura es la aproximación más cercana. Algunas acciones argentinas cotizan también en Nueva York después del cierre local, y las notas de la noche pueden estar contando esos movimientos.
- **Pesos nominales.** Precios, retornos y montos incluyen inflación y tipo de cambio. Las variables anormales comparan con las 20 ruedas previas, lo que descuenta la tendencia lenta, pero no la elimina del todo.
- **Cobertura del corpus.** Depende de qué capturó la Wayback Machine y de la retención de los mapas del sitio; abril de 2026 tiene un hueco de recolección en iProfesional, el portal más grande.
- **Volatilidad simétrica.** El VIX argentino sube igual con una suba que con una caída,

mientras que la evidencia para el S&P Merval indica que las caídas pesan más (Otuki et al., 2008); y hereda el eco de la ventana de 20 ruedas, que también afecta a las fechas de los regímenes.

- **Pocos eventos de mercado.** Los estudios de eventos del mercado tienen entre 5 y 16 eventos, por lo que se apoyan en la comparación contra fechas al azar.

7.5 Líneas futuras

- **Validar el etiquetado con personas.** Una muestra chica etiquetada por anotadores alcanzaría para justificar estadísticamente el uso de Gemma como etiquetador (Calderon et al., 2025), y permitiría reentrenar FinBETO con los datos limpios y una división por fecha (Xue et al., 2026). Probar MarIA como modelo base es la alternativa natural (Gutiérrez-Fandiño et al., 2022; Pan et al., 2023).
- **Redes sociales.** Integrar los *trending topics* de X/Twitter, como preveía el plan, para validar los shocks que aparecen a la vez en medios y en redes (Yang et al., 2024; Wu et al., 2026).
- **Modelo de rezagos distribuidos.** Implementar el DLM del plan como complemento del VAR.
- **Análisis en dólares.** Repetir los modelos con precios en dólares contado con liquidación, para separar el efecto de las noticias del de la inflación y el tipo de cambio.
- **Precios intradiarios.** Con datos hora a hora se podría ordenar noticias y precios dentro de la rueda, la principal limitación de este trabajo.
- **Más información por nota.** Separar las noticias por tema (Chen, 2025), medir cuán central es cada empresa en la nota (Asgarieh et al., 2024) y ampliar el corpus con otras fuentes, como GDELT (Fronzetti Colladon y Vestrelli, 2026).
- **Volatilidad.** Reemplazar la media móvil de 20 ruedas por una media exponencial (J.P. Morgan y Reuters, 1996), que olvida los shocks de a poco en lugar de soltarlos de golpe.
- **Ventana más larga.** Con varios años de datos, que incluyan recesiones, se podría probar si el tono anticipa al mercado en los períodos de crisis, como encontró Garcia (2013).

Bibliografía

Referencias en estilo autor-año (APA), en orden alfabético. Debajo de cada una se indica el archivo PDF descargado, con su ruta dentro de la carpeta `tesis version 3.0`; en el PDF de la tesina la ruta es un enlace que abre el archivo. Los trabajos sin copia gratuita oficial se citan con su enlace y el motivo por el que no se descargaron.

Aguda, T., Siddagangappa, S., Kochkina, E., Kaur, S. et al. (2024). Large Language Models as Financial Data Annotators: A Study on Effectiveness and Efficiency. arXiv:2403.18152.
Archivo:
`Unión/11_papers_lado_noticias/sentimiento_2403.18152_LLM_anotadores_financieros.pdf`

Alexandre, M., Lopes de Moraes, K. y Rodrigues, F. A. (2021). Risk-dependent centrality in the Brazilian stock market. arXiv:2103.09059.
Archivo: `Lado Bursatil/02_clustering_acciones/papers/2021_Risk_centrality_Brasil.pdf`

Amburgey, A. J. (2025). How Election Shocks Impact Markets: Evidence from Sectoral Stock Prices. arXiv:2504.02731.
Archivo:
`Lado Bursatil/00_mapa_lado_bursatil/papers/2025_Election_shocks_sectoral_prices.pdf`

Araci, D. (2019). FinBERT: Financial Sentiment Analysis with Pre-trained Language Models. arXiv:1908.10063.
Archivo: `Unión/11_papers_lado_noticias/sentimiento_1908.10063_FinBERT.pdf`

Ardia, D., Bluteau, K. y Boudt, K. (2022). Media abnormal tone, earnings announcements, and the stock market. *Journal of Financial Markets*, 61, 100683. arXiv:2110.10800.
Archivo: `Unión/10_papers_union/U7_2110.10800_media_abnormal_tone_earnings.pdf`

Arratia, A. y Cabaña, A. (2013). Tracing the temporal evolution of clusters in a financial stock market. Computational Economics, 41, 213–231. arXiv:1111.3127.
Archivo: `Lado Bursatil/02_clustering_acciones/papers/2011_Temporal_evolution_clusters.pdf`

Asgarieh, E., Thadani, K. y O'Hare, N. (2024). Scalable Detection of Salient Entities in News Articles. arXiv:2405.20461.
Archivo: `Unión/11_papers_lado_noticias/ner_2405.20461_entidades_salientes_noticias.pdf`

Ataei, M. (2025). Modeling Regime Structure and Informational Drivers of Stock Market Volatility via the Financial Chaos Index. arXiv:2504.18958.
Archivo: `Lado Bursatil/06_hmm_regimen_mercado/papers/2025_Regime_structure_volatility.pdf`

Ataurima Arellano, M. (2016). Empirical Modeling of Latin American Stock Markets Returns and Volatility Using Markov-Switching GARCH Models. Tesis de maestría, Pontificia Universidad Católica del Perú.
Archivo: `Lado Bursatil/06_hmm_regimen_mercado/papers/2016_Ataurima_MS-GARCH_Latinoamerica_PUCP.pdf`

Barbaresi, A. (2021). Trafilatura: A Web Scraping Library and Command-Line Tool for Text Discovery and Extraction. En *Proceedings of the 59th Annual Meeting of the ACL and the 11th IJCNLP: System Demonstrations*, 122–131. `https://doi.org/10.18653/v1/2021.acl-demo.15`
Archivo: `Unión/11_papers_lado_noticias/noticias_Barbaresi_2021_trafilatura.pdf`

Benjamini, Y. y Hochberg, Y. (1995). Controlling the False Discovery Rate: A Practical and Powerful Approach to Multiple Testing. *Journal of the Royal Statistical Society: Series B*, 57(1), 289–300. `https://doi.org/10.1111/j.2517-6161.1995.tb02031.x`
No descargado: con derechos de autor y sin copia gratuita oficial.

Blake, A. C., Gandhi, N. A. y Jakkula, A. R. (2025). Improving S&P 500 Volatility Forecasting through Regime-Switching Methods. arXiv:2510.03236.

Archivo:
`Lado Bursatil/06_hmm_regimen_mercado/papers/2025_Regime_switching_SP500_volatility.pdf`

Braña, J. P., Litterio, A. M. J. y Fernández, A. (2016). Sentiment Analysis para la clasificación de noticias financieras en los Mercados Argentinos. Un modelo híbrido de POST enriquecido semánticamente. CAETI, Universidad Abierta Interamericana. Repositorio SEDICI-UNLP. `http://sedici.unlp.edu.ar/handle/10915/52945`
Archivo:
`Unión/10_papers_union/U2U3_Brana_Litterio_Fernandez_sentimiento_mercados_argentinos.pdf`

Brown, S. J. y Warner, J. B. (1985). Using daily stock returns: The case of event studies. *Journal of Financial Economics*, 14(1), 3–31.
No descargado: clásico citado en el documento de la entrega final; con derechos de autor.

Busca, J. y Thomir, L. (2023). Epps Effect and the Signature of Short-Term Momentum Traders. arXiv:2309.06711.
Archivo:
`Lado Bursatil/02_clustering_acciones/papers/2023_Epps_effect_momentum_traders.pdf`

Caballero Martínez, R. y Caballero Claure, B. (2016). Estimación de la volatilidad del tipo de cambio en México y Brasil. Un enfoque con modelos Markov Switching GARCH. Latin American Journal of Economic Development (LAJED), 25, 127–170.
Archivo: `Lado Bursatil/06_hmm_regimen_mercado/papers/2016_Caballero_MS-GARCH_tipo_de_cambio_Mexico_Brasil.pdf`

Calandroni, S. (2026). Impacto de las elecciones sobre el MERVAL (2011-2023). Tesis de maestría, Universidad Torcuato Di Tella.
Archivo: `Lado Bursatil/03_vix_argentino/papers/2026_Calandroni_elecciones_Merval_UTDT.pdf`

Calderon, N., Reichart, R. y Dror, R. (2025). The Alternative Annotator Test for LLM-as-a-Judge: How to Statistically Justify Replacing Human Annotators with LLMs. arXiv:2501.10970.
Archivo:
`Unión/11_papers_lado_noticias/sentimiento_2501.10970_alternative_annotator_test.pdf`

Cañete, J., Chaperon, G., Fuentes, R., Ho, J.-H. et al. (2020). Spanish Pre-trained BERT Model and Evaluation Data. En *PML4DC Workshop at ICLR 2020*. arXiv:2308.02976.
Archivo: `Unión/11_papers_lado_noticias/sentimiento_2308.02976_BETO.pdf`

Cao, Z., Wunkaew, W. y Geman, H. (2025). The Hype Index: an NLP-driven Measure of Market News Attention. arXiv:2506.06329.
Archivo: `Unión/10_papers_union/U4_2506.06329_hype_index_attention.pdf`

Carbó Casals, I. (2026). From Noisy News Sentiment Scores to Interpretable Temporal Dynamics: A Bayesian State-Space Model. arXiv:2601.16769.
Archivo: `Unión/10_papers_union/U2U4_2601.16769_noisy_sentiment_bayesian_state_space.pdf`

Chen, Q. (2025). A Framework for Measuring How News Topics Drive Stock Movement. arXiv:2510.06864.
Archivo: `Unión/10_papers_union/U3_2510.06864_news_topics_stock_movement.pdf`

Chniguir, M. y Henchiri, J. E. (2022). Causality between investor sentiment and the shares return on the Moroccan and Tunisian financial markets. *Revue du Contrôle, de la Comptabilité et de l'Audit*, 6(4), 350–364. arXiv:2305.16632.
Archivo: `Unión/10_papers_union/U6_2305.16632_sentiment_returns_Morocco_Tunisia.pdf`

Coronado, S., Martinez, J. N., Gualajara, V. y Rojas, O. (2022). Transfer Entropy Granger Causality between News Indices and Stock Markets in U.S. and Latin America during the COVID-19 Pandemic. *Entropy*, 24, 1420. `https://doi.org/10.3390/e24101420`
Archivo: `Unión/10_papers_union/U6_Entropy_2022_transfer_entropy_COVID_LatAm.pdf`

Coronado, S., Martinez, J. N., Gualajara, V., Romero-Meza, R. y Rojas, O. (2023). Time-Varying Granger Causality of COVID-19 News on Emerging Financial Markets: The Latin American Case. *Mathematics*, 11, 394. `https://doi.org/10.3390/math11020394`
Archivo: `Unión/10_papers_union/U6_MDPI_2023_Granger_variable_COVID_LatAm.pdf`

Correa Rocha, L. E. (2026). Stable Sentiment and Persistent Dynamics in U.S. Economic News over 45 Years. arXiv:2607.06220.
Archivo: Unión/10_papers_union/U5_2607.06220_stable_sentiment_persistence.pdf

Cruz Montaña, L. F. y Tirado León, L. F. (2025). Análisis de sentimientos en noticias financieras y su impacto en la bolsa de valores de Colombia – COLCAP. Universidad Ean, Seminario de Investigación de Especialización, Bogotá.
Archivo: Unión/10_papers_union/U6_CruzMontana_Tirado_2025_sentimiento_COLCAP.pdf

Da, Z., Engelberg, J. y Gao, P. (2011). In Search of Attention. *Journal of Finance*, 66(5), 1461–1499. https://doi.org/10.1111/j.1540-6261.2011.01679.x
No descargado: con derechos de autor y sin copia gratuita oficial.

Devlin, J., Chang, M.-W., Lee, K. y Toutanova, K. (2019). BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding. En *Proceedings of NAACL-HLT 2019*, 4171–4186. https://doi.org/10.18653/v1/N19-1423
No descargado: se cita a través del artículo de BETO.

Dickey, D. A. y Fuller, W. A. (1979). Distribution of the Estimators for Autoregressive Time Series with a Unit Root. Journal of the American Statistical Association, 74(366), 427–431. https://doi.org/10.2307/2286348
No descargado: acceso por suscripción (JSTOR). https://www.jstor.org/stable/2286348

Dodge, J., Sap, M., Marasović, A., Agnew, W. et al. (2021). Documenting Large Webtext Corpora: A Case Study on the Colossal Clean Crawled Corpus. arXiv:2104.08758.
Archivo: Unión/11_papers_lado_noticias/noticias_2104.08758_documentar_corpus_web_C4.pdf

Dougal, C., Engelberg, J., García, D. y Parsons, C. A. (2012). Journalists and the stock market. *The Review of Financial Studies*, 25(3), 639–679.
No descargado: clásico citado en el documento de la entrega final; con derechos de autor.

Efron, B. y Morris, C. (1975). Data Analysis Using Stein's Estimator and its Generalizations. *Journal of the American Statistical Association*, 70(350), 311–319. https://doi.org/10.1080/01621459.1975.10479864
No descargado: con derechos de autor y sin copia gratuita oficial.

Engelberg, J. E. y Parsons, C. A. (2011). The causal impact of media in financial markets. *The Journal of Finance*, 66(1), 67–97.
No descargado: clásico citado en el documento de la entrega final; con derechos de autor.

Fama, E. F. (1970). Efficient capital markets: A review of theory and empirical work. *The Journal of Finance*, 25(2), 383–417.
No descargado: clásico citado; con derechos de autor.

Fang, L. y Peress, J. (2009). Media Coverage and the Cross-Section of Stock Returns. *Journal of Finance*, 64(5), 2023–2052. https://doi.org/10.1111/j.1540-6261.2009.01493.x
No descargado: con derechos de autor y sin copia gratuita oficial.

Foley, M. (2026). WCXB: A Multi-Type Web Content Extraction Benchmark. arXiv:2605.21097.
Archivo: Unión/11_papers_lado_noticias/noticias_2605.21097_WCXB_extraccion_contenido.pdf

Fronzetti Colladon, A. y Vestrelli, R. (2026). Free Access to World News: Reconstructing Full-Text Articles from GDELT. *Big Data and Cognitive Computing*, 10(2), 45. https://doi.org/10.3390/bdcc10020045 arXiv:2504.16063.
Archivo: Unión/11_papers_lado_noticias/noticias_2504.16063_GDELT_texto_completo.pdf

Galdi, F. C. y Gonçalves, A. M. (2018). Pessimismo e incerteza das notícias e o comportamento dos investidores no Brasil. *RAE-Revista de Administração de Empresas*, 58(2), 130–148. https://doi.org/10.1590/S0034-759020180203
Archivo: Unión/10_papers_union/U6_Galdi_Goncalves_2018_RAE_pesimismo_noticias_Brasil.pdf

Garcia, D. (2013). Sentiment during Recessions. *Journal of Finance*, 68(3), 1267–1300. https://doi.org/10.1111/jofi.12027
Archivo: Unión/10_papers_union/00_marco_Garcia_2013_sentiment_recessions.pdf

García-Díaz, J. A., García-Sánchez, F. y Valencia-García, R. (2023). Smart Analysis of Economics

Sentiment in Spanish Based on Linguistic Features and Transformers. *IEEE Access*, 11, 14211–14224. https://doi.org/10.1109/ACCESS.2023.3244065
No descargado: de acceso abierto, pero sin enlace directo al PDF; se baja a mano desde IEEE Xplore.

Garg, K., Alam, S., Ayala, D., Graham, M. et al. (2025). Longitudinal Sampling of URLs From the Wayback Machine. arXiv:2507.14752.
Archivo: Unión/11_papers_lado_noticias/noticias_2507.14752_wayback_machine_sampling.pdf

Gemma Team, Google DeepMind (2026). Gemma 4 Technical Report. arXiv:2607.02770.
Archivo: Unión/11_papers_lado_noticias/sentimiento_2607.02770_Gemma4.pdf

Ghosh, D. (2025). Polyspectral Mean based Time Series Clustering of Indian Stock Market. Discover Data, 3, 10. arXiv:2504.07021.
Archivo: Lado Bursatil/02_clustering_acciones/papers/2025_Kmeans_49_stocks_India.pdf

Gilardi, F., Alizadeh, M. y Kubli, M. (2023). ChatGPT Outperforms Crowd-Workers for Text-Annotation Tasks. *Proceedings of the National Academy of Sciences*, 120(30). arXiv:2303.15056.
Archivo: Unión/11_papers_lado_noticias/sentimiento_2303.15056_ChatGPT_anotador.pdf

Glasserman, P., Krstovski, K., Laliberte, P. y Mamaysky, H. (2025). Does Overnight News Explain Overnight Returns?. arXiv:2507.04481.
Archivo: Unión/10_papers_union/U6b_2507.04481_overnight_news_overnight_returns.pdf

Golde, J., Haller, P. y Akbik, A. (2025). FiNERweb: Datasets and Artifacts for Scalable Multilingual Named Entity Recognition. arXiv:2512.13884.
Archivo: Unión/11_papers_lado_noticias/ner_2512.13884_FiNERweb.pdf

Granger, C. W. J. (1969). Investigating Causal Relations by Econometric Models and Cross-spectral Methods. *Econometrica*, 37(3), 424–438. https://doi.org/10.2307/1912791
No descargado: con derechos de autor y sin copia gratuita oficial.

Guo, L., Peng, L., Tao, Y. y Tu, J. (2017). Joint News, Attention Spillover, and Stock Returns. arXiv:1703.02715.
Archivo: Unión/10_papers_union/U7_1703.02715_joint_news_attention_spillover.pdf

Gururangan, S., Marasović, A., Swayamdipta, S., Lo, K. et al. (2020). Don't Stop Pretraining: Adapt Language Models to Domains and Tasks. En *Proceedings of ACL 2020*. arXiv:2004.10964.
Archivo: Unión/11_papers_lado_noticias/sentimiento_2004.10964_dont_stop_pretraining.pdf

Gutiérrez-Fandiño, A., Armengol-Estapé, J., Pàmies, M., Llop-Palao, J. et al. (2022). MarIA: Spanish Language Models. *Procesamiento del Lenguaje Natural*, 68, 39–60. arXiv:2107.07253.
Archivo: Unión/11_papers_lado_noticias/sentimiento_2107.07253_MarIA.pdf

Hamilton, J. D. (1989). A New Approach to the Economic Analysis of Nonstationary Time Series and the Business Cycle. Econometrica, 57(2), 357–384.
No descargado: acceso por suscripción (JSTOR / Econometric Society).
https://ideas.repec.org/a/ecm/emetrp/v57y1989i2p357-84.html

Harvey, C. R., Liu, Y. y Zhu, H. (2016). … and the Cross-Section of Expected Returns. *Review of Financial Studies*, 29(1), 5–68. https://doi.org/10.1093/rfs/hhv059
No descargado: con derechos de autor y sin copia gratuita oficial.

Harvey, C. R. y Liu, Y. (2020). False (and Missed) Discoveries in Financial Economics. arXiv:2006.04269.
Archivo: Unión/10_papers_union/U6U8_2006.04269_false_missed_discoveries.pdf

Hatwar, S., Partridge, V., Bhargava, R. y Bermejo, F. (2024). Author Unknown: Evaluating Performance of Author Extraction Libraries on Global Online News Articles. arXiv:2410.19771.
Archivo: Unión/11_papers_lado_noticias/noticias_2410.19771_extraccion_autor_noticias.pdf

Honnibal, M., Montani, I., Van Landeghem, S. y Boyd, A. (2020). spaCy: Industrial-strength Natural Language Processing in Python. Zenodo. https://doi.org/10.5281/zenodo.1212303
No descargado: es software; se cita como herramienta.

Huth, N. y Abergel, F. (2011). High Frequency Lead/lag Relationships — Empirical facts. arXiv:1111.7103.
Archivo: Lado Bursatil/02_clustering_acciones/papers/2011_Lead_lag_relationships.pdf

J.P. Morgan y Reuters (1996). RiskMetrics — Technical Document (4.ª edición). Nueva York: J.P. Morgan.
Archivo: Lado Bursatil/03_vix_argentino/papers/1996_RiskMetrics_Technical_Document.pdf

Jain, D., Patel, M., Narsaria, A. y Malik, S. (2020). A Study on the Efficiency of the Indian Stock Market. arXiv:2012.01160.
Archivo: Lado Bursatil/04_adf/papers/2020_Efficiency_Indian_stock_market.pdf

Jazbec, M., Pàsztor, B., Faltings, F., Antulov-Fantulin, N. et al. (2020). On the impact of publicly available news and information transfer to financial markets. arXiv:2010.12002.
Archivo: Unión/10_papers_union/U6_2010.12002_public_news_information_transfer.pdf

Kalnina, I. y Tewou, K. (2024). Cross-sectional Dependence in Idiosyncratic Volatility. arXiv:2408.13437.
Archivo:
Lado Bursatil/05_volatilidad_ranking/papers/2024_Idiosyncratic_volatility_dependence.pdf

Kapoor, S. y Narayanan, A. (2023). Leakage and the Reproducibility Crisis in Machine-learning-based Science. *Patterns*, 4(9). arXiv:2207.07048.
Archivo:
Unión/11_papers_lado_noticias/sentimiento_2207.07048_leakage_reproducibilidad.pdf

Kargarzadeh, A., Khaledian, N., Parvini, N., Ghatak, S. et al. (2026). Buy the Rumor, Sell the News: When Is News Priced In?. arXiv:2608.14014.
Archivo: Unión/10_papers_union/U7_2608.14014_buy_rumor_sell_news.pdf

Kim, C.-J. (1994). Dynamic linear models with Markov-switching. Journal of Econometrics, 60(1–2), 1–22.
No descargado: acceso por suscripción (Elsevier).
https://ideas.repec.org/a/eee/econom/v60y1994i1-2p1-22.html

Knuteson, B. (2020). Strikingly Suspicious Overnight and Intraday Returns. arXiv:2010.01727.
Archivo: Unión/10_papers_union/U6b_2010.01727_overnight_intraday_returns.pdf

Kulikova, M. V., Taylor, D. R. y Kulikov, G. Yu. (2024). Evolving efficiency of the BRICS markets. Economic Systems, 48(1), 101166. arXiv:2403.05233.
Archivo: Lado Bursatil/04_adf/papers/2024_Evolving_efficiency_BRICS.pdf

Kwiatkowski, D., Phillips, P. C. B., Schmidt, P. y Shin, Y. (1992). Testing the null hypothesis of stationarity against the alternative of a unit root. *Journal of Econometrics*, 54, 159–178.
https://doi.org/10.1016/0304-4076(92)90104-Y
No descargado: con derechos de autor y sin copia gratuita oficial.

Larre, T. F. y Auza, J. (2019). Modelización financiera mediante modelos híbridos Arima–Garch: evidencia para Argentina. Ciencias Económicas (UNL), 16(2), 29–45.
Archivo: Lado Bursatil/03_vix_argentino/papers/2019_Larre_Auza_ARIMA-GARCH_Merval_UNL.pdf

Lee, K., Ippolito, D., Nystrom, A., Zhang, C. et al. (2021). Deduplicating Training Data Makes Language Models Better. arXiv:2107.06499.
Archivo: Unión/11_papers_lado_noticias/noticias_2107.06499_deduplicacion.pdf

Lesmond, D. A., Ogden, J. P. y Trzcinka, C. A. (1999). A New Estimate of Transaction Costs. Review of Financial Studies, 12(5), 1113–1141.
No descargado: acceso por suscripción (Oxford University Press / JSTOR).
https://ideas.repec.org/a/oup/rfinst/v12y1999i5p1113-41.html

Lo, A. W. y MacKinlay, A. C. (1990). An econometric analysis of nonsynchronous trading. Journal of Econometrics, 45(1–2), 181–211.
No descargado: acceso por suscripción (Elsevier); la versión de trabajo del MIT bloquea la descarga automática. https://www.nber.org/papers/w2960

Loughran, T. y McDonald, B. (2011). When Is a Liability Not a Liability? Textual Analysis,

Dictionaries, and 10-Ks. *Journal of Finance*, 66(1), 35–65.
https://doi.org/10.1111/j.1540-6261.2010.01625.x
No descargado: con derechos de autor y sin copia gratuita oficial.

Lütkepohl, H. (2005). New Introduction to Multiple Time Series Analysis. Springer.
No descargado: con derechos de autor y sin copia gratuita oficial.

MacKinlay, A. C. (1997). Event Studies in Economics and Finance. *Journal of Economic Literature*, 35(1), 13–39.
No descargado: con derechos de autor y sin copia gratuita oficial.

Majumder, R., Ji, Q. y Neerchal, N. K. (2023). Optimal Stock Portfolio Selection with a Multivariate Hidden Markov Model. Sankhya B, 85 (Suppl 1), 177–198. arXiv:2406.02297.
Archivo: Lado Bursatil/06_hmm_regimen_mercado/papers/2024_Multivariate_HMM_bull_bear.pdf

Malafeyev, O., Awasthi, A. y Kambekar, K. S. (2017). Random walks and market efficiency in Chinese and Indian equity markets. arXiv:1709.04059.
Archivo: Lado Bursatil/04_adf/papers/2017_Random_walks_China_India.pdf

Malo, P., Sinha, A., Takala, P., Korhonen, P. y Wallenius, J. (2014). Good Debt or Bad Debt: Detecting Semantic Orientations in Economic Texts. *Journal of the Association for Information Science and Technology*, 65(4), 782–796. arXiv:1307.5336.
Archivo: Unión/11_papers_lado_noticias/sentimiento_1307.5336_Financial_PhraseBank.pdf

Mantegna, R. N. (1999). Hierarchical Structure in Financial Markets. European Physical Journal B, 11, 193–197. arXiv:cond-mat/9802256.
Archivo:
Lado Bursatil/02_clustering_acciones/papers/1999_Mantegna_hierarchical_structure.pdf

Marín, M. J., Valencia-García, R., García-Díaz, J. A., Almela Sánchez-Lafuente, Á., García-Sánchez, F. y Alcaraz Mármol, G. (2023). Overview of FinancES 2023: Financial Targeted Sentiment Analysis in Spanish. *Procesamiento del Lenguaje Natural*, 71, 417–423.
No descargado: no se encontró un PDF directo.

Marti, G., Nielsen, F., Bińkowski, M. y Donnat, P. (2021). A review of two decades of correlations, hierarchies, networks and clustering in financial markets. En Progress in Information Geometry, 245–274. arXiv:1703.00485.
Archivo: Lado Bursatil/02_clustering_acciones/papers/2017_Marti_review_correlations_clustering.pdf

Mavillonio, M. S., Borgioli, S., Giannetti, C., Ongari, C. et al. (2026). Measuring Sentiment News with Transformer-Based Language Models. arXiv:2607.13968.
Archivo: Unión/10_papers_union/U2_2607.13968_sentiment_news_transformers.pdf

Medina Pérez, A. (2013). Comprobación de la existencia de la caminata aleatoria en los principales mercados de valores latinoamericanos. Trabajo de grado, Universidad Industrial de Santander (Colombia).
Archivo: Lado Bursatil/04_adf/papers/2013_Medina_caminata_aleatoria_Latinoamerica_UIS.pdf

Mukherjee, T. (2025). Investor Sentiment and Market Movements: A Granger Causality Perspective. arXiv:2510.15915.
Archivo: Lado Bursatil/00_mapa_lado_bursatil/papers/2025_Investor_sentiment_Granger.pdf; Unión/10_papers_union/U6_2510.15915_investor_sentiment_granger.pdf

Nanyonga, E., Kasozi, J., Mayambala, F., Kayondo, H. W. y Davison, M. (2025). A Stochastic Model for Illiquid Stock Prices and its Conclusion about Correlation Measurement. Research in Mathematics, 13(1), 2026. arXiv:2509.10553.
Archivo:
Lado Bursatil/01_scraping_acciones/papers/2025_Illiquid_stock_prices_correlation.pdf

Nikolopoulos, S. D. (2026). Spurious Predictability in Financial Machine Learning. arXiv:2604.15531.
Archivo: Unión/10_papers_union/U8_2604.15531_spurious_predictability.pdf

Onnela, J.-P., Chakraborti, A., Kaski, K. y Kertész, J. (2003). Dynamic asset trees and Black Monday. Physica A, 324, 247. arXiv:cond-mat/0212037.
Archivo: Lado Bursatil/02_clustering_acciones/papers/2003_Onnela_dynamic_asset_trees.pdf

Otuki, T. F., Radavelli, C. H., Seabra, F. y da Costa Jr., N. C. A. (2008). Assimetria na volatilidade dos retornos revisitada: Ibovespa, Merval e Inmex. Revista de Gestão USP, 15(4), 71–84.
Archivo: Lado Bursatil/03_vix_argentino/papers/2008_Otuki_asimetria_volatilidad_Ibovespa_Merval_Inmex.pdf

Pan, R., García-Díaz, J. A., García-Sánchez, F. y Valencia-García, R. (2023). Evaluation of transformer models for financial targeted sentiment analysis in Spanish. *PeerJ Computer Science*, 9, e1377. https://doi.org/10.7717/peerj-cs.1377
No descargado: de acceso abierto, pero el sitio bloquea la descarga automática; se baja a mano desde https://peerj.com/articles/cs-1377.

Papaioannou, G., Papaioannou, P. y Parliaris, N. (2014). Modeling the stylized facts of wholesale system marginal price (SMP) and the impacts of regulatory reforms on the Greek Electricity Market. arXiv:1401.5452.
Archivo: Lado Bursatil/03_vix_argentino/papers/2014_Ghost_features_moving_average.pdf

Pérez, J. M., Rajngewerc, M., Giudici, J. C., Furman, D. A. et al. (2021). pysentimiento: A Python Toolkit for Opinion Mining and Social NLP tasks. arXiv:2106.09462.
Archivo: Unión/11_papers_lado_noticias/sentimiento_2106.09462_pysentimiento.pdf

Pharasi, H. K., Seligman, E. y Seligman, T. H. (2020). Market states: A new understanding. arXiv:2003.07058.
Archivo: Lado Bursatil/02_clustering_acciones/papers/2020_Market_states_UNAM.pdf

Rabiner, L. R. (1989). A Tutorial on Hidden Markov Models and Selected Applications in Speech Recognition. *Proceedings of the IEEE*, 77(2), 257–286. https://doi.org/10.1109/5.18626
No descargado: con derechos de autor y sin copia gratuita oficial.

Ramírez-Carrillo, G., Ortiz-Mora, D. y Aguilar-Larrotta, A. (2025). Hierarchical Risk Parity for Portfolio Allocation in the Latin American NUAM Market. arXiv:2509.03712.
Archivo: Lado Bursatil/02_clustering_acciones/papers/2025_HRP_NUAM_Latinoamerica.pdf

Rocha Filho, T. M. y Rocha, P. M. M. (2019). Inefficiency of the Brazilian Stock Market: the IBOVESPA Future Contracts. arXiv:1904.09214.
Archivo: Lado Bursatil/04_adf/papers/2019_Inefficiency_Brazilian_market.pdf

Rodríguez-García, M. Á., Riaño-Martínez, A., Roldán-Álvarez, D. y Montalvo-Herranz, S. (2023). URJC-Team at FinancES 2023: Financial Targeted Sentiment Analysis in Spanish Combining Transformers. En *CEUR Workshop Proceedings*, vol. 3496.
https://ceur-ws.org/Vol-3496/finances-paper5.pdf
Archivo: Unión/10_papers_union/U2_CEUR_3496_BETO_opiniones_financieras.pdf

Rojas, E. y Kristjanpoller, W. (2015). Relación precio-volumen mediante análisis de causalidad y efecto día de semana en los mercados accionarios latinoamericanos. *Lecturas de Economía*, n.º 83, 9–31. http://www.redalyc.org/articulo.oa?id=155240414001
Archivo: Unión/10_papers_union/U4U6_redalyc_retorno_volumen_LatAm.pdf

Rousseeuw, P. J. (1987). Silhouettes: a graphical aid to the interpretation and validation of cluster analysis. Journal of Computational and Applied Mathematics, 20, 53–65.
No descargado: acceso por suscripción (Elsevier).
https://ftp.math.utah.edu/pub/tex/bib/idx/jcomputapplmath1980/20/z/53_65.html

Sakowski, P., Sieradzki, R. y Ślepaczuk, R. (2023). Systemic risk indicator based on implied and realized volatility. arXiv:2307.05719.
Archivo:
Lado Bursatil/03_vix_argentino/papers/2023_Implied_realized_volatility_systemic_risk.pdf

Schwarz, G. (1978). Estimating the Dimension of a Model. Annals of Statistics, 6(2), 461–464.
https://doi.org/10.1214/aos/1176344136
No descargado: es de acceso libre en Project Euclid, pero el sitio bloquea la descarga automática (se puede bajar a mano). https://www.projecteuclid.org/euclid.aos/1176344136

Seabold, S. y Perktold, J. (2010). Statsmodels: Econometric and statistical modeling with Python. *Proceedings of the 9th Python in Science Conference*, 92–96.
No descargado: software usado en todos los modelos; se cita como herramienta.

Segovia, M. y Favata, F. (2022a). Estimación del Valor a Riesgo del mercado accionario argentino mediante modelos GARCH. Revista de la Facultad de Ciencias Económicas (UNNE), 29(2), 7–27. https://doi.org/10.30972/rfce.2926286
Archivo: Lado Bursatil/03_vix_argentino/papers/2022_Segovia_Favata_VaR_GARCH_Argentina.pdf

Segovia, M. y Favata, F. (2022b). Estimación del Valor a Riesgo del mercado accionario argentino mediante modelos GARCH. Anales de la Asociación Argentina de Economía Política, documento 4562.
Archivo: Lado Bursatil/03_vix_argentino/papers/2022_AAEP_4562_VaR_GARCH_Argentina_wp.pdf

Shiffler, R. E. (1988). Maximum Z scores and outliers. *The American Statistician*, 42(1), 79–80.
No descargado: citado en el documento de la entrega final; con derechos de autor.

Sims, C. A. (1980). Macroeconomics and Reality. *Econometrica*, 48(1), 1–48. https://doi.org/10.2307/1912017
No descargado: con derechos de autor y sin copia gratuita oficial.

Sinha, A., Kedas, S., Kumar, R. y Malo, P. (2023). SEntFiN 1.0: Entity-Aware Sentiment Analysis for Financial News. arXiv:2305.12257.
Archivo: Unión/10_papers_union/U3_2305.12257_SEntFiN.pdf

Stan, S., Lunghi, M., Vargetto, V., Ricci, C. et al. (2026). Causal Reconstruction of Sentiment Signals from Sparse News Data. arXiv:2603.23568.
Archivo: Unión/10_papers_union/U2_2603.23568_sentiment_sparse_news.pdf

Tang, Y., Yang, Y., Huang, A. H., Tam, A. et al. (2023). FinEntity: Entity-level Sentiment Classification for Financial Texts. arXiv:2310.12406.
Archivo: Unión/10_papers_union/U3_2310.12406_FinEntity.pdf

Tetlock, P. C. (2007). Giving Content to Investor Sentiment: The Role of Media in the Stock Market. *Journal of Finance*, 62(3), 1139–1168. https://doi.org/10.1111/j.1540-6261.2007.01232.x
Archivo: Unión/10_papers_union/00_marco_Tetlock_2007_media_sentiment.pdf

Tjong Kim Sang, E. F. (2002). Introduction to the CoNLL-2002 Shared Task: Language-Independent Named Entity Recognition. En *Proceedings of CoNLL-2002*. https://aclanthology.org/W02-2024
Archivo: Unión/11_papers_lado_noticias/ner_TjongKimSang_2002_CoNLL_NER_espanol.pdf

Ujiie, S., Iso, H., Yada, S., Wakamiya, S. et al. (2021). End-to-end Biomedical Entity Linking with Span-based Dictionary Matching. arXiv:2104.10493.
Archivo: Unión/11_papers_lado_noticias/ner_2104.10493_dictionary_matching.pdf

Verma, S., Tulsyan, S., Dhanuka, S. y Sen, A. (2026). Quantitative Analysis of Media Bias and Stock Price Dynamics: The 2020 Shock. arXiv:2608.05899.
Archivo: Lado Bursatil/00_mapa_lado_bursatil/papers/2026_Media_bias_stock_prices.pdf; Unión/10_papers_union/U6_2608.05899_media_bias_stock_prices_2020.pdf

Wirth, R. y Hipp, J. (2000). CRISP-DM: Towards a Standard Process Model for Data Mining. En *Proceedings of the 4th International Conference on the Practical Applications of Knowledge Discovery and Data Mining*, 29–39.
No descargado: no se localizó una copia oficial.

Worthington, A. y Higgs, H. (2003). An empirical note on the random walk behaviour and market efficiency of Latin American stock markets. Empirical Economics Letters, 2(5), 183–197.
No descargado: el repositorio no ofrece el PDF de forma pública.
https://ro.uow.edu.au/commpapers/298

Wu, F., Liu, A., Chen, J., Li, Y. et al. (2026). Do News and Social Media Tell the Same Story? Constructing and Comparing Sentiment Spillover Networks. arXiv:2604.26811.
Archivo: Unión/10_papers_union/U6_2604.26811_news_vs_social_media_spillover.pdf

Xenofontos, A. (2014). Modelling and Forecasting Volatility of Stock Index Return Using GARCH Models: an Empirical Evidence of Argentina. Tesis de maestría, University of Nottingham.
No descargado: acceso restringido a usuarios de la University of Nottingham.
`https://eprints.nottingham.ac.uk/27379`

Xue, C., Guesmi, R., Feng, S., Gong, Y. et al. (2026). Temporal Leakage in Financial News NLP: A Multi-Architecture Audit with a Regime-Specific M&A Signal. arXiv:2608.17223.
Archivo: `Unión/11_papers_lado_noticias/sentimiento_2608.17223_temporal_leakage_noticias_financieras.pdf`

Yang, N., Fernández-Pérez, A. y Indriawan, I. (2024). Spillover between investor sentiment and volatility: The role of social media. *International Review of Financial Analysis*, 96, 103643.
No descargado: con derechos de autor y sin copia gratuita oficial.

Zablotsky, E. E. (2002). Consideraciones sobre la eficiencia del mercado de capitales argentino. Documento de trabajo 213, Universidad del CEMA.
Archivo: `Lado Bursatil/04_adf/papers/2002_Zablotsky_eficiencia_mercado_argentino.pdf`

Anexo A

Panel de acciones

Las 47 acciones del panel, ordenadas por sector. «Merval» indica si integra el S&P Merval; «Volumen» es el porcentaje de ruedas con operaciones en los tres años; «Volatilidad» es la volatilidad realizada promedio entre el 2/1/2025 y el 30/4/2026; «Ruedas con noticias» cuenta las ruedas de la unión en que al menos una oración la menciona; «Tono propio» indica si tiene noticias suficientes (90 ruedas o más) para medirlo. Se citan en la sección 3.3.

Ticker	Empresa	Sector	Merval	Volumen (%)	Volatilidad (%)	Ruedas con noticias	Tono propio
CVH	Cablevision Holding	Comunicaciones	Sí	100,0	39,3	8	No
TECO2	Telecom Argentina	Comunicaciones	Sí	100,0	52,2	52	No
COME	Sociedad Comercial del Plata	Conglomerado	Sí	100,0	68,3	74	No
CRES	Cresud	Conglomerado	Sí	100,0	41,3	163	Sí
GARO	Garovaglio y Zorraquín	Conglomerado	No	97,0	70,5	1	No
GRIM	Grimoldi	Consumo	No	96,9	54,8	20	No
HAVA	Havanna Holding	Consumo	No	100,0	38,7	29	No
LEDE	Ledesma	Consumo	No	100,0	41,6	11	No
LONG	Longvie	Consumo	No	100,0	47,2	0	No
MIRG	Mirgor	Consumo	Sí	100,0	36,2	27	No
MOLI	Molinos Río de la Plata	Consumo	No	100,0	58,5	13	No
MORI	Morixe Hermanos	Consumo	No	100,0	62,9	7	No
SAMI	San Miguel	Consumo	No	100,0	64,7	2	No
SEMI	Molinos Juan Semino	Consumo	No	100,0	55,2	1	No
CAPX	CAPEX SA	Energía	No	100,0	52,8	0	No
TGNO4	Transportadora de Gas del Norte	Energía	Sí	100,0	61,7	75	No
TGSU2	Transportadora de Gas del Sur	Energía	Sí	100,0	53,8	189	Sí
YPFD	YPF SA	Energía	Sí	100,0	44,9	237	Sí
BBAR	BBVA Banco Francés	Financiero	Sí	100,0	65,9	229	Sí
BHIP	Banco Hipotecario	Financiero	No	100,0	66,4	47	No
BMA	Banco Macro	Financiero	Sí	100,0	60,9	184	Sí
BPAT	Banco Patagonia	Financiero	No	100,0	60,9	56	No
BYMA	Bolsas y Mercados Argentinos	Financiero	Sí	100,0	46,7	141	Sí

Ticker	Empresa	Sector	Merval	Volumen (%)	Volatilidad (%)	Ruedas con noticias	Tono propio
GGAL	Grupo Financiero Galicia	Financiero	Sí	100,0	55,8	195	Sí
SUPV	Supervielle	Financiero	Sí	100,0	74,4	223	Sí
VALO	Banco de Valores	Financiero	Sí	100,0	40,2	50	No
AGRO	Agrometal	Industrial	No	100,0	64,3	2	No
AUSO	Autopistas del Sol	Industrial	No	100,0	55,0	7	No
OEST	Grupo Concesionario del Oeste	Industrial	No	99,7	46,9	1	No
ALUA	Aluar	Materiales	Sí	100,0	50,2	94	Sí
CELU	Celulosa Argentina	Materiales	No	100,0	104,6	13	No
FIPL	Fiplasto	Materiales	No	99,9	41,3	0	No
LOMA	Loma Negra	Materiales	No	100,0	51,2	175	Sí
RIGO	Rigolleau	Materiales	No	95,8	58,1	4	No
TXAR	Ternium Argentina	Materiales	Sí	100,0	48,1	105	Sí
CTIO	Consultatio	Real Estate	No	100,0	37,5	38	No
GCDI	GCDI S.A. (ex TGLT)	Real Estate	No	94,9	46,2	1	No
IRSA	IRSA Inversiones y Representaciones	Real Estate	No	100,0	43,7	186	Sí
BOLT	Boldt	Tecnología	No	99,7	44,1	1	No
CEPU	Central Puerto	Utilities	Sí	100,0	53,7	193	Sí
CGPA2	Camuzzi Gas Pampeana	Utilities	No	100,0	67,5	21	No
DGCU2	Distribuidora de Gas Cuyana	Utilities	No	100,0	55,2	5	No
EDN	Edenor	Utilities	Sí	100,0	65,5	213	Sí
GBAN	Naturgy BAN	Utilities	No	100,0	58,0	4	No
METR	MetroGas	Utilities	No	100,0	73,6	112	Sí
PAMP	Pampa Energía	Utilities	Sí	100,0	44,5	164	Sí
TRAN	Transener	Utilities	Sí	100,0	65,9	116	Sí

Tabla A.1. Panel de 47 acciones. Fuente: elaboración propia (`Lado Bursatil/01_scraping_acciones`, `05_volatilidad_ranking` y `Unión/03_sentimiento_por_empresa`).

Anexo B

Diccionario de variables

Columnas de los dos datasets de la unión: `dataset_mercado.csv` (una fila por rueda) y `dataset_panel.csv` (una fila por acción y rueda). «Tabla» indica en cuál está cada variable; «ambos», que está en las dos. El archivo original es `Unión/04_dataset_unificado/diccionario_variables.csv`.

Variable	Tabla	Qué es	Unidad	De dónde sale
`rueda`	ambos	Día de bolsa (BYMA)	fecha	Lado `Bursatil/03_vix_argentino` (calendario de ^MERV)
`merv_cierre`	mercado	Cierre del índice Merval	puntos	Lado `Bursatil/03_vix_argentino`
`ret_merval`	ambos	Retorno diario del Merval	proporción (0,01 = 1 %)	Lado `Bursatil/03_vix_argentino`
`vix_arg`	ambos	VIX argentino: volatilidad realizada de 20 ruedas, anualizada	%	Lado `Bursatil/03_vix_argentino`
`regimen`	ambos	Régimen de mercado (HMM, probabilidades suavizadas): Calmo, Moderado o Tenso	categoría	Lado `Bursatil/06_hmm_regimen_mercado`
`regimen_filtrado`	ambos	Régimen con probabilidades filtradas (solo usa información hasta ese día)	categoría	Lado `Bursatil/06_hmm_regimen_mercado`
`prob_tenso`	ambos	Probabilidad suavizada del régimen Tenso	0 a 1	Lado `Bursatil/06_hmm_regimen_mercado`
`prob_tenso_filtrada`	mercado	Probabilidad filtrada del régimen Tenso	0 a 1	Lado `Bursatil/06_hmm_regimen_mercado`
`monto_operado`	mercado	Cierre × volumen, sumado sobre las 47 acciones	pesos	Lado `Bursatil/01_scraping_acciones` (U4)
`monto_anormal`	mercado	log(monto) − promedio de log(monto) de las 20 ruedas previas	log (0 = habitual)	U4
`n_notas`	ambos	Notas que recibe la rueda (regla de las 17:00)	notas	U1
`dias_cubiertos`	mercado	Días de calendario que junta la rueda (1 normal, 3 un lunes, 4+ tras feriado)	días	U2
`atencion_anormal`	ambos	Atención de los medios: notas comparadas con lo habitual para ese tipo de rueda y las 20 previas	log (0 = habitual)	U2

Variable	Tabla	Qué es	Unidad	De dónde sale
sent_neto	ambos	Tono de las noticias: promedio del sentimiento neto de las notas de la rueda	puntos (−100 a +100)	U2 (sentimiento de Gino)
sent_neto_portal	ambos	Tono ajustado por portal (a cada nota se le resta el promedio de su portal)	puntos	U2
sent_anormal	ambos	Tono anormal: tono de la rueda − promedio del tono de las 20 ruedas previas. Variable de tono del VAR	puntos (0 = habitual)	U4 (decisión de U5)
sent_portal_anormal	ambos	Lo mismo con el tono ajustado por portal	puntos (0 = habitual)	U4 (decisión de U5)
pct_pos, pct_neg, pct_neu, pct_mixto	mercado	Porcentaje promedio de oraciones de cada clase en las notas de la rueda	%	U2
z_shock	mercado	Distancia del tono a lo habitual, en veces el error esperable por la cantidad de notas	veces	U2
shock, shock_pos, shock_neg	ambos	Rueda de tono extremo (|z| > 2,5), total, positiva y negativa	0/1	U2
evento_id	ambos	Número de evento (shocks del mismo signo en ruedas seguidas = un evento); 0 si no hay	número	U2
dia_electoral	ambos	Rueda posterior a una elección (08/09/2025 y 27/10/2025)	texto	U2
eco_electoral	ambos	Rueda dentro de las 20 posteriores a un día electoral (eco en el VIX y el régimen)	0/1	U4
abril_2026	ambos	Rueda de abril de 2026 (hueco de iProfesional en el corpus)	0/1	U4
ticker, empresa, sector, oficial	panel	Identificación de la acción; oficial = está en el S&P Merval	texto	Lado Bursatil/01_scraping_acciones
grupo_baja_liquidez	panel	Integra el grupo de 8 del clustering, explicado por baja liquidez	0/1	Lado Bursatil/02_clustering_acciones
cuatro_iliquidas	panel	Es una de las 4 acciones con más días sin operar (GCDI, RIGO, GRIM, GARO)	0/1	Lado Bursatil/02_clustering_acciones
cierre	panel	Precio de cierre ajustado	pesos	Lado Bursatil/01_scraping_acciones
retorno	panel	Retorno diario de la acción (pct_change sobre la serie completa)	proporción	U4 (misma definición que la carpeta 04)
volumen	panel	Acciones operadas en la rueda	acciones	Lado Bursatil/01_scraping_acciones
monto	panel	Cierre × volumen	pesos	U4

Variable	Tabla	Qué es	Unidad	De dónde sale
vol_anormal	panel	log(1 + volumen) − promedio de log(1 + volumen) de las 20 ruedas previas	log (0 = habitual)	U4
sin_operar	panel	La acción no operó (volumen 0)	0/1	U4
precio_quieto	panel	El cierre es igual al de la rueda anterior	0/1	U4
hubo_noticia	panel	Al menos una oración de las notas de la rueda menciona a la empresa	0/1	U3
sentimiento_propio	panel	La empresa tiene noticias en al menos 90 ruedas y usa su propio sentimiento	0/1	U3
n_articulos_empresa, n_oraciones_empresa	panel	Notas y oraciones de la rueda que mencionan a la empresa	cantidad	U3
sent_neto_empresa	panel	Tono de las oraciones que mencionan a la empresa; vacío si no hubo noticia	puntos	U3 (cruce de Gino)
peso_tono_propio	panel	Cuánto se confía en las oraciones de la empresa: n / (n + K), con K estimado de los datos	0 a 1	U4 (decisión de U6)
tono_propio	panel	Tono propio: peso × (tono de la empresa − tono del mercado); 0 si no hubo noticia. Variable de empresa del VAR	puntos (0 = como el mercado)	U4 (decisión de U6)

Tabla B.1. Diccionario de variables de los datasets unificados. Fuente: elaboración propia.

Anexo C

Alineación de las notas con las ruedas

Horas sospechosas. Se marcó como sospechosa toda hora que concentra más del 3 % de las notas de un portal en un mismo minuto. Las detectadas son: Ámbito 00:00 y 07:00; Clarín 04:00, 06:01, 07:00, 07:05, 07:08 y 09:00; iProfesional 07:00; La Nación 01:05 y 02:00; TN 05:44, 05:48 y 05:55. Suman 1.881 notas (13,4 %). La mayoría cae de madrugada, por lo que la regla las asigna a la rueda del mismo día; si en realidad salieron la noche anterior ya están en la rueda correcta, y si salieron después de las 17:00 deberían ir a la siguiente. No hay forma de saberlo con los datos, y por eso los resultados se repitieron sin ellas.

Esperas. La espera más larga entre la publicación y la rueda es de cinco días: una nota del viernes 13/02/2026 a la noche cuenta para el miércoles 18/02/2026, porque el lunes y el martes fueron feriados de Carnaval.

Controles automáticos (10 de 10). Cada nota tiene una rueda o un motivo para no tenerla; ninguna va a una rueda anterior a su publicación; ninguna publicada tras el cierre queda en la rueda del mismo día; las URL y los portales coinciden uno a uno con el archivo de sentimiento del lado de noticias; tomando la fecha sin convertir se reproduce la fecha de su serie diaria; todas las ruedas tienen noticias; y la cantidad de ruedas, el mínimo y la mediana de notas por rueda y las notas con hora sospechosa coinciden con el diagnóstico previo.

Ruedas de tono extremo. Las 19 ruedas marcadas fueron: 18/06, 15/09, 24/09, 25/09, 13/10, 16/10, 27/10, 30/10, 03/11, 14/11, 25/11, 01/12 y 23/12/2025; 23/01, 26/01, 04/02, 13/02, 16/03 y 31/03/2026. Siete coinciden con un shock de la serie diaria del lado de noticias; las diferencias se deben a la regla de la rueda, al ajuste por portal y a que la regla por muestreo no marca días con pocas notas.

Anexo D

Detalle de las pruebas de Granger

p corregidos por Benjamini-Hochberg dentro de cada nivel. • significativo después de la corrección; ° $p < 0{,}05$ solo sin corregir. «Rez.» es la cantidad de rezagos elegida por el criterio de Akaike. Se comentan en la sección 6.1.

Empresa	Rez.	Propio → retorno	Propio → volumen	Retorno → propio	Volumen → propio
ALUA	1	0,6272	0,9768	0,0593°	0,4127
BBAR	1	0,5969	0,9001	<0,0001•	0,8505
BMA	1	0,7880	0,1776	0,0091•	0,9206
BYMA	1	0,9768	0,9206	<0,0001•	0,5643
CEPU	1	0,6321	0,3490	<0,0001•	0,9565
CRES	1	0,4127	0,3169	0,0006•	0,0584°
EDN	1	0,8505	0,1442°	<0,0001•	0,8505
GGAL	1	0,5643	0,4541	0,0002•	0,9001
IRSA	1	0,5969	0,0215•	0,0002•	0,6272
LOMA	1	0,7883	0,3251	<0,0001•	0,9450
METR	1	0,6271	0,3251	<0,0001•	0,8505
PAMP	1	0,6272	0,9523	0,9206	0,5969
SUPV	1	0,5513	0,4127	<0,0001•	0,9206
TGSU2	1	0,9001	0,5969	0,0002•	0,5969
TRAN	1	0,3080	0,5969	0,0116•	0,8505
TXAR	1	0,6623	0,3251	0,0263•	0,9206
YPFD	1	0,9351	0,9206	0,0120•	0,3251

Tabla D.1. Granger con el tono propio de las 17 empresas. Fuente: elaboración propia (`Unión/06_var_granger/granger_resultados.csv`).

Empresa	Rez.	Tono → retorno	Tono → volumen	Retorno → tono	Volumen → tono
AGRO	2	0,4426	0,5936	0,0006•	0,0471•
ALUA	1	0,7962	0,6495	0,1518	0,3506
AUSO	4	0,4426	0,2305	0,0024•	0,5449
BBAR	4	0,3119	0,1817	0,0023•	0,6873
BHIP	4	0,2069	0,3417	<0,0001•	0,8127

Empresa	Rez.	Tono → retorno	Tono → volumen	Retorno → tono	Volumen → tono
BMA	1	0,2765	0,9943	0,0034•	0,5034
BOLT	2	0,1170°	0,6640	0,1416°	0,9375
BPAT	1	0,2347	0,3628	0,0003•	0,1054°
BYMA	3	0,9188	0,1293°	0,0038•	0,3691
CAPX	2	0,5481	0,6259	0,0003•	0,9607
CELU	1	0,7656	0,9672	0,7001	0,0633°
CEPU	4	0,2086	0,3628	0,0003•	0,3628
CGPA2	3	0,3691	0,4717	<0,0001•	0,3119
COME	1	0,2847	0,5446	0,0003•	0,1050°
CRES	1	0,6495	0,6126	0,2107	0,6918
CTIO	2	0,4717	0,4426	0,0005•	0,8127
CVH	1	0,5875	0,1247°	0,0042•	0,0236•
DGCU2	1	0,4252	0,7780	<0,0001•	0,5936
EDN	1	0,5875	0,4299	0,0003•	0,7448
FIPL	1	0,8180	0,5707	0,0024•	0,2107
GARO	1	0,6866	0,9502	0,0005•	0,7100
GBAN	1	0,3628	0,2181	<0,0001•	0,3249
GCDI	1	0,4808	0,0503°	0,0006•	0,2847
GGAL	1	0,2765	0,2472	0,0005•	0,1424°
GRIM	1	0,9271	0,1538	0,1416°	0,6373
HAVA	1	0,8926	0,1817	0,0784°	0,5160
IRSA	1	0,6905	0,1424°	0,3628	0,6332
LEDE	1	0,8343	0,3119	0,0471•	0,4426
LOMA	2	0,5936	0,6495	0,0135•	0,4808
LONG	1	0,6495	0,0126•	0,0030•	0,0024•
METR	4	0,4474	0,2107	<0,0001•	0,9769
MIRG	2	0,4252	0,4808	0,0017•	0,1538
MOLI	1	0,4717	0,4424	0,0024•	0,0652°
MORI	2	0,2750	0,5875	0,0462•	0,4717
OEST	1	0,6545	0,8127	0,0006•	0,4426
PAMP	1	0,3964	0,1538	0,0024•	0,4717
RIGO	1	0,2157	0,5136	0,0185•	0,3690
SAMI	2	0,6905	0,7260	0,0245•	0,1518
SEMI	3	0,7292	0,3691	0,0077•	0,4857
SUPV	1	0,3029	0,0498•	0,0030•	0,4426
TECO2	1	0,9672	0,7001	0,0327•	0,1424°
TGNO4	1	0,6332	0,8127	<0,0001•	0,6312
TGSU2	1	0,2654	0,5936	0,0154•	0,1240°

Empresa	Rez.	Tono → retorno	Tono → volumen	Retorno → tono	Volumen → tono
TRAN	1	0,7962	0,6980	<0,0001•	0,2750
TXAR	1	0,7100	0,2847	0,0784°	0,1817
VALO	1	0,9849	0,3628	0,0044•	0,1293°
YPFD	1	0,4717	0,1538	0,0044•	0,3417

Tabla D.2. Granger de las 47 empresas con el tono anormal del mercado. Fuente: elaboración propia (`Unión/06_var_granger/granger_resultados.csv`).

Sector (acciones)	Tono → retorno	Tono → volumen	Retorno → tono	Volumen → tono
Comunicaciones (2)	—	—	Sí (+)	Sí (+)
Conglomerado (3)	—	Sí (−)	Sí (+)	—
Consumo (9)	—	sin corregir	Sí (+)	Sí (+)
Energía (4)	—	—	Sí (+)	—
Financiero (8)	—	—	Sí (+)	—
Industrial (3)	—	—	Sí (+)	—
Materiales (6)	—	—	Sí (+)	—
Real Estate (3)	—	sin corregir	Sí (+)	—
Tecnología (1)	sin corregir	—	sin corregir	—
Utilities (8)	—	—	Sí (+)	—

Tabla D.3. Granger por sector. «Sí» indica significativo después de la corrección, con el signo del efecto; «sin corregir», $p < 0{,}05$ solo sin corrección. Fuente: elaboración propia (`Unión/06_var_granger`).

Anexo E

Especificaciones escritas antes de los resultados

Las dos pruebas más directas de la hipótesis se especificaron por escrito y se guardaron antes de correr ningún cálculo. Si algo hubiera que cambiar, se agrega como «cambio posterior», con la fecha y el motivo, y se informan las dos versiones. Los textos completos están en `Unión/06b_noticias_preapertura/especificacion_previa.md` y `Unión/07b_shock_volumen_noticias/especificacion_previa.md`.

E.1 Notas publicadas con el mercado cerrado (U6b)

- **Pregunta.** ¿El tono de las noticias publicadas con el mercado cerrado anticipa el precio de la rueda siguiente? Esas notas salen antes de cualquier operación de la rueda, así que la rueda no puede haberlas causado.
- **Notas.** Las asignadas a la rueda t que no se publicaron entre las 11:00 y las 17:00 del día t, sin las de hora sospechosa.
- **Variables.** Tono pre-apertura anormal del mercado (menos el promedio de las 20 ruedas previas); tono propio pre-apertura de las 17 empresas, con la misma fórmula del tono propio y el mismo K; retorno de apertura (apertura de t / cierre de $t-1-1$) y de la sesión (cierre de t / apertura de $t-1$). El mercado es el promedio simple de las 47 acciones.
- **Modelos.** Mínimos cuadrados con errores robustos HC3. Mercado: retorno $= a +$ b·tono pre-apertura anormal $+c$·retorno del día anterior $+d$·rueda tras día sin mercado. Empresas: panel con efecto fijo por empresa, tono propio y tono del mercado, retorno propio del día anterior y errores agrupados por rueda; y el mismo modelo para cada empresa por separado.
- **Evidencia.** La hipótesis se apoya si $b > 0$ y es significativo ($p < 0{,}05$) en el retorno de apertura, en el mercado o en el panel, con corrección de Benjamini-Hochberg dentro de cada grupo (4 pruebas principales y 34 por empresa). Se controla la calibración con el tono mezclado al azar.
- **Robustez agregada antes de correr.** Sin los dos días electorales.

E.2 Shock de cantidad de noticias (U7b)

- **Shock.** Puntaje z de la cantidad de la rueda contra las 30 ruedas previas (al menos 20 con dato), umbral $z > 2$. Mercado: notas de la rueda. Empresas (las 17 con tono propio): artículos que la mencionan, con al menos 3 en la rueda. Ruedas seguidas con shock cuentan como un solo evento.

- **Medición.** Igual que el estudio de eventos de tono: ventanas $[-25, -4]$ y $[-3, +5]$; media constante para el S&P Merval y modelo de mercado para cada acción; días electorales fuera de la estimación.
- **Medidas.** |retorno anormal| del día $[0]$; volumen anormal antes, el día y después; CAR antes, el día y después.
- **Significancia.** Contra 5.000 sorteos de fechas al azar, con Benjamini-Hochberg sobre las 14 pruebas principales (2 niveles $\times$ 7 medidas).
- **Evidencia.** H1 se apoya si, después de la corrección, el |retorno anormal| del día, el volumen anormal del día o de después, o el CAR de después son significativos. Si solo aparece movimiento «antes», es mercado $\rightarrow$ noticias.
- **Robustez fijada de antemano.** Umbral 2,5; z sobre $\log(1 + \text{cantidad})$; con los eventos de ventana electoral.
- **Cambio posterior 1** (después de ver la versión original). Los 13 eventos del mercado caían en la primera rueda tras un día sin mercado, que junta las notas de tres o cuatro días. La cantidad pasó a medirse por día de calendario; todo lo demás quedó igual y se informan las dos versiones.
- **Agregado posterior 2** (antes de correrlo). Prueba pre-apertura: solo notas publicadas con el mercado cerrado, con el salto de apertura anormal como medida central y Benjamini-Hochberg sobre 6 pruebas.
- **Agregado posterior 3** (descriptivo). Sensibilidad del salto de apertura del mercado sacando un evento por vez.

Anexo F

Reproducibilidad y organización del proyecto

El proyecto está en la carpeta `tesis version 3.0`, con tres partes que no se modifican entre sí. Cada carpeta tiene su script, sus resultados en CSV, sus controles automáticos y un PDF que la documenta.

Carpeta	Qué contiene
Lado Bursatil	
`00_mapa_lado_bursatil`	Mapa del lado bursátil
`01_scraping_acciones`	Selección del panel y precios diarios de las 47 acciones
`02_clustering_acciones`	Clustering y análisis del grupo de baja liquidez
`03_vix_argentino`	VIX argentino y ventana de fechas
`04_adf`	Estacionariedad de precios y retornos
`05_volatilidad_ranking`	Volatilidad por acción, ranking y picos propios
`06_hmm_regimen_mercado`	Regímenes de mercado
Lado Noticias	
`noticias`	Recolección, auditoría y depuración del corpus
`sentimiento_finbert`	Etiquetado, FinBETO, medición de calidad y serie diaria
`ner_entidades`	Reconocimiento de entidades y cruce con el sentimiento
Unión	
`00_pipeline_union`	Pipeline, diagnóstico del cruce y decisiones previas
`01_alineacion_noticias_ruedas`	U1: cada nota a su rueda (10 controles)
`02_sentimiento_por_rueda`	U2: tono, atención y ruedas de tono extremo (7 controles)
`03_sentimiento_por_empresa`	U3: tono de cada empresa por rueda (7 controles)
`04_dataset_unificado`	U4: datasets y diccionario de variables (8 controles)
`05_adf_union`	U5: estacionariedad (5 controles)
`06_var_granger`	U6: VAR, Granger e impulso-respuesta (6 controles)
`06b_noticias_preapertura`	U6b: notas con el mercado cerrado (6 controles)
`07_event_study`	U7: estudio de eventos de tono extremo (5 controles)
`07b_shock_volumen_noticias`	U7b: shock de cantidad de noticias (7 controles)
`08_robustez`	U8: robustez (5 controles)
`09_entrega_final`	Documento de la entrega, mapa de la tesis, plan actualizado y `correr_todo.py`

Carpeta	Qué contiene
`10_papers_union`	Papers relacionados con cada prueba de la unión
`11_papers_lado_noticias`	Papers relacionados con el corpus, el sentimiento y el NER

Tabla F.1. Organización del proyecto. Fuente: elaboración propia.

Cómo se rehace la unión. Desde `Unión/09_entrega_final`, el comando `python correr_todo.py` corre los pasos U1 a U8 en orden (unos dos minutos y medio), verifica que pasen los 66 controles automáticos y compara la huella de cada uno de los 64 archivos de resultados con la corrida anterior. Los documentos PDF se regeneran con los scripts de `99_generadores_documentacion`. Esta tesina se compila desde `Informe Final` con `python compilar_tesina.py`, que copia las figuras, arma la bibliografía a partir de los catálogos de papers y las tablas de los anexos a partir de los CSV.

Anexo G

Bibliografía por tema

Cada paso del trabajo tiene su propia carpeta de papers, con las referencias en `referencias.bib` o `referencias_papers.md`. Esta tabla agrupa las referencias de la bibliografía según el tema al que respaldan; el archivo de cada una figura en la Bibliografía.

Tema	Referencias
Marco general	
Medios y mercado	Tetlock (2007); Garcia (2013); Fang y Peress (2009); Engelberg y Parsons (2011); Dougal et al. (2012); Verma et al. (2026); Fama (1970)
Metodología del proceso	Wirth y Hipp (2000); Seabold y Perktold (2010)
Lado bursátil (`Lado Bursatil/*/papers`)	
00 Mapa	Verma et al. (2026); Calandroni (2026); Mukherjee (2025); Amburgey (2025)
01 Selección de acciones	Nanyonga et al. (2025); Lesmond et al. (1999)
02 Clustering	Mantegna (1999); Rousseeuw (1987); Onnela et al. (2003); Marti et al. (2021); Pharasi et al. (2020); Ghosh (2025); Arratia y Cabaña (2013); Ramírez-Carrillo et al. (2025); Alexandre et al. (2021); Huth y Abergel (2011); Busca y Thomir (2023); Lo y MacKinlay (1990)
03 VIX argentino	Segovia y Favata (2022a); Segovia y Favata (2022b); Larre y Auza (2019); Otuki et al. (2008); Calandroni (2026); Sakowski et al. (2023); Papaioannou et al. (2014); J.P. Morgan y Reuters (1996); Xenofontos (2014)
04 Estacionariedad	Dickey y Fuller (1979); Zablotsky (2002); Worthington y Higgs (2003); Medina Pérez (2013); Jain et al. (2020); Malafeyev et al. (2017); Kulikova et al. (2024); Rocha Filho y Rocha (2019)
05 Volatilidad por acción	Kalnina y Tewou (2024); Papaioannou et al. (2014); Otuki et al. (2008)
06 Régimen de mercado	Hamilton (1989); Schwarz (1978); Kim (1994); Ataurima Arellano (2016); Caballero Martínez y Caballero Claure (2016); Blake et al. (2025); Ataei (2025); Majumder et al. (2023); Rabiner (1989)
Lado de noticias (`Unión/11_papers_lado_noticias`)	
Recolección del corpus	Barbaresi (2021); Garg et al. (2025); Foley (2026); Hatwar et al. (2024); Dodge et al. (2021); Lee et al. (2021); Fronzetti Colladon y Vestrelli (2026)

Tema	Referencias
Modelo de sentimiento	Cañete et al. (2020); Devlin et al. (2019); Araci (2019); Gururangan et al. (2020); Malo et al. (2014); Loughran y McDonald (2011); Pérez et al. (2021); Gutiérrez-Fandiño et al. (2022); Pan et al. (2023); Marín et al. (2023); García-Díaz et al. (2023)
Etiquetado y evaluación	Gilardi et al. (2023); Aguda et al. (2024); Calderon et al. (2025); Gemma Team (2026); Kapoor y Narayanan (2023); Xue et al. (2026)
Entidades nombradas	Tjong Kim Sang (2002); Honnibal et al. (2020); Ujiie et al. (2021); Golde et al. (2025); Asgarieh et al. (2024)
Unión (`Unión/10_papers_union`)	
U2 Tono por rueda	Braña et al. (2016); Rodríguez-García et al. (2023); Stan et al. (2026); Mavillonio et al. (2026); Carbó Casals (2026); Shiffler (1988)
U3 Tono por empresa	Tang et al. (2023); Sinha et al. (2023); Chen (2025)
U4 Atención y volumen	Cao et al. (2025); Rojas y Kristjanpoller (2015); Efron y Morris (1975); Fang y Peress (2009); Da et al. (2011)
U5 Estacionariedad del tono	Correa Rocha (2026); Dickey y Fuller (1979); Kwiatkowski et al. (1992)
U6 VAR y Granger	Granger (1969); Sims (1980); Lütkepohl (2005); Benjamini y Hochberg (1995); Verma et al. (2026); Mukherjee (2025); Chniguir y Henchiri (2022); Wu et al. (2026); Jazbec et al. (2020); Coronado et al. (2022); Coronado et al. (2023); Cruz Montaña y Tirado León (2025); Galdi y Gonçalves (2018)
U6b Notas pre-apertura	Glasserman et al. (2025); Knuteson (2020)
U7 y U7b Estudios de eventos	MacKinlay (1997); Brown y Warner (1985); Kargarzadeh et al. (2026); Ardia et al. (2022); Guo et al. (2017)
U6 y U8 Pruebas múltiples	Harvey et al. (2016); Harvey y Liu (2020); Nikolopoulos (2026)
Trabajo futuro	Yang et al. (2024); Wu et al. (2026)

Tabla G.1. Referencias agrupadas por tema. Fuente: elaboración propia.