Scraping de acciones

Selección del panel de empresas

Tesina — Impacto de shocks informativos en acciones argentinas (BYMA / S&P Merval). Documento exclusivamente del lado bursátil. No toca noticias, sentimiento ni gazetteer.

Ubicación de todo lo generado. `D:\2.Tesina\tesis version 3.0\Lado Bursatil\01_scraping_acciones\`.
Es el punto de partida del lado bursátil: todas las carpetas siguientes leen el panel que sale de acá.

1. Objetivo

Definir con qué empresas se trabaja, con un criterio basado en datos verificables y guardado junto con el resultado. La pregunta concreta: ¿el panel puede ampliarse más allá de las 20 empresas oficiales del S&P Merval? Más empresas pueden dar mejores resultados en los análisis siguientes (clustering, VAR, HMM), pero sin sacrificar calidad de dato: una acción con huecos de cotización o sin operaciones reales no aporta, contamina.

2. Universo de partida — las 53 candidatas

Se parte de 53 tickers del Panel General y Panel Líderes de BYMA: las 20 oficiales del Merval más 33 candidatas de sectores similares.

> **53 tickers, 52 empresas**
> TGLT.BA y GCDI.BA son el mismo emisor: TGLT pasó a llamarse GCDI. El ticker viejo ya no tiene datos en Yahoo Finance, por eso TGLT figura como "sin datos" — no es una empresa que se haya caído del panel, sigue presente como GCDI.

Nombres y sectores. Verificados contra la ficha de cada ticker en Yahoo Finance. El sector se asigna por el negocio principal de la empresa; los holdings diversificados (Garovaglio y Zorraquín, Sociedad Comercial del Plata, Cresud) van como Conglomerado.

Ventana temporal — fija, 3 años exactos: 2023-05-03 → 2026-05-03. El final coincide a propósito con el final de la ventana del corpus de noticias del compañero (2026-05-03), para que el panel de 3 años y la ventana de 1 año que usan VIX, ADF y volatilidad terminen el mismo día. La última rueda con datos es el 30/04/2026: el 01/05 es feriado y el 02-03/05 es fin de semana.

3. Qué se midió — cobertura de días y de volumen

Para cada una de las 53 candidatas se descargó la serie diaria completa (Open/High/Low/Close/Volume, vía yfinance, precios ajustados) y se midieron dos cosas por separado:

Medida	Qué es
dias	Cuántas ruedas trajo Yahoo Finance en la ventana, recortadas al calendario real de BYMA (ver sección 4). El máximo observado entre las 53 es 731.
pct_dias_con_volumen	De esos días, qué porcentaje tuvo Volume > 0 (operaciones reales), contra días con Volume = 0.

Qué pasa exactamente en un día con Volume = 0

No es una fila vacía ni un día faltante — Yahoo Finance sí entrega el renglón, pero con el precio "pegado" al último valor que sí operó y Volume en cero. Ejemplo real, tomado de una de las candidatas con peor cobertura de volumen (Polledo, POLL.BA): retorno diario exactamente 0,000000 en esos días, con rachas de varios días seguidos así. Por eso el criterio de selección no puede basarse solo en el calendario, tiene que exigir también volumen real.

4. El criterio de selección

Dos condiciones, ambas obligatorias:

Condición	Umbral	Por qué
Cobertura de calendario	dias = máximo observado (731), sin excepciones	Sin tolerancia: una empresa a la que le falta un solo día también queda afuera.
Días con volumen real	≥ 90%	Tolera algún corte de datos aislado, pero excluye a las que tienen huecos largos de inactividad.

Calendario real de BYMA — tomado del índice, no de cada acción

Yahoo Finance agrega, para cada acción individual, una fila "fantasma" en los feriados de BYMA (precio pegado al cierre anterior, Volume = 0) que el índice ^MERV no tiene. Se confirmó con YPFD.BA el 01/05/2026 (feriado): la acción trae una fila con Volume = 0, el índice no trae nada ese día. Como pasa en varias fechas a lo largo de los 3 años, el script descarga primero ^MERV y usa su lista de fechas como filtro para todas las acciones — así todas comparten exactamente las mismas ruedas que el índice. Sin ese filtro, el máximo de días sería 732 en vez de 731 y la mayoría de las acciones mostraría ~99,9% de días con volumen en vez de 100%, por feriados que no son ruedas reales.

Reintentos ante fallas transitorias de Yahoo Finance

Yahoo Finance falla de forma intermitente para algunos tickers: GARO.BA y HAVA.BA llegaron a dar "sin datos" en una corrida y días completos en la siguiente. Para no confundir una falla de la fuente con una baja real, el script reintenta hasta 3 veces por ticker antes de declarar "sin datos"; con eso el resultado es estable entre corridas.

5. Eventos corporativos mal ajustados por Yahoo Finance

Yahoo Finance entrega precios ajustados por splits y dividendos en acciones, pero en dos casos el ajuste vino mal. Se detectaron buscando retornos diarios mayores a ±50% en las 47 acciones seleccionadas, y se corrigen dentro del propio script (lista CORRECCIONES), con el ajuste estándar de un split: precios divididos por el factor y volumen multiplicado por el mismo factor.

Acción	Qué vino mal	Corrección
SEMI.BA	Yahoo registra un split de 4,227 el 16/12/2024 y ajustó los días anteriores, pero dejó ese día con el precio sin dividir: $113,2 entre $27,3 y $29,8.	Solo el 16/12/2024, dividido por 4,227 (queda en $26,8).
AGRO.BA	Dividendo en acciones de noviembre 2023 (Yahoo lo registra como split 21:10 el 06/11/2023) que Yahoo no aplicó a los precios anteriores: la serie mostraba una caída falsa de −88%.	Todo hasta el 02/11/2023, dividido por 2,1.

> **Lo que se dejó como está**
>
> **AGRO.BA 03/11/2023:** aun después del ajuste, ese día cierra en $13,9 (−76%) y el siguiente en $27 (+94%). Tiene 8,5 millones de acciones operadas, así que no hay prueba de que sea un dato falso; se mantiene, pero conviene tenerlo presente al interpretar a AGRO en los análisis de 3 años.
>
> **Saltos grandes que son reales:** GCDI 24/01/2024 (+97%), CELU 17/09/2025 (+54%) y 18/02/2026 (−40% y +50% al día siguiente), RIGO 18/06/2025 (+31% y −20%). En todos el precio se sostiene o el movimiento viene con volumen muy por encima de lo normal, la firma de un shock real y no de un error de datos.

6. Resultado — 47 de 53 pasan el criterio

47 de las 53 candidatas cumplen las dos condiciones. Quedan repartidas en 10 sectores:

Sector	Empresas	Tickers
Consumo	9	GRIM, HAVA, LEDE, LONG, MIRG, MOLI, MORI, SAMI, SEMI
Financiero	8	BBAR, BHIP, BMA, BPAT, BYMA, GGAL, SUPV, VALO
Utilities	8	CEPU, CGPA2, DGCU2, EDN, GBAN, METR, PAMP, TRAN
Materiales	6	ALUA, CELU, FIPL, LOMA, RIGO, TXAR
Energía	4	CAPX, TGNO4, TGSU2, YPFD
Conglomerado	3	COME, CRES, GARO
Industrial	3	AGRO, AUSO, OEST
Real Estate	3	CTIO, GCDI, IRSA
Comunicaciones	2	CVH, TECO2
Tecnología	1	BOLT

Las 6 que quedan afuera:

Ticker	Empresa	Motivo
CARC.BA	Carboclor	462 de 731 días (cotiza desde 06/2024) y solo 39,0% con volumen real
HARG.BA	Holcim Argentina	731 días, pero solo 67,2% con volumen real
NQNO.BA	NII Holdings (Nextel)	Sin datos en Yahoo Finance
POLL.BA	Polledo	731 días, pero solo 50,2% con volumen real
ROSE.BA	Instituto Rosenbusch	731 días, pero solo 87,3% con volumen real
TGLT.BA	TGLT SA (hoy GCDI)	Sin datos en Yahoo Finance

Casos al borde del umbral de volumen. GCDI.BA entra con 94,9% de días con volumen real; ROSE.BA queda afuera con 87,3%.

Las 20 oficiales del Merval, todas incluidas. Las 20 cumplen el máximo de días y ≥90% de volumen real. El panel las contiene a las 20, más 27 adicionales.

7. Archivos generados

`D:\2.Tesina\tesis version 3.0\Lado Bursatil\01_scraping_acciones\`

Archivo	Qué es
scraping_acciones.py	Único script. Descarga ^MERV para fijar el calendario real; descarga las 53 (con reintentos y las correcciones de eventos corporativos) y mide cobertura -> aplica el criterio -> guarda los precios diarios de las que pasan.
cobertura_53_candidatas.csv	Las 53 candidatas con sus días, % de volumen y estado (descargada / sin_datos).
panel_acciones_final.csv	Las 47 que pasan el criterio, con empresa y sector.
descartadas_por_cobertura.csv	Las 6 que no pasan, con sus días y % de volumen.
precios_diarios_47_acciones.csv	Precios día por día (Open/High/Low/Close/Volume) de las 47 seleccionadas, recortados al calendario real y con los dos eventos corporativos corregidos — 34.357 filas.

8. Qué queda fuera de este documento (a propósito)

Este documento cubre únicamente la selección de acciones a partir de datos de mercado (cobertura y volumen). No evalúa si estas empresas tienen o no menciones en el corpus de noticias, ni toca el diccionario de variantes de nombres (gazetteer) usado para detectar sentimiento por empresa — eso corresponde a la rama de noticias del trabajo.

9. Referencias bibliográficas

Trabajos previos sobre este tema, en español, inglés y portugués. Los que son de acceso libre están descargados en `papers\` dentro de esta misma carpeta (1 archivos); los que tienen acceso restringido se citan con su enlace oficial. La misma lista, en formato BibTeX para citar en la tesis, está en `papers\referencias.bib`.

[1] Nanyonga, E., Kasozi, J., Mayambala, F., Kayondo, H. W. y Davison, M. (2025). A Stochastic Model for Illiquid Stock Prices and its Conclusion about Correlation Measurement. Research in Mathematics, 13(1), 2026. arXiv:2509.10553.

De qué trata: Modela los precios de la bolsa de Uganda, que pasan gran parte del tiempo sin cambiar por falta de operaciones. Muestra que cuantos más días "quietos" tiene una acción, más baja sale su correlación medida con otras, aunque la relación de fondo sea alta.

Relación con este análisis: Respalda el criterio de ≥ 90% de días con volumen real: los días con Volume = 0 (precio pegado) no solo ensucian la serie de esa acción, también achican artificialmente sus correlaciones con las demás — justo la medida que usan el clustering (02) y el VAR.

Archivo: `papers\2025_Illiquid_stock_prices_correlation.pdf` · inglés

[2] Lesmond, D. A., Ogden, J. P. y Trzcinka, C. A. (1999). A New Estimate of Transaction Costs. Review of Financial Studies, 12(5), 1113–1141.

De qué trata: Usa la frecuencia de días con retorno cero como medida de iliquidez y de costos de transacción de una acción.

Relación con este análisis: Es la referencia clásica para medir liquidez a partir de días sin movimiento de precio — la misma lógica del criterio de porcentaje de días con volumen real.

No descargado: acceso por suscripción (Oxford University Press / JSTOR).
https://ideas.repec.org/a/oup/rfinst/v12y1999i5p1113-41.html · inglés