Clustering de acciones

¿Existen familias de acciones que se comportan parecido?

Tesina — Impacto de shocks informativos en acciones argentinas (BYMA / S&P Merval). Documento exclusivamente del lado bursátil. No toca noticias, sentimiento ni gazetteer.

Ubicación de todo lo generado. `D:\2.Tesina\tesis version 3.0\Lado Bursatil\02_clustering_acciones\`. Input: el panel de 47 acciones de `01_scraping_acciones`.

1. Objetivo

Si existen grupos de acciones que reaccionan de forma parecida entre sí, el impacto de las noticias se podría analizar por familia en vez de acción por acción — más señal, menos ruido, un relato más simple que 47 series sueltas. Este documento evalúa esa pregunta sobre el panel de 47 acciones (ver 01_scraping_acciones): K-Means, Jerárquico y MST, sobre 3 representaciones de comportamiento, en 2 ventanas temporales.

> **Qué representaciones se usan, y por qué no otras**
>
> Se usan solo representaciones que miden comportamiento (cómo se mueve el precio, cómo varía el volumen) — se descartó deliberadamente cualquier representación de nivel "crudo" (precio promedio, volumen promedio sin normalizar), porque eso agrupa por magnitud — caro contra barato, mucho volumen contra poco — no por comportamiento, y no responde la pregunta de la sección anterior.

2. Metodología aplicada

Representación	Qué mide	Distancia / algoritmo base
Precio	Retornos logarítmicos diarios, normalizados por empresa	1 − correlación entre series
Volumen	Log-volumen diario, normalizado por empresa	1 − correlación entre series
13 features	Retorno medio, volatilidad, asimetría, curtosis, máxima caída, beta y correlación contra el promedio del panel, momentum 20d/50d, volumen medio/desvío, volumen anormal, correlación volumen-retorno	Distancia euclídea (features estandarizadas)

Cada representación se corrió con 3 algoritmos (K-Means, Jerárquico con linkage average/ward, MST) sobre 2 ventanas, probando k de 2 a 8 y quedándose con el k de mayor silueta. En total, 18 combinaciones (3 representaciones × 2 ventanas × 3 algoritmos) sobre las 47 acciones del panel.

> **Las dos ventanas, alineadas con el resto del análisis**
>
> "3 años" es el panel completo (2023-05-03 → 2026-05-03, exacto). "1 año" no es un recorte arbitrario de los últimos 365 días del panel — se toma la ventana de `../03_vix_argentino/vix_arg.csv` (2025-01-02 → 2026-04-30), la misma que usan VIX, ADF y volatilidad por acción. El retorno se calcula sobre la serie completa y recién después se recorta a cada ventana, para no perder el primer día.

Datos de entrada. Los precios ya incluyen las dos correcciones de eventos corporativos de 01_scraping_acciones (SEMI 16/12/2024 y AGRO hasta el 02/11/2023), que entran de lleno en la ventana de 3 años.

3. Resultado — casi todo degenerado, y un grupo de tamaño real

Ranking de las 10 combinaciones con mejor silueta, y qué tan parejo es el reparto real de empresas:

Análisis	Período	Método	k	Silueta	Tamaños de los grupos
13 features	3 años	MST	2	0,567	46 y 1 — degenerado (AGRO aislada)
13 features	3 años	Jerárquico	2	0,430	40 y 7 — tamaño real (ver sección 4)
13 features	3 años	K-Means	2	0,406	39 y 8 — tamaño real (ver sección 4)
13 features	1 año	MST	2	0,383	46 y 1 — degenerado (BOLT aislada)
Precio	1 año	Jerárquico	2	0,357	46 y 1 — degenerado (RIGO aislada)
Precio	1 año	MST	2	0,357	46 y 1 — degenerado (RIGO aislada)
Precio	3 años	Jerárquico	2	0,330	45 y 2
Precio	3 años	MST	2	0,327	46 y 1 — degenerado (GRIM aislada)
13 features	1 año	K-Means	6	0,249	16, 14, 11, 3, 2 y 1
13 features	1 año	Jerárquico	6	0,246	18, 12, 11, 3, 2 y 1

La mejor silueta de todas (0,567, MST) es un caso degenerado: aísla a AGRO sola contra las otras 46. La mayoría del top 10 tiene esa misma firma — 1 o 2 outliers contra el resto —, salvo dos splits con tamaño real, ambos sobre "13 features" a 3 años: 40/7 con Jerárquico y 39/8 con K-Means.

4. El grupo de 8 — qué lo distingue: sobre todo, la liquidez

13 features, 3 años, K-Means, k=2, silueta 0,406 separa 39 empresas de un grupo de 8: AGRO, CELU, FIPL, GARO, GCDI, GRIM, LONG, RIGO. Jerárquico (silueta 0,430) encuentra prácticamente el mismo grupo: coincide en 7 de las 8, todas menos FIPL.

A primera vista el grupo es más volátil y rinde menos que el resto:

Grupo	Retorno diario promedio	Volatilidad diaria (desvío)
Las otras 39	0,281%	3,85%
AGRO, CELU, FIPL, GARO, GCDI, GRIM, LONG, RIGO	0,123%	4,55%

Pero lo que más lo separa del resto es la liquidez. Ordenando las 13 features según cuánto difieren entre el grupo y el resto, las primeras no son la volatilidad sino las huellas de una acción que se opera de a ratos: poca correlación con las demás y un volumen irregular.

Feature	Diferencia grupo vs. resto (en desvíos estándar)
Correlación con el promedio del panel	−2,10
Volumen anormal (irregularidad del volumen)	+2,00
Desvío del volumen	+1,79
Retorno medio	−1,54

Feature	Diferencia grupo vs. resto (en desvíos estándar)
Curtosis (días extremos)	+1,39
Beta	−1,18

La liquidez de cada empresa del grupo, en los 3 años:

Empresa	Días sin operar	Días con el precio igual al anterior	Acciones operadas en un día típico	Puesto por volumen (1 = el menor)
GCDI	37	9,6%	222.220	22 de 47
RIGO	31	17,9%	779	1 de 47
GRIM	23	16,6%	1.077	2 de 47
GARO	22	11,1%	9.476	8 de 47
FIPL	1	3,3%	46.682	16 de 47
AGRO	0	1,8%	1.990.626	41 de 47
CELU	0	1,9%	126.192	19 de 47
LONG	0	3,1%	232.641	23 de 47

En promedio, el precio de una empresa del grupo queda igual al del día anterior en el 8,2% de los días, contra 2,1% en el resto del panel; 7 de las 8 están en la mitad del panel con menos volumen. Las cuatro con más días sin operar — GCDI, RIGO, GRIM, GARO — están todas en el grupo.

> **Por qué la baja liquidez arma un grupo**
>
> Tener un dato todos los días no es lo mismo que operar todos los días: cuando nadie opera una acción, Yahoo Finance igual entrega la fila, con el precio del día anterior y volumen 0. Una acción cuyo precio queda congelado muchos días "no acompaña" al resto del mercado aunque su negocio sí lo haga, y su correlación medida con las demás sale más baja que la real (Nanyonga et al., 2025, en las referencias de 01_scraping_acciones). El clustering la ve distinta por cómo se actualiza su precio, no por cómo reacciona.

Para comprobarlo, se repitió el mismo K-Means en tres versiones (robustez_grupo_liquidez.csv):

Prueba	Acciones	Silueta	Tamaños	Coincidencia con el grupo
A) Como está hoy	47	0,406	8 / 39	8 de 8
B) Días sin operación como dato faltante	47	0,400	7 / 40	7 de 8
C) Sin las 4 acciones con más días sin operar (GCDI, RIGO, GRIM, GARO)	43	0,219	16 / 27	4 de 8

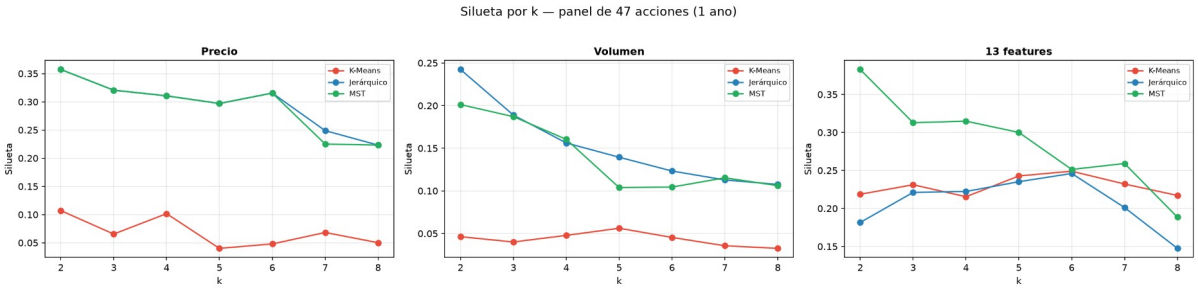
Lectura: tratar los días sin operación como faltantes casi no cambia nada (prueba B: silueta 0,400, 7 de las 8), así que el grupo no es un error de carga de esos días. Pero si se sacan las 4 acciones menos líquidas (prueba C), el grupo se deshace: la silueta cae de 0,406 a 0,219 y el reparto pasa a 16 / 27, sin una identidad clara. El grupo

existe, sobre todo, porque existen acciones de baja liquidez. Las otras 4 del grupo se operan con normalidad y entran por otros rasgos — por ejemplo, la volatilidad extrema de CELU o el día dudoso de AGRO.

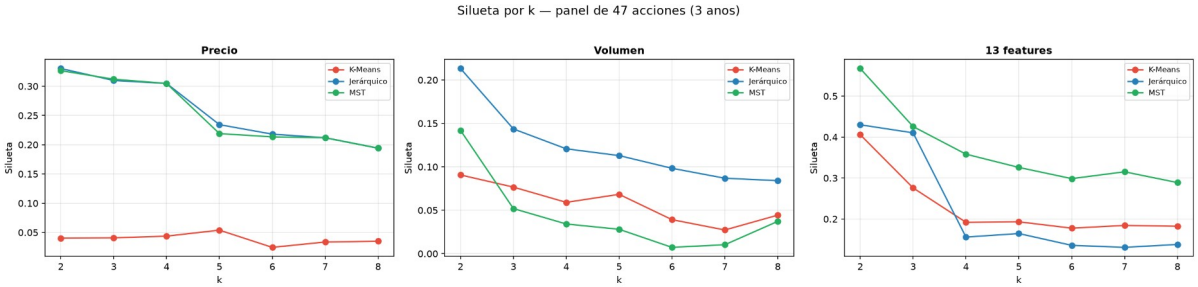
> **Dos aclaraciones**
>
> **GCDI:** hoy se opera con normalidad (su volumen típico es como el de la acción promedio); sus días sin operar se concentran en 2023 y principios de 2024, antes del salto de precio del 24/01/2024.
>
> **AGRO:** además de estar en el grupo es la empresa que MST aísla sola. Conserva un día dudoso (03/11/2023: −76% y +94% al día siguiente, ver 01_scraping_acciones) que infla su volatilidad, curtosis y máxima caída en la ventana de 3 años.

5. Gráficos — silueta por k, cada ventana

Ventana de 1 año



Ventana de 3 años (todo el período)



En Precio y Volumen, K-Means se mantiene bajo y plano para todo k (silueta entre 0,025 y 0,107) — sin estructura de grupos. Jerárquico y MST muestran en general la silueta cayendo a medida que k crece, la firma típica de ir "pelando" un outlier a la vez en vez de encontrar grupos genuinos. Solo "13 features" a 3 años despega con K-Means y Jerárquico, exactamente en el resultado de la sección 4. Los valores de cada punto están en siluetas_por_k.csv.

6. Conclusión de este paso

Sobre el panel de 47 acciones no aparecen familias de comportamiento bien definidas. Casi todas las combinaciones solo aíslan 1 o 2 outliers, y el único grupo de tamaño real (8 empresas) se explica sobre todo por la baja liquidez de varias de sus integrantes: al sacarlas, la estructura desaparece. Para el análisis con noticias, esto lleva a trabajar acción por acción (y por sector), no por familias.

Para la etapa siguiente: en las acciones de baja liquidez (GCDI, RIGO, GRIM, GARO) el precio se actualiza menos seguido. En un VAR o un test de Granger eso puede hacer que parezcan reaccionar con retraso aunque no sea así, por lo que sus resultados por empresa deben leerse con cautela.

7. Archivos generados

`D:\2.Tesina\tesis version 3.0\Lado Bursatil\02_clustering_acciones\`

Archivo	Qué es
clustering_acciones.py	Script principal. Carga el panel de 47, corre las 18 combinaciones, guarda el resumen, las siluetas y los gráficos.
resumen_clustering_47.csv	Una fila por cluster × método × período × análisis (50 filas).
siluetas_por_k.csv	Silueta de cada k (2 a 8) para las 18 combinaciones (126 filas) — los mismos valores de los gráficos.
clustering_1ano.png / clustering_3anos.png	Silueta vs. k, 3 algoritmos, una figura por representación.
analizar_grupo_no_degenerado.py	Script de la sección 4: lee el grupo de resumen_clustering_47.csv, mide su liquidez, qué features lo separan, y corre las pruebas de robustez A, B y C.
comparacion_grupo_no_degenerado.csv	Una fila por empresa (47): retorno, volatilidad, volumen, días sin operar, % de días con el precio quieto y puesto por volumen.
features_que_separan_grupo.csv	Diferencia de cada una de las 13 features entre el grupo y el resto, en desvíos estándar.
robustez_grupo_liquidez.csv	Las pruebas A, B y C: silueta, tamaños y coincidencia con el grupo en cada versión.

8. Referencias bibliográficas

Trabajos previos sobre este tema, en español, inglés y portugués. Los que son de acceso libre están descargados en `papers\` dentro de esta misma carpeta (10 archivos); los que tienen acceso restringido se citan con su enlace oficial. La misma lista, en formato BibTeX para citar en la tesis, está en `papers\referencias.bib`.

[1] Mantegna, R. N. (1999). Hierarchical Structure in Financial Markets. European Physical Journal B, 11, 193–197. arXiv:cond-mat/9802256.

De qué trata: Construye el árbol de expansión mínima (MST) a partir de las correlaciones entre los retornos de todas las acciones y muestra que el árbol agrupa a las empresas por sector económico.

Relación con este análisis: Es el origen del método MST que usamos. Mantegna usa la distancia $\sqrt{2(1-\rho)}$ y nosotros $1-\rho$; el árbol resultante es el mismo, porque el MST solo depende del orden de las distancias y una es función creciente de la otra.

Archivo: `papers\1999_Mantegna_hierarchical_structure.pdf` · inglés

[2] Rousseeuw, P. J. (1987). Silhouettes: a graphical aid to the interpretation and validation of cluster analysis. Journal of Computational and Applied Mathematics, 20, 53–65.

De qué trata: Introduce el índice de silueta: para cada elemento compara qué tan cerca está de su propio grupo y qué tan lejos del grupo más cercano; el promedio sirve para evaluar un agrupamiento y elegir la cantidad de grupos.

Relación con este análisis: Es la medida con la que se elige el k de cada combinación y se ordena el ranking de la sección 3.

No descargado: acceso por suscripción (Elsevier).
https://ftp.math.utah.edu/pub/tex/bib/idx/jcomputapplmath1980/20/z/53_65.html · inglés

[3] Onnela, J.-P., Chakraborti, A., Kaski, K. y Kertész, J. (2003). Dynamic asset trees and Black Monday. Physica A, 324, 247. arXiv:cond-mat/0212037.

De qué trata: Sigue el árbol MST en el tiempo y muestra que se "encoge" durante una crisis (el Lunes Negro de 1987): en los días de pánico todas las acciones pasan a moverse juntas.

Relación con este análisis: Ayuda a entender por qué en un período con shocks fuertes, como 2025 en Argentina, la estructura de grupos se vuelve difusa: en los días extremos todo el panel se correlaciona y las familias se desdibujan.

Archivo: `papers\2003_Onnela_dynamic_asset_trees.pdf` · inglés

[4] Marti, G., Nielsen, F., Bińkowski, M. y Donnat, P. (2021). A review of two decades of correlations, hierarchies, networks and clustering in financial markets. En Progress in Information Geometry, 245–274. arXiv:1703.00485.

De qué trata: Revisión de veinte años de investigación sobre clustering de series financieras: distancias basadas en correlación, métodos jerárquicos, árboles y redes.

Relación con este análisis: Marco general del paso: documenta las decisiones que tomamos (distancia 1 − correlación, linkage jerárquico, MST) y sus limitaciones conocidas.

Archivo: `papers\2017_Marti_review_correlations_clustering.pdf` · inglés

[5] Pharasi, H. K., Seligman, E. y Seligman, T. H. (2020). Market states: A new understanding. arXiv:2003.07058.

De qué trata: Agrupa períodos (no acciones) del S&P 500 y del Nikkei 225 según la estructura de sus matrices de correlación, y llama "estados de mercado" a los grupos resultantes. Autores de la UNAM.

Relación con este análisis: Es el puente entre este paso y el HMM (06): usa clustering para encontrar regímenes de mercado, la misma idea que el régimen Calmo / Moderado / Tenso pero por otro camino.

Archivo: `papers\2020_Market_states_UNAM.pdf` · inglés

[6] Ghosh, D. (2025). Polyspectral Mean based Time Series Clustering of Indian Stock Market. Discover Data, 3, 10. arXiv:2504.07021.

De qué trata: Aplica K-Means sobre 49 acciones del mercado indio, describiendo cada serie con información espectral.

Relación con este análisis: Panel de tamaño casi igual al nuestro (47 acciones) en un mercado emergente: referencia directa para comparar el uso de K-Means sobre una representación resumida de cada acción, como nuestras 13 features.

Archivo: `papers\2025_Kmeans_49_stocks_India.pdf` · inglés

[7] Arratia, A. y Cabaña, A. (2013). Tracing the temporal evolution of clusters in a financial stock market. Computational Economics, 41, 213–231. arXiv:1111.3127.

De qué trata: Agrupa 34 acciones del IBEX 35 (Bolsa de Madrid) en 2008-2009 y propone una forma de seguir cómo cambian los clusters a lo largo del tiempo.

Relación con este análisis: Muestra que los grupos de acciones no son fijos sino que cambian entre períodos — consistente con que nuestros resultados difieran entre la ventana de 1 año y la de 3 años.

Archivo: `papers\2011_Temporal_evolution_clusters.pdf` · inglés

[8] Ramírez-Carrillo, G., Ortiz-Mora, D. y Aguilar-Larrotta, A. (2025). Hierarchical Risk Parity for Portfolio Allocation in the Latin American NUAM Market. arXiv:2509.03712.

De qué trata: Aplica clustering jerárquico de acciones para armar carteras en el mercado regional NUAM (Chile, Colombia y Perú). Universidad del Rosario.

Relación con este análisis: Antecedente latinoamericano de clustering jerárquico sobre correlaciones de acciones, en mercados emergentes de tamaño comparable al argentino.

Archivo: `papers\2025_HRP_NUAM_Latinoamerica.pdf` · inglés

[9] Alexandre, M., Lopes de Moraes, K. y Rodrigues, F. A. (2021). Risk-dependent centrality in the Brazilian stock market. arXiv:2103.09059.

De qué trata: Calcula qué acciones son más "centrales" en la red de la bolsa brasileña (2008-2020) y muestra que ese orden cambia según el nivel de riesgo externo y las crisis.

Relación con este análisis: En el mercado vecino, la estructura de relaciones entre acciones es inestable y depende de los shocks — otra razón por la que un grupo encontrado en una ventana puede no repetirse en otra.

Archivo: `papers\2021_Risk_centrality_Brasil.pdf` · inglés

[10] Huth, N. y Abergel, F. (2011). High Frequency Lead/lag Relationships — Empirical facts. arXiv:1111.7103.

De qué trata: Con datos tick a tick, muestra que algunos activos siguen a otros con un pequeño retraso: los más líquidos tienden a adelantarse a las acciones más chicas, y las acciones más correlacionadas entre sí son las que tienen niveles de liquidez parecidos.

Relación con este análisis: Respalda los dos puntos de la sección 4 y la conclusión: que la liquidez arma grupos por sí misma (las acciones se parecen en correlación cuando se parecen en liquidez) y que en el VAR las acciones poco líquidas pueden parecer reaccionar con retraso respecto de las más operadas.

Archivo: `papers\2011_Lead_lag_relationships.pdf` · inglés

[11] Busca, J. y Thomir, L. (2023). Epps Effect and the Signature of Short-Term Momentum Traders. arXiv:2309.06711.

De qué trata: Parte del efecto Epps (Epps, 1979): la correlación entre los retornos de dos activos relacionados baja cuando se mide en horizontes cortos, porque no se actualizan al mismo tiempo. El paper estudia una excepción en divisas y criptomonedas.

Relación con este análisis: Es el mismo mecanismo que separa a las acciones poco líquidas: si una acción tarda en actualizar su precio, su correlación diaria con el resto sale más baja que la real. Medido a horizontes más largos (semanal), la diferencia se achicaría.

Archivo: `papers\2023_Epps_effect_momentum_traders.pdf` · inglés

[12] Lo, A. W. y MacKinlay, A. C. (1990). An econometric analysis of nonsynchronous trading. Journal of Econometrics, 45(1–2), 181–211.

De qué trata: Modela qué pasa con las estadísticas de los retornos cuando las acciones no operan todos los días: los precios atrasados generan correlaciones y adelantos/retrasos espurios entre acciones.

Relación con este análisis: Es la referencia clásica de la advertencia para la etapa siguiente: en las acciones de baja liquidez (GCDI, RIGO, GRIM, GARO), un test de Granger puede detectar un retraso que es efecto del precio atrasado y no una reacción real.

No descargado: acceso por suscripción (Elsevier); la versión de trabajo del MIT bloquea la descarga automática.
https://www.nber.org/papers/w2960 · inglés