U4 · Datasets unificados

Las dos tablas que juntan el lado bursátil con el lado de noticias

Tesina — Impacto de shocks informativos en acciones argentinas (BYMA / S&P Merval). Documento de la unión: lee el lado bursátil y el lado de noticias sin modificarlos.

Ubicación. `D:\2.Tesina\tesis version 3.0\Unión\04_dataset_unificado\`. Script: `construir_datasets.py`.

> **En una frase**
>
> Todo lo que usan los modelos quedó en dos archivos: dataset_mercado.csv (una fila por rueda, 244 filas y 29 columnas) y dataset_panel.csv (una fila por acción y rueda, 11.468 filas y 39 columnas). Cada columna está explicada en el diccionario de variables (anexo) y los 8 controles pasan.

1. Qué hace este paso

Hasta acá cada pieza estaba en su carpeta: los precios y el régimen en el lado bursátil, el tono y la atención en U2, el tono de cada empresa en U3. Este paso las junta en dos tablas, para que ningún modelo tenga que armar su propio cruce: si dos modelos usan la misma variable, la sacan del mismo lugar.

Tabla	Una fila es	Para qué se usa
`dataset_mercado.csv`	Una rueda	VAR del mercado (U6), régimen y robustez
`dataset_panel.csv`	Una acción en una rueda	VAR por empresa y por sector (U6) y event study (U7)

2. Qué tiene cada tabla

Mercado. Del lado bursátil: Merval y su retorno, VIX argentino, régimen del HMM (suavizado y filtrado) y la probabilidad de Tenso. Del lado de noticias: cantidad de notas, atención anormal, tono simple y ajustado por portal, porcentaje de cada clase de oración y las ruedas de tono extremo. Nuevo en U4: el monto operado del panel y su versión anormal, el tono anormal (decisión de U5) y tres marcas de días especiales.

Tono anormal. Es el tono de la rueda menos el promedio del tono de las 20 ruedas previas: cuánto más optimistas o pesimistas que lo habitual están las noticias. Se agregó después de U5, donde el tono en nivel dio inconcluso en el test de estacionariedad; es la variable de tono que usa el VAR, y el tono en nivel queda para las pruebas de robustez.

Tono propio de la empresa. Es cuánto mejor o peor se habla de la empresa que del mercado ese día, con más peso cuantas más oraciones la mencionan: peso × (tono de la empresa − tono del mercado), con peso = n / (n + 10,9). Si no hubo noticias de la empresa vale 0. El número del peso no se eligió a ojo: es la varianza de una oración suelta dividida por la varianza real del tono entre días (estimación empírica de Bayes). Con 1 oración se confía un 8%, con 5 un 31%, con 10 un 48% y con 30 un 73%. Se agregó en U6, donde se decidió cómo tratar los días sin noticias y los días con una sola oración.

Panel. Por cada acción y rueda: cierre, retorno, volumen, monto, volumen anormal, si no operó y si el precio quedó quieto; sector, si es oficial del Merval y su grupo de liquidez; si hubo noticias de la empresa, cuántas y con qué tono; y, repetidas en cada fila, las variables de mercado de esa rueda.

3. Las variables de volumen (decisión D2)

El plan de tesis pide medir el impacto sobre precio y volumen. El volumen en bruto no sirve para comparar: cada acción tiene su propio nivel (YPF opera mucho más que Agrometal) y los montos en pesos crecen con la inflación. Por eso se usa el volumen anormal: cuánto se operó hoy comparado con las 20 ruedas previas de la misma acción.

- **Volumen anormal de cada acción** = log(1 + volumen de hoy) − promedio de log(1 + volumen) de las 20 ruedas previas. 0 es un día habitual; +0,69 es el doble de lo habitual; −0,69, la mitad. El "1 +" evita el problema de los días sin operaciones.
- **Monto operado anormal del mercado:** lo mismo con el monto total (cierre × volumen, sumado sobre las 47 acciones).

Se calculan sobre la serie completa desde 2023 y recién después se recorta la ventana, como los retornos del lado bursátil; así la primera rueda de la ventana ya tiene sus 20 previas.

Un detalle: los días en que una acción no operó dan un volumen anormal muy negativo (el mínimo es -12,7), porque se compara un volumen de 0 con lo habitual. Son pocos días y quedan identificados con la columna sin_operar.

4. Marcas de días especiales

Marca	Ruedas	Por qué
dia_electoral	2	Ruedas posteriores a las elecciones bonaerenses (08/09/2025) y legislativas (27/10/2025): son a la vez noticia y los mayores saltos del mercado
eco_electoral	40	Las 20 ruedas desde cada día electoral: el salto sigue dentro de la ventana del VIX y arrastra el régimen (eco de 20 ruedas, carpeta 03)
abril_2026	20	Ruedas de abril de 2026, cuando el corpus casi no tiene notas de iProfesional

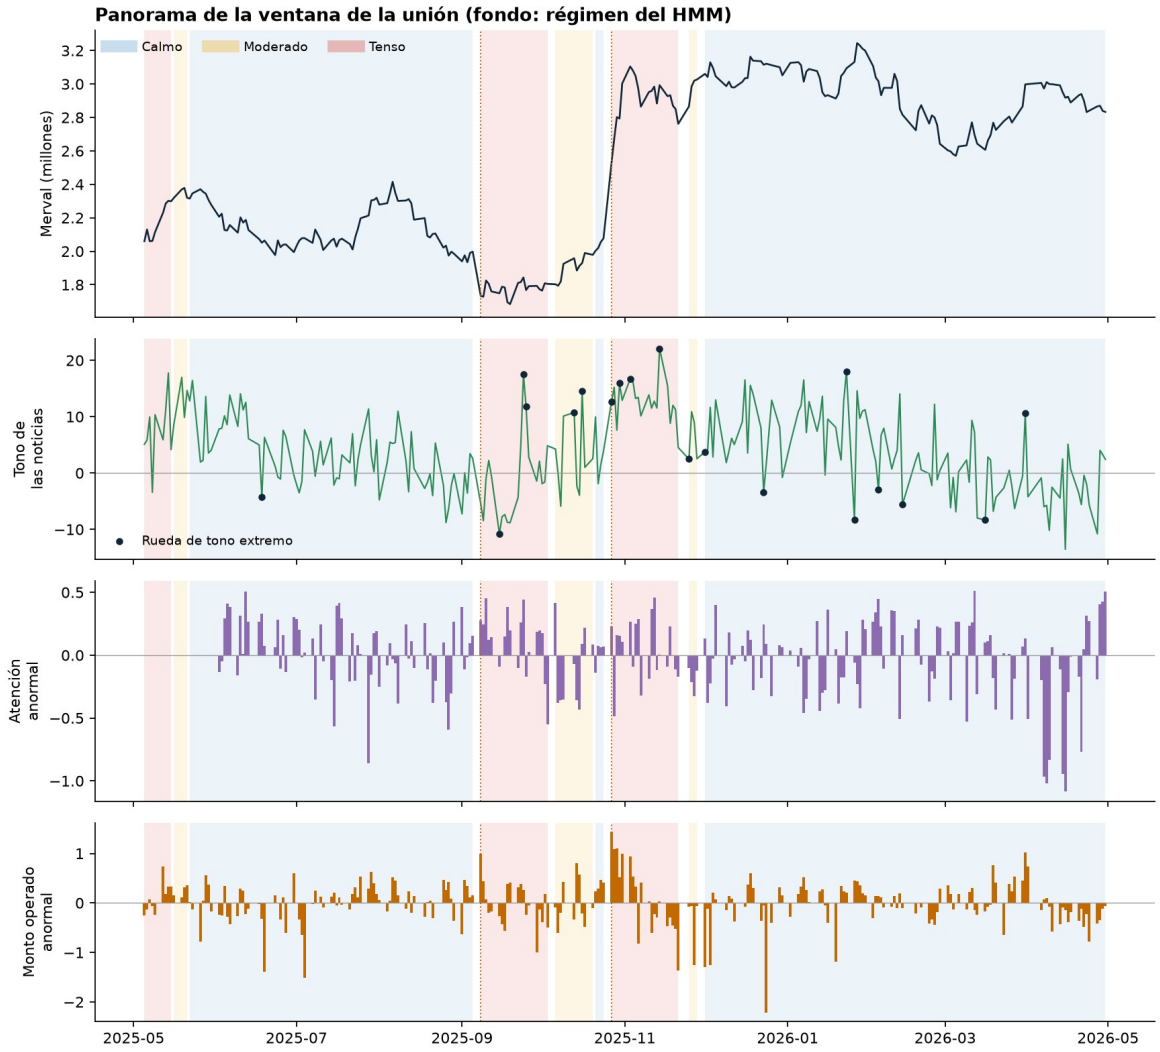
Las marcas no cambian ningún dato: sirven para analizar esos días aparte o repetir los resultados sin ellos (U7 y U8).

5. La liquidez dentro de la ventana

Las 4 acciones con más días sin operar en los 3 años (GCDI, RIGO, GRIM y GARO, 113 días entre las cuatro) casi no tienen días sin operar dentro de la ventana de la unión: 3 en total (GARO 0; GCDI 1; GRIM 0; RIGO 2). Sus días sin operar se concentraban en 2023 y principios de 2024.

Lo que sí conservan son días de precio quieto (el cierre igual al del día anterior): 79 entre las cuatro (GARO 30; GCDI 20; GRIM 18; RIGO 11), contra una mediana de 6 en las 47 acciones. La cautela sobre su liquidez sigue, pero pesa menos en este tramo; en U8 se repiten los resultados sin ellas.

6. Panorama y números básicos



Merval, tono de las noticias, atención de los medios y monto operado anormal en la ventana de la unión. El color de fondo es el régimen del HMM; las líneas punteadas, los días electorales.

Variable	Filas	Media	Desvío	Mínimo	Máximo
Retorno del Merval	244	0,16%	2,79%	-13,25%	21,77%
VIX argentino (%)	244	41,87	17,04	15,40	90,99
Monto operado anormal (log)	244	-0,00	0,46	-2,21	1,44
Tono de las noticias	244	3,91	7,00	-13,54	22,10
Tono ajustado por portal	244	-0,07	6,87	-15,34	17,15
Tono anormal (variable del VAR)	224	-0,51	6,01	-16,94	20,97
Notas por rueda	244	57,07	22,87	12,00	145,00
Atención anormal (log)	224	-0,01	0,30	-1,08	0,51
Retorno de cada acción	11.468	0,12%	3,86%	-39,57%	53,96%
Volumen anormal de cada acción (log)	11.468	-0,02	0,77	-12,68	4,79
Tono de la empresa (si hubo noticia)	3.489	12,57	62,39	-100,00	100,00
Oraciones que mencionan a la empresa	11.468	0,96	3,13	0,00	185,00

Variable	Filas	Media	Desvío	Mínimo	Máximo
Tono propio (17 empresas)	4.148	1,67	9,17	-40,67	49,05

La atención y el tono anormal tienen 224 filas porque las primeras 20 ruedas no tienen 20 previas de referencia. El tono de la empresa solo existe en las filas con noticias de la empresa.

7. Lo que se resolvió para U6

- **Ruedas sin noticias y ruedas con una sola oración (resuelto en U6).** Las 17 empresas con sentimiento propio tienen noticias en 2.919 de sus 4.148 filas (70,4%), y muchas veces una sola oración. Las dos cosas se resolvieron con el tono propio (sección 2): vale 0 sin noticias y pondera por cantidad de oraciones.
- **Moderado.** Tiene 18 ruedas: el VAR por régimen compara Calmo (177) contra Tenso (49), como se decidió.

8. Controles

Control	Resultado
Mercado: 244 ruedas, sin repetidas, las mismas del calendario bursátil	Pasa
Merval, retorno y VIX idénticos a la carpeta 03	Pasa
Panel: 47 acciones × 244 ruedas, sin repetidos	Pasa
Sin valores faltantes en las variables principales (salvo atención en las 20 primeras ruedas)	Pasa
Las notas suman lo mismo que en U1	Pasa
Sentimiento de la empresa presente ⇔ hubo noticia	Pasa
Cada rueda del panel tiene el mismo tono de mercado que el dataset de mercado	Pasa
Todas las columnas de los dos datasets están en el diccionario	Pasa

9. Archivos que genera

Archivo	Qué tiene
`dataset_mercado.csv`	244 ruedas × 29 columnas
`dataset_panel.csv`	11.468 filas (47 acciones × 244 ruedas) × 39 columnas
`diccionario_variables.csv`	Qué es cada columna, su unidad y de dónde sale (anexo de este documento)
`descriptivos.csv`	Media, desvío, mínimo, mediana y máximo de las variables principales
`resumen_u4.csv`, `verificaciones.csv`	Las cifras y los controles de este documento
`u4_panorama.png`	La figura de la sección 6

10. Limitaciones

- Precios, retornos y montos están en pesos nominales: incluyen inflación y tipo de cambio (la versión en dólares queda como trabajo futuro). Las variables anormales comparan con las 20 ruedas previas, lo que descuenta la tendencia lenta.
- El monto operado del mercado es el de las 47 acciones del panel, no el total de BYMA.

- El retorno del mercado es el del Merval; el event study lo usa como referencia para cada acción.

Anexo · Diccionario de variables

Variable	Tabla	Qué es	Unidad	De dónde sale
rueda	ambos	Día de bolsa (BYMA)	fecha	Lado Bursatil/03_vix_argentino (calendario de ^MERV)
merv_cierre	mercado	Cierre del índice Merval	puntos	Lado Bursatil/03_vix_argentino
ret_merval	ambos	Retorno diario del Merval	proporción (0,01 = 1%)	Lado Bursatil/03_vix_argentino
vix_arg	ambos	VIX argentino: volatilidad realizada de 20 ruedas, anualizada	%	Lado Bursatil/03_vix_argentino
regimen	ambos	Régimen de mercado (HMM, probabilidades suavizadas): Calmo, Moderado o Tenso	categoría	Lado Bursatil/06_hmm_regimen_mercado
regimen_filtrado	ambos	Régimen con probabilidades filtradas (solo usa información hasta ese día)	categoría	Lado Bursatil/06_hmm_regimen_mercado
prob_tenso	ambos	Probabilidad suavizada del régimen Tenso	0 a 1	Lado Bursatil/06_hmm_regimen_mercado
prob_tenso_filtrada	mercado	Probabilidad filtrada del régimen Tenso	0 a 1	Lado Bursatil/06_hmm_regimen_mercado
monto_operado	mercado	Cierre × volumen, sumado sobre las 47 acciones	pesos	Lado Bursatil/01_scraping_acciones (U4)
monto_anormal	mercado	log(monto) − promedio de log(monto) de las 20 ruedas previas	log (0 = habitual)	U4
n_notas	ambos	Notas que recibe la rueda (regla de las 17:00)	notas	U1
dias_cubiertos	mercado	Días de calendario que junta la rueda (1 normal, 3 un lunes, 4+ tras feriado)	días	U2
atencion_anormal	ambos	Atención de los medios: notas comparadas con lo habitual para ese tipo de rueda y las 20 previas	log (0 = habitual)	U2
sent_neto	ambos	Tono de las noticias: promedio del sentimiento neto de las notas de la rueda	puntos (−100 a +100)	U2 (sentimiento de Gino)
sent_neto_portal	ambos	Tono ajustado por portal (a cada nota se le resta el promedio de su portal)	puntos	U2
sent_anormal	ambos	Tono anormal: tono de la rueda − promedio del tono de las 20 ruedas previas. Variable de tono del VAR	puntos (0 = habitual)	U4 (decisión de U5)

Variable	Tabla	Qué es	Unidad	De dónde sale
sent_portal_anormal	ambos	Lo mismo con el tono ajustado por portal	puntos (0 = habitual)	U4 (decisión de U5)
pct_pos, pct_neg, pct_neu, pct_mixto	mercado	Porcentaje promedio de oraciones de cada clase en las notas de la rueda	%	U2
z_shock	mercado	Distancia del tono a lo habitual, en veces el error esperable por la cantidad de notas	veces	U2
shock, shock_pos, shock_neg	ambos	Rueda de tono extremo (|z| > 2,5), total, positiva y negativa	0/1	U2
evento_id	ambos	Número de evento (shocks del mismo signo en ruedas seguidas = un evento); 0 si no hay	número	U2
dia_electoral	ambos	Rueda posterior a una elección (08/09/2025 y 27/10/2025)	texto	U2
eco_electoral	ambos	Rueda dentro de las 20 posteriores a un día electoral (eco en el VIX y el régimen)	0/1	U4
abril_2026	ambos	Rueda de abril de 2026 (hueco de iProfesional en el corpus)	0/1	U4
ticker, empresa, sector, oficial	panel	Identificación de la acción; oficial = está en el S&P Merval	texto	Lado Bursatil/01_scraping_acciones
grupo_baja_liquidez	panel	Integra el grupo de 8 del clustering, explicado por baja liquidez	0/1	Lado Bursatil/02_clustering_acciones
cuatro_iliquidas	panel	Es una de las 4 acciones con más días sin operar (GCDI, RIGO, GRIM, GARO)	0/1	Lado Bursatil/02_clustering_acciones
cierre	panel	Precio de cierre ajustado	pesos	Lado Bursatil/01_scraping_acciones
retorno	panel	Retorno diario de la acción (pct_change sobre la serie completa)	proporción	U4 (misma definición que la carpeta 04)
volumen	panel	Acciones operadas en la rueda	acciones	Lado Bursatil/01_scraping_acciones
monto	panel	Cierre × volumen	pesos	U4
vol_anormal	panel	log(1 + volumen) − promedio de log(1 + volumen) de las 20 ruedas previas	log (0 = habitual)	U4
sin_operar	panel	La acción no operó (volumen 0)	0/1	U4
precio_quieto	panel	El cierre es igual al de la rueda anterior	0/1	U4
hubo_noticia	panel	Al menos una oración de las notas de la rueda menciona a la empresa	0/1	U3
sentimiento_propio	panel	La empresa tiene noticias en al menos 90 ruedas y usa su propio sentimiento	0/1	U3

Variable	Tabla	Qué es	Unidad	De dónde sale
n_articulos_empresa, n_oraciones_empresa	panel	Notas y oraciones de la rueda que mencionan a la empresa	cantidad	U3
sent_neto_empresa	panel	Tono de las oraciones que mencionan a la empresa; vacío si no hubo noticia	puntos	U3 (cruce de Gino)
peso_tono_propio	panel	Cuánto se confía en las oraciones de la empresa: n / (n + K), con K estimado de los datos	0 a 1	U4 (decisión de U6)
tono_propio	panel	Tono propio: peso × (tono de la empresa − tono del mercado); 0 si no hubo noticia. Variable de empresa del VAR	puntos (0 = como el mercado)	U4 (decisión de U6)