PROYECTO DE TRABAJO FINAL

Seminario de Trabajo Final

“Impacto de shocks informativos en el comportamiento bursátil de empresas argentinas: un enfoque basado en análisis de sentimiento y modelos de series temporales”

Autores:

Gino Frigoni

Nicolás Diego Diddi

Rosario – Mayo 2026

Versión 3 · octubre de 2026: actualiza el estado de los objetivos y corrige el apellido de un autor.

1. Temática seleccionada y motivación

El presente trabajo estudia cómo los shocks informativos —definidos como aumentos anormales en el volumen de noticias publicadas por medios digitales argentinos sobre temas económico-financieros— impactan el precio y el volumen de transacciones de acciones de empresas argentinas que cotizan en bolsa.

Los mercados financieros responden de manera continua a la información disponible. En el contexto argentino, caracterizado por alta volatilidad macroeconómica, las noticias sobre política económica, tipo de cambio o resultados corporativos pueden generar movimientos significativos en las cotizaciones y en el volumen de operaciones. Un evento relevante genera, en pocas horas, decenas de artículos en distintos medios, creando un shock informativo cuyo impacto no necesariamente se agota en el instante del evento, sino que puede propagarse en el tiempo de manera diferencial según el tipo de empresa y el carácter del evento.

Los avances en modelos de lenguaje preentrenados —en particular BERT y su variante en español BETO— permiten cuantificar automáticamente el sentimiento de miles de noticias financieras en español con una precisión antes inalcanzable. Combinado con datos de trending topics en redes sociales (X/Twitter) y series históricas bursátiles, este trabajo aspira a construir un pipeline que vincule el flujo informativo con el comportamiento del mercado accionario argentino.

2. Hipótesis

Hipótesis alternativa (H_1): El shock informacional tiene un impacto medible y estadísticamente significativo sobre el comportamiento bursátil —precio y/o volumen de transacciones— de las empresas argentinas que cotizan en bolsa.

Hipótesis nula (H_0): El shock informacional no tiene un impacto estadísticamente significativo sobre el comportamiento bursátil de las empresas argentinas.

3. Objetivos

3.1 Objetivo general

Modelar y cuantificar el impacto de shocks informativos provenientes de portales de noticias y redes sociales argentinos sobre el comportamiento bursátil —precio y volumen de transacciones— de empresas argentinas que cotizan en bolsa.

3.2 Objetivos específicos

1. Construir y consolidar un corpus de noticias de economía y finanzas de los principales portales digitales argentinos, estructurado como serie temporal por portal, fecha y categoría. [Completado]
2. Diseñar e implementar un modelo de análisis de sentimiento financiero en español, adaptando la arquitectura FinBERT mediante fine-tuning del modelo BETO sobre noticias financieras argentinas. [Completado]
3. Integrar datos de trending topics de X/Twitter como variable complementaria para la detección y validación de shocks informativos. [No realizado]
4. Definir y cuantificar variables de shock informativo: volumetría de publicaciones, temperatura de sentimiento agregado, y presencia de entidades en el flujo noticioso. [Completado]
5. Agrupar las empresas del mercado accionario argentino en clusters significativos, considerando clasificación sectorial y, de ser viable, sensibilidad al flujo informativo. [Completado]
6. Modelar la relación entre las variables de shock informativo y las variables bursátiles, incorporando desfases temporales para capturar el impacto diferido del flujo de noticias. [Completado]

Estado de los objetivos (actualizado en octubre de 2026)

Objetivo 3: no se realizó. Los datos de X/Twitter no llegaron a integrarse al análisis y quedan como trabajo futuro. Objetivo 6: se cumplió con un modelo VAR, pruebas de causalidad de Granger, funciones de impulso-respuesta, event studies y el análisis por régimen del HMM. El modelo de rezagos distribuidos (DLM) queda como trabajo futuro: el VAR ya mide los efectos con rezagos. El detalle de cada objetivo y de los resultados está en el documento de entrega final (Unión/09_entrega_final).

4. Metodología de trabajo

La metodología se organiza como un pipeline secuencial de cinco etapas.

4.1 Construcción del corpus de noticias

Se cuenta con un sistema de scraping operativo que recolecta noticias de las categorías de economía y finanzas de los principales portales argentinos (Clarín, La Nación, Infobae, Ámbito, TN, El Economista, iProfesional). El corpus se almacena en formato JSONL, con campos de sitio, fecha, título, contenido completo y tags. Se aplican técnicas de deduplicación para evitar el conteo múltiple de noticias replicadas entre portales.

4.2 Scraping de trending topics (X/Twitter)

Como variable complementaria, se dispone de un scraper operativo sobre X/Twitter que permite obtener los trending topics y el volumen de tweets asociados a entidades económicas y financieras argentinas. Esta fuente funciona como filtro y validador del shock informativo: un evento que aparece simultáneamente en medios de noticias y en tendencias de redes sociales constituye una señal de mayor relevancia que si aparece sólo en uno de los dos canales. La clasificación y el análisis de sentimiento de estos tweets está en etapa de revisión.

4.3 Análisis de sentimiento y detección de entidades (PLN)

Se propone un enfoque de dos pasos:

a) Detección de entidades nombradas (NER): se utilizará BETO con un cabezal de NER para identificar empresas, organismos e indicadores económicos mencionados en cada noticia, permitiendo asociar el sentimiento al nivel de entidad.

b) Análisis de sentimiento financiero: se realizará un fine-tuning de BETO sobre noticias financieras argentinas etiquetadas (positivo / negativo / neutro), replicando la metodología de FinBERT (Araci, 2019) pero adaptada al español. El modelo resultante asignará una puntuación de sentimiento a cada artículo y, por agregación, a cada entidad mencionada.

4.4 Cuantificación del shock informativo

A partir del corpus procesado se construirán las siguientes variables:

- Volumen noticioso diario por entidad: cantidad de artículos que mencionan una empresa o sector en un día dado.
- Z-score de volumen: desviación del volumen diario respecto a la media móvil de los 30 días previos. Un Z-score superior a un umbral determinará un evento de shock informativo.
- Temperatura de sentimiento: promedio ponderado de los scores de sentimiento de las noticias del día sobre una entidad.
- Volumen de tweets: cantidad de publicaciones en X/Twitter que referencian la entidad o el evento en el mismo período.

4.5 Clustering de empresas

Las empresas del mercado accionario argentino serán agrupadas según su sector de actividad principal (banca/finanzas, energía, agro, tecnología, consumo masivo, etc.), utilizando el listado de acciones disponible. Adicionalmente, se evaluará la factibilidad de un clustering basado en la respuesta histórica al flujo informativo, aunque este enfoque aún se encuentra en revisión.

4.6 Modelado de series temporales

Esta etapa vincula las variables de shock informativo con el comportamiento bursátil e integra el núcleo de la tesina. Se plantean los siguientes modelos:

- Modelo de Regresión con Rezagos Distribuidos (DLM): cuantifica el impacto diferido de un shock informativo sobre precio/volumen, asignando coeficientes a distintos rezagos temporales.
- Vector Autorregresivo (VAR) con test de causalidad de Granger: modela la interdependencia entre el volumen noticioso, el sentimiento y las variables bursátiles, y permite determinar si el flujo informativo precede causalmente a los movimientos del mercado.
- Cadenas de Markov Ocultas (HMM): para detectar estados ocultos en el comportamiento de las acciones (por ejemplo, estados de alta y baja sensibilidad a noticias) y analizar cómo el estado del mercado modula la respuesta al shock.

5. Disponibilidad de datos

5.1 Corpus de noticias

Se cuenta con un corpus de aproximadamente 14.600 noticias recolectadas de ocho portales nacionales en las categorías de economía y finanzas, cubriendo el período mayo 2025 – mayo 2026.

Portal	Noticias	Fuente
iProfesional	5.504	Sitemap XML
Clarín	3.748	Sitemap XML
El Economista	3.055	Sitemap XML
Ámbito (Economía + Finanzas)	757	Wayback Machine
La Nación	500	Wayback Machine
Infobae	500	Wayback Machine
TN	103	Wayback Machine
TOTAL	~14.667	

5.2 Trending topics (X/Twitter)

Se cuenta además con un scraper operativo sobre X/Twitter que permite obtener trending topics y volúmenes de tweets asociados a entidades económicas argentinas. Estos datos complementan el corpus de noticias y sirven como variable de validación del shock informativo.

5.3 Datos bursátiles

Las series históricas de precio y volumen de transacciones se obtendrán de fuentes públicas (Yahoo Finance u otras APIs financieras). El universo se limita a empresas de capital nacional que cotizan en BYMA, excluyendo CDRs, ETFs y acciones extranjeras.

5.4 Calidad del corpus de noticias

Como primer análisis sobre los datos disponibles, la extracción de texto mediante Trafilatura arrojó una tasa de éxito superior al 95% para contenido completo. Los campos más problemáticos son el autor —ausente en aproximadamente el 30% de los artículos— y los tags, con alta variabilidad entre portales. El título y la fecha de publicación tienen cobertura prácticamente completa, lo cual es suficiente para los análisis de volumetría y serie temporal.

6. Referencias bibliográficas

Araci, D. (2019). FinBERT: Financial Sentiment Analysis with Pre-trained Language Models. University of Amsterdam. arXiv:1908.10063.

Cañete, J., Chaperon, G., Fuentes, R., Ho, J. H., Kang, H., & Pérez, J. (2020). Spanish pre-trained BERT model and evaluation data. ICLR 2020 Workshop.

Devlin, J., Chang, M. W., Lee, K., & Toutanova, K. (2019). BERT: Pre-training of deep bidirectional transformers for language understanding. NAACL-HLT 2019.

Granger, C. W. J. (1969). Investigating causal relations by econometric models and cross-spectral methods. Econometrica, 37(3), 424–438.

Loughran, T., & McDonald, B. (2011). When is a liability not a liability? Textual analysis, dictionaries, and 10-Ks. Journal of Finance, 66(1), 35–65.

Rabiner, L. R. (1989). A tutorial on hidden Markov models and selected applications in speech recognition. Proceedings of the IEEE, 77(2), 257–286.

Sims, C. A. (1980). Macroeconomics and reality. Econometrica, 48(1), 1–48.

Yang, N., Fernandez-Perez, A., & Indriawan, I. (2024). Spillover between investor sentiment and volatility: The role of social media. International Review of Financial Analysis, 96, 103643.